



Rapport de Projet de Fin d'Études

Présenté en vue de l'obtention du

DIPLÔME NATIONAL D'INGÉNIEUR EN INFORMATIQUE

Filière : Génie Logiciel

Un méta-système de reconnaissance de panneaux
routiers basé sur l'apprentissage profond

Réalisé par : Rania Ben Romdhane

Soutenue le 05/07/2022 devant le jury :

Président :	Dr. Sami ACHOUR	ISSATSO
Examineur :	Dr. Rihem MAHMOUD	ISSATSO
Encadrant :	Dr. Selma BELGACEM	ISSATSO
Superviseur :	Mohamed l'Habib KARMOUS	TALAN

Organisme d'accueil : Talan Tunisie



Année universitaire 2021/2022

CODE :FI-GL22-004

Dédicaces

Je dédie ce travail à :

*À mon cher père,
merci de m'avoir soutenu tout au long de mes années d'études et de
m'avoir poussé chaque jour à devenir une meilleure version de
moi-même. Je n'aurais jamais pu réussir sans toi.
Je vous souhaite une longue vie, saine et heureuse.*

*À ma très chère mère,
Ma première institutrice, pour ton amour inestimable, ta confiance, ton
soutien et tes sacrifices.
Que tu trouves dans ce travail l'expression de mon profond amour.*

*À ma soeur et mon frère,
Je vous remercie pour votre soutien moral et vos encouragements.
Je vous souhaite d'atteindre tout ce que vous voulez dans cette vie.*

*À ma famille et mes chers amis,
je voudrais vous remercier tous pour m'avoir aidé de toutes les manières
possibles. Je vous souhaite une vie pleine de bonheur.*

À tous ceux qui m'aiment, je dédie ce modeste travail.

Remerciements

Au terme de ce projet, je tiens à exprimer ma profonde gratitude, à ceux qui ont contribué, de près ou de loin, à la réalisation de ce travail et à ceux qui m'ont beaucoup appris durant cette période.

Mes remerciements les plus sincères s'adressent à mon encadrante académique Mme. Selma BELGACEM, pour ses directives précieuses, ses conseils ainsi que et le temps consacré à la lecture et à la correction de ce rapport.

Également, j'exprime ma profonde gratitude à mes encadrants au sein de Talan Tunisie, Mr. Mohamed ROMDHANE et Mr. Mohamed l'habib KARMOUS pour leurs instructions précises et leurs conseils précieux afin de bien mener ce travail sur les voies de la réussite.

De même, je remercie toute l'équipe de Talan Tunisie Consulting pour leur accueil, pour leurs conseils et pour le temps passé ensemble.

Je tiens à exprimer toute ma gratitude envers mes enseignants de l'ISSATSo pour les connaissances qu'ils m'ont communiqué tout au long de ma formation.

Je tien aussi à exprimer mes remerciements aux membres de jury qui ont accepté d'évaluer ce travail.

Résumé

Notre projet "Un méta-système de reconnaissance de panneaux routiers basé sur l'apprentissage profond " est un système d'assistance aux conducteurs. En effet, plusieurs facteurs humains et matériels présentent un risque pour les conducteurs, les empêchent de se rendre compte de l'existence de ces panneaux et de prendre les précautions nécessaires et peuvent causer des infractions routières menant à de graves dégâts. Cependant, avec les récentes avancées technologiques dans les domaines de l'intelligence artificielle et l'apprentissage automatique, il devient possible de résoudre ce genre de problème en implémentant des systèmes automatiques d'aide à la conduite. Dans ce contexte, notre participation était de développer un système automatique de reconnaissance de panneaux routiers robuste et performant en présence de plusieurs défis liés à la position des panneaux, leurs états matériels, le climat et l'environnement d'une manière générale, nous avons développé également une plateforme qui permet l'évaluation de plusieurs modèles de reconnaissance de panneaux routiers avant d'intégrer celui ayant les meilleures prédictions dans une application mobile, que nous avons aussi développée, permettant d'alerter le conducteur en temps réel de la présence de panneaux routiers à l'aide d'un signal sonore et d'un étiquetage visuel. De cette manière, le conducteur bénéficiera toujours de la meilleure version du modèle de reconnaissance en mettant à jour son application.

Mots-clés : Apprentissage en profondeur, détection des objets, classification, Streaming, reconnaissance d'objet en temps réel, Cloud Computing

Abstract

Our project "Traffic Sign Deep Recongnition Meta-system" is supporting drivers's diligence when driving. Indeed, several human and material factors make it difficult for these drivers to be aware of the presence of traffic signs at the proper times to ensure safe driving, to take the necessary precautions, and to avoid committing traffic violations that could result in damage. However, with recent technological advances in artificial intelligence and machine learning, it becomes possible putting in place systems with the ability to provide driving assistance. Our involvement in this process seeks to ensure a reliable and effective system in the face of numerous difficulties linked to the positioning of traffic signs, their material states, the climate, and the environment in general. To help notify drivers to the presence of traffic signs in real time through voice signal and and visual labeling, we have decided to establish a platform to test traffic sign recognition models, then apply the model with the best predictions in our mobile application. In this way, the driver will always benefit from the latest versions just by updating his mobile application.

Key words : Deep Learning, Objet Detection, Classification, Streaming, Real Time Object Detection, Cloud Computing

Table des matières

Introduction générale	1
1 Présentation générale du projet	4
Introduction	4
1 Présentation de l'organisme d'accueil	4
1.1 Talan Consulting	5
1.2 Activités et domaines d'expertise	6
2 Présentation du projet	7
2.1 Cadre du projet	7
2.2 Problématique	7
2.3 Solution proposée	8
2.4 Les objectifs	9
3 Étude de l'existant	9
3.1 Définition des applications	10
3.2 Étude comparative	11
4 Processus de développement	11
4.1 Cross Industry Standard Process for Data Mining CRISP DM . . .	12
4.2 Étude comparative des méthodologies	13
4.3 Application de la méthodologie CRISP-DM	15
Conclusion	16
2 Spécification des besoins	17
Introduction	17
1 Spécification des besoins	17
1.1 Acteurs	18

1.2	Besoins Fonctionnels	18
1.3	Besoins non Fonctionnels	19
2	Diagrammes de cas d'utilisation	19
2.1	Diagramme de cas d'utilisation général	20
2.2	Raffinement du cas d'utilisation «Réaliser un test total de comparaison»	21
2.3	Raffinement du cas d'utilisation «Réaliser un test unitaire ciblé» . .	22
2.4	Raffinement du cas d'utilisation «Être averti de la présence des panneaux routiers»	24
	Conclusion	25
3	Étude conceptuelle	26
	Introduction	26
1	Vue statique de l'application	26
1.1	Architecture logique du logiciel	26
1.2	Plateforme d'évaluation	28
1.3	Module intelligent	30
1.4	IaaS du Cloud	31
1.5	Application mobile	32
2	Vue dynamique de l'application	34
2.1	Diagramme de séquences «Détecter et classifier les panneaux routiers»	34
2.2	Diagramme de séquences «Réaliser un test total de comparaison» .	35
2.3	Diagramme de séquences «Réaliser un test unitaire ciblé et analyser les résultats de prédiction»	36
2.4	Diagramme d'activités partitionnés «Détection des panneaux routiers avec l'application mobile»	37
	Conclusion	38
4	Processus de reconnaissance et protocole expérimental	39
	Introduction	39
1	Approches de reconnaissance	39
2	Méthodes d'apprentissage profond (Deep Learning (DL)) appliquées	41
2.1	Principe	41
2.2	Méthodes d'apprentissage profond pour la détection	42

2.3	Méthodes d'apprentissage profond pour la classification	44
3	Métriques d'évaluation des algorithmes	46
4	Préparation des données	47
4.1	Données pour la détection	47
4.1.1	Bases de données	47
4.1.2	Prétraitement sur les données	48
4.2	Données pour la classification	49
4.2.1	Bases de données	49
4.2.2	Prétraitement sur les données	51
	Conclusion	53
5	Réalisation	54
	Introduction	54
1	Environnement de travail	54
1.1	Environnement logiciel	55
1.2	Environnement Cloud (IaaS)	56
1.3	Outils d'implémentation	57
1.4	Diagramme de déploiement	57
2	Plateforme d'évaluation	58
2.1	Les interfaces graphiques de la plateforme d'évaluation	58
2.1.1	Interfaces graphiques destinées à l'administrateur	59
2.1.2	Interfaces graphiques destinées au testeur	61
2.2	Expérimentations	68
2.2.1	Performances de détection	68
2.2.2	Performances de classification	71
3	Application mobile	74
	Conclusion générale	76
	Annexe	IX

Table des figures

1.1	Talan dans le monde	5
1.2	Organigramme de Talan	6
1.3	My Drive assist	10
1.4	Radarbot	10
1.5	Méthodologie CRISP-DM	12
1.6	Diagramme de Gantt	15
2.1	Diagramme de cas d'utilisation général	20
2.2	Cas d'utilisation «Réaliser un test total de comparaison»	21
2.3	Cas d'utilisation «Réaliser un test unitaire ciblé»	23
2.4	Cas d'utilisation «Être averti de la présence de panneaux routiers»	24
3.1	Diagramme de paquetage	27
3.2	Le patron d'architecture MVT	28
3.3	Application du patron MVT sur la plateforme d'évaluation	29
3.4	Le patron d'architecture Blackboard	30
3.5	Application du patron d'architecture Blackboard sur le module intelligent	31
3.6	Le patron d'architecture micro-services	32
3.7	Le patron d'architecture MVC	33
3.8	Application du patron d'architecture MVC sur l'application mobile	33
3.9	Diagramme de séquences «Détecer et classifier les panneaux routiers»	34
3.10	Diagramme de séquences «Réaliser un test total de comparaison»	35
3.11	Diagramme de séquences «Réaliser un test unitaire ciblé et analyser les résultats de prédiction»	36
3.12	Diagramme d'activités partitionnés «Détection des panneaux routiers avec l'application mobile»	37

4.1	Processus de reconnaissance selon l'approche séquentielle	40
4.2	Architecture CNN	41
4.3	Architecture YOLO-v4	42
4.4	Architecture YOLOV4 Tiny	43
4.5	Architecture du modèle de classification	45
4.6	Extrait des datasets GTSDB, Lisa-Tiny et Custom	48
4.7	Portion de la dataset GTSRB	50
4.8	Distribution du Dataset d'apprentissage GTSRB sur les 43 classes	50
4.9	Appliquer le "Flipping" sur la dataset d'apprentissage GTSRB	51
4.10	Agrandissement des images de la dataset d'apprentissage GTSRB	52
4.11	Changement d'éclairage des images de la dataset d'apprentissage GTSRB	52
4.12	Application de Clahe gray sur la dataset d'apprentissage GTSRB	52
4.13	Distribution équilibrée de la base de données d'apprentissage GTSRB sur ses 43 classes	53
5.1	Outils et framework utilisés	55
5.2	Technologies Cloud utilisées	57
5.3	Diagramme de déploiement	58
5.4	Interface «Authentification»	59
5.5	Interface «Ajouter un testeur»	59
5.6	Interface «Liste des testeurs»	60
5.7	Interface «Dashboard d'informations générales»	60
5.8	Interface «Dashboard d'informations par modèle»	61
5.9	Interface «Dashboard d'informations sur la Dataset»	61
5.10	Interface «Test total de comparaison»	62
5.11	Interface «Résultat de test total de comparaison»	62
5.12	Interface «Test unitaire ciblé»	63
5.13	Interface «Rectification des prédictions»	63
5.14	Interface «Résultat de test unitaire ciblé»	64
5.15	Interface «Historiques des tests»	64
5.16	Interface «Authentification Azure»	65
5.17	Interface «Lancer un apprentissage»	65

5.18	Interface «Lancer un réapprentissage»	66
5.19	Interface «Suivie du status d'apprentissage (ou de ré-apprentissage)» . . .	66
5.20	Interface «Lancement du job dans Azure»	66
5.21	Interface «Caractéristiques du Compute»	67
5.22	Interface «Historique des vidéos traités dans la plateforme»	67
5.23	Interface «Stockage des vidéos dans Azure Blob Storage»	68
5.24	Les courbe maP et Loss de YOLO-v4 sur les données d'apprentissage . . .	69
5.25	Les courbe maP et Loss de YOLO-v4 Tiny sur les données d'apprentissage	69
5.26	Résultat de test avec YOLO-V4	70
5.27	Résultat de test avec YOLO-V4 Tiny	71
5.28	Validation Loss avec STN	71
5.29	Résultat de test du classifieur avec et sans STN et Clahe Gray	73
5.30	Robustesse de notre système de reconnaissance	73
5.31	Interface principale de l'application mobile "MODY test"	74
5.32	Interfaces de l'application mobile de détection et classification de panneaux routiers	75
1	Méthodologie KDD	IV
2	Fournisseurs et consommateurs du Cloud	VII
3	Les panneaux d'indication	VIII
4	Les panneaux d'interdiction	VIII
5	Les panneaux de danger	IX
6	Les panneaux d'obligation	IX

Liste des tableaux

1.1	Étude comparative des applications	11
1.2	Étude comparative des méthodologies de développement des logiciels dans le domaine des sciences des données	14
1.3	Avantages et inconvénients des méthodologies de développement des logiciels dans le domaine des sciences des données	14
2.1	Description textuelle du CU «Réaliser un test total de comparaison» . . .	22
2.2	Raffinement du cas d'utilisation «Réaliser un test unitaire ciblé»	23
2.3	Description textuelle du CU «Analyser les données»	24
2.4	Description textuelle du CU «Être averti de la présence de panneaux routiers»	25
4.1	Structuration des méthodes de détection	44
4.2	Structuration des méthodes de classification	45
4.3	Les bases de données exploitées pour la détection de panneaux routiers . .	47
4.4	Caractéristiques de la base de données de classification	49
5.1	Outils d'implémentation	57
5.2	Paramètres d'apprentissage des modèles de détection	68
5.3	Évaluation de performance de YOLO-v4, YOLO-v4 Tiny, SSD et Faster R-CNN	70
5.4	Résultats de classification sur notre base de test avec le même environnement d'enregistrement entre la base de test et la base d'apprentissage . . .	72
5.5	Résultats de classification sur une nouvelle base de test avec un environnement d'enregistrement différent entre la base d'apprentissage et la base de test	72

Liste d’abréviation

NTIC Nouvelles Technologies de l’Information et de la Communication

IA Intelligence Artificielle

DL Deep Learning

ML Machine Learning

CNN Convolutional neural network

IaaS Infrastructure as a Service

SaaS Software as a Service

PaaS Platform as a Service

BaaS Backend as a Service

GPU Graphics Processing Unit

UC Use Case

FPS Frame Per Second

GTSDDB German Traffic Sign Detection Benchmark

SSD Single Shot multibox Detector

YOLO You Only Look Once

SPP Pooling Pyramidal Spatial

PANet Path Aggregation Network

FPN Feature Pyramid Networks

maP mean average Precision

NMS Non-maximum Suppression

GTSRB German Traffic Sign Recognition Benchmark

STN Spatial Transformer Network

MVT Model View Template

Introduction générale

La science et la technologie progressent si rapidement que nous ne pouvons pas les suivre dans tous les domaines. Récemment le développement des technologies de l'information dans le monde oblige les organisations à s'intéresser aux systèmes d'information, ce qui est devenu le point central de leur développement. Cette avancée au niveau du système informatique couvre plusieurs domaines, notamment dans le domaine de la science des données.

Dans le cadre des systèmes avancés d'aide à la conduite, les systèmes de reconnaissance de la signalisation routière pourront être intégrés dans les voitures sous forme d'un tableau de bord pour alerter le conducteur pendant la conduite (en particulier chez les personnes ayant des besoins spéciaux), ce qui réduit le risque des accidents dus à la distraction, à la fatigue ou à une mauvaise visibilité causée par de mauvaises conditions météorologiques.

Bien que plusieurs systèmes de reconnaissance de panneaux routiers ont été proposés dans la littérature, le développement d'un système de reconnaissance robuste et efficace en présence de plusieurs défis dû à l'environnement routier reste difficile (voir section 2.2). Un système de reconnaissance de panneaux routière contient généralement deux parties : La détection qui consiste à extraire le panneau de signalisation d'une scène en plein air en se basant sur un ensemble de caractéristiques générale (tels que la couleur et la forme), et la classification qui consiste à classifier le panneau détecté d'une manière précise en indiquant son nom (les noms de panneaux sont définies dans la section 4).

La réalisation d'une telle solution ne peut fonctionner qu'avec l'existence de modèles robustes et bien testés. C'est dans ce contexte que s'inscrit notre projet au sein de l'entreprise TALAN Tunisie et dans le cadre d'un stage de fin d'études de 4 mois pour l'obtention d'un diplôme d'ingénieur en informatique de la part de l'Institut Supérieur des Sciences Appliquées et de Technologie de Sousse. Notre mission est le développement d'une solution

informatique qui teste la performance des algorithmes de détection et de reconnaissance de panneaux routiers et la mise en production du modèle de reconnaissance le plus performant sous la forme d’une application mobile. Pour développer ce système de génération de modèles de reconnaissance performants, nous nous basons sur des concepts de DL pour la détection et la classification intelligente, ainsi que les concepts du Cloud Computing pour l’accélération des calculs et l’exploitation des services de stockage offerts.

Cette solution est divisée en deux parties : Une plateforme de test intelligente utilisable par des testeurs afin d’analyser les prédictions des modèles de reconnaissance sur des vidéos qui contiennent des panneaux routiers dans de scènes réelles. Les testeurs seront responsables de tester les performances des modèles de détections et de classification avec la possibilité de lancer une étape de ré-apprentissage du modèle de classification pour améliorer sa performance. La deuxième partie est le développement d’une application mobile qui consomme un modèle combiné (détecteur-classifieur). Cette application permet de détecter les panneaux en temps réel, destinée aux conducteurs de toutes sorte de véhicule. Ce dernier peut à chaque fois mettre à jour son application pour bénéficier de la dernière version du modèle déployé présentant les meilleures prédictions.

Le présent rapport synthétise la démarche suivie pour arriver à la mise en place de notre solution et décrit le travail élaboré depuis la rédaction du cahier des charges jusqu’à la mise en production. Ce rapport s’articule autour de cinq chapitres qui s’enchaînent comme suit :

- Dans le premier chapitre, nous présentons l’organisation hôte et le problème qui a donné naissance à l’idée de ce travail ainsi que la solution proposée. Par la suite nous étudions les solutions existantes et nous terminons ce chapitre par une description de la méthodologie de développement.
- Le deuxième chapitre traite la spécification des besoins en commençons par la présentation des acteurs suivi par la description des besoins fonctionnels et les besoins non fonctionnels suivi par l’élaboration d’un ensemble de diagrammes de cas d’utilisation modélisant les principales fonctionnalités requises du logiciel.
- Dans le troisième chapitre, nous présentons la conception préliminaire et détaillée pour avoir une vision sur la vue statique et la vue dynamique du logiciel tout en appliquant des patrons d’architecture qui facilitent le travail.
- Dans le quatrième chapitre, nous décrivons notre processus de reconnaissance y compris les étapes de détection et de classification, et le protocole expérimental appliqué.

- Le dernier chapitre décrit la réalisation de la plateforme de test ainsi que l'application mobile où nous allons préciser les différentes technologies utilisées pendant la mise en production et présenter quelques interfaces graphiques de notre solution et les résultats d'évaluation de notre processus de reconnaissance.
- Nous clôturons ce rapport par une conclusion générale qui synthétise notre travail ainsi que les éventuelles perspectives prévues dans le cadre de l'extension et l'amélioration de notre application.

1

Présentation générale du projet

Introduction

Ce chapitre a pour objectif de situer notre projet dans son contexte général. Ainsi, nous commençons par une présentation générale de l'organisme d'accueil Talan Tunisie Consulting. Ensuite, nous détaillons la problématique à résoudre ainsi que la solution proposée. Puis nous présentons une analyse des solutions existantes. Enfin, nous déterminerons la méthodologie de développement adoptée pendant notre stage.

1 Présentation de l'organisme d'accueil

Afin de situer notre travail dans son environnement de réalisation, nous présentons dans cette section l'organisme d'accueil en décrivant ses secteurs d'activité.

1.1 Talan Consulting

Talan est une société de conseil spécialisée dans l'intégration des Nouvelles Technologies de l'Information et de la Communication (NTIC) dans le domaine de la relation client. Talan a été fondée en 2002 à Paris par Mehdi HOUAS, Philippe CASSOULAT et Eric BENAMOU.

La société délivre son expertise et son savoir-faire technologique et métier à l'échelle internationale. En effet, le groupe compte désormais plusieurs implantations : au Royaume Uni, en France, à New York, à Hong Kong et à Montréal.

La filiale «Talan Tunisie Consulting» a vu le jour en 2007 dans le but d'accélérer son développement et satisfaire les besoins de ses clients, mobilisant à ce jour environ 180 ingénieurs développeurs oeuvrant dans les nouvelles technologies et travaillant avec de grands clients. La figure 1.1 présente les implantations de Talan dans le monde. [1]



FIGURE 1.1 – Talan dans le monde

Le corps de l'entreprise est composé de trois pôles : le pôle "INTÉGRATION", le pôle "NOUVELLES TECHNOLOGIES" et le pôle "INNOVATION FACTORY". Chaque pôle est composé de plusieurs équipes. La figure 1.2 qui suit résume l'organigramme de la société.




FIGURE 1.2 – Organigramme de Talan

Chaque secteur se décompose d'un directeur qui supervise les managers. Ces derniers sont les responsables à la direction des travaux des chefs de projets. Tandis que les chefs des projets administrent les équipes de travail.

Le projet en question a été effectué au sein de l'équipe "DATA RPA" du pôle "INTEGRATION" dans lequel une grande importance est accordée aux nouveaux concepts tels que le Big Data et le Data Science.

1.2 Activités et domaines d'expertise

Le périmètre d'exercice de Talan Tunisie contient des domaines variés et complémentaires et englobe le conseil, l'assistance, la maîtrise d'ouvrage et l'intégration de nouvelles technologies et les métiers de support autour des systèmes d'informations. Elle oeuvre essentiellement dans les secteurs suivants :

- **Finance** : La filière finance de Talan intervient auprès des principaux acteurs des marchés financiers : banques de financement et d'investissement.
- **Assurance** : Talan se distingue par des connaissances solides des métiers de l'assurance lui permettant d'intervenir dans les principales problématiques de ce secteur : évolutions réglementaires, rapprochements de moyens etc.
- **Énergie et services publics** : Dans le domaine de l'énergie Talan se distingue par ses capacités à adresser les enjeux propres à l'ouverture du marché, et à intervenir

sur les sujets de type système d'informations.

- **Télécom et médias** : Talan ne cesse d'évoluer dans les domaines de Télécoms. La majorité des opérateurs ont bénéficié de ses services et solutions intelligentes.
- **Transport et logistique** : La filière Transport de Talan est issue du rapprochement avec Cereza en 2012. Talan est reconnue pour accompagner les acteurs dans leurs projets d'optimisation et de transformation de leurs organisations.

2 Présentation du projet

Nous détaillons dans cette section la problématique du projet, la solution proposée et les objectifs envisagés.

2.1 Cadre du projet

Les panneaux routiers sont souvent conçus pour avoir une forme et une couleur particulières avec des symboles à l'intérieur ce qui donne la possibilité de développement d'un système capable de les détecter et les reconnaître. Ce genre d'application s'intègre dans le contexte des systèmes d'aide à la conduite tel est le cas de notre solution qui consiste à développer des modèles de reconnaissance de panneaux routiers à l'aide d'une plateforme d'évaluation qui permet de tester les performances de ces modèles et de consommer en temps réel la meilleure version du modèle sous forme d'une application mobile qui aide l'utilisateur final à détecter les panneaux de la route lors de la conduite. Ce projet s'inscrit dans le cadre d'un stage de fin d'études, réalisé en vue d'obtention du diplôme d'ingénieur en génie logiciel de l'Institut Supérieur des Sciences Appliquées et de Technologie de Sousse (ISSATSo).

2.2 Problématique

D'une part, lors de la conduite d'un véhicule, les conducteurs sont exposés à la fatigue, à la mauvaise visibilité causée par de mauvaises conditions météorologiques ou même à

l’occultation des panneaux routiers, ce qui peut causer de graves accidents. Ces situations prouvent la nécessité d’automatisation du processus de détection et de reconnaissance des panneaux routiers.

D’autre part, le système de reconnaissance de panneaux routières est un système multiobjectif : détecter et classifier en temps réel tous les panneaux présents dans un frame (une image d’une vidéo) pouvant contenir une scène complexe présentant plusieurs défis tels que :

- Le changement d’éclairage, selon le moment de la journée, la saison et d’autres conditions météorologiques.
- Changement d’échelle, puisque la taille du panneau dépend de la distance à la caméra.
- Rotation et translations, puisque les panneaux peuvent être capturés selon différents points de vue.
- La présence d’obstacles dans la scène pouvant occulter partiellement ou même totalement le panneau.
- L’existence d’un certain nombre d’objets similaires soit en couleur ou en forme.
- La condition physique des panneaux qui se dégrade avec le temps.
- Variation de la vitesse de la voiture.
- Le frame est chargé d’information ce qui alourdit son traitement et complexifie la détection de l’objet cible.

Ainsi, le système de reconnaissance que nous allons développer doit être robuste à toutes ces conditions. En effet, ce système doit être extrêmement fiable puisque la moindre erreur lors de son utilisation par des conducteurs peut entraîner de graves accidents ou bien de graves punitions à cause du non respect de la loi de la route.

2.3 Solution proposée

En premier lieu, nous proposons le développement d’une plateforme de test web fournissant un dashboard de test du fonctionnement des différents modèles de détection et de classification. Cette plateforme permettra aux testeurs d’évaluer les performances des modèles de détection et de classification. Suite à cette évaluation, les testeurs corrigent les prédictions erronées et les réintègrent dans la base d’apprentissage afin de renforcer la robustesse du classifieur. Ensuite, une procédure de réapprentissage est lancée dans le but d’augmenter la précision du système. Par la suite, une nouvelle version du système de reconnaissance est déployée et devient accessible au conducteur pour renforcer sa sécurité.

En deuxième lieu, nous proposons d'exploiter le modèle de reconnaissance le plus performant pour détecter et classifier les panneaux routiers en temps réel à partir de vidéos en streaming afin d'assister le conducteur et de l'avertir en cas de danger. L'alerte peut être sous forme de notifications sonores ou écrites à travers une application mobile. Cette application consomme, à chaque fois, la dernière version déployée fournissant les meilleurs prédictions.

2.4 Les objectifs

L'objectif de notre projet est de développer :

1. Une plateforme de test permettant à des testeurs de vérifier les prédictions des modèles de reconnaissance et de les corriger dans le but d'agrandir la base de données d'apprentissage et de lancer un réapprentissage des ces modèles afin d'améliorer la précision du classifieur.
2. Une application mobile permettant d'assister le conducteur et de l'avertir en cas de présence de panneaux routiers.

Le modèle de reconnaissance généré doit être caractérisé par :

- Un modèle de détection performant robuste aux objets qui cachent le panneau et indépendant de la vitesse de de la véhicule.
- Un modèle de classification précis et robuste aux changement de luminosité.
- Un modèle de classification capable de réapprendre jusqu'à obtention d'une version précise.

3 Étude de l'existant

Cette étape constitue une phase d'analyse des solutions de reconnaissance de panneaux routiers existantes dans le marché. Cette étude nous permettra de dégager les avantages de ces solutions afin de les exploiter, et leurs inconvénients afin de les résoudre à travers le développement de notre solution. Les solutions existantes étudiées sont "My Drive Assist" et "Radarbot".

3.1 Définition des applications

- **Mydrive assist [2]**

L'application Mydrive assist a été conçue par la société Bosh compatible avec le système d'exploitation mobile Android. Cette application a été téléchargée plus de 50.000 fois. Lors de la détection d'un panneau routier, cette application alerte le conducteur à l'aide d'un signal sonore et propose un système de récompenses en fonction du nombre de panneaux de limitations de vitesse respectée. La figure 1.3 présente une interface de cette application.



FIGURE 1.3 – My Drive assist

- **Radarbot [3]**

C'est une application qui combine la détection de panneaux routiers de limitation de vitesse et la détection de radar, et lance des alertes en temps réel et hors ligne. La figure 1.4 illustre une interface de cette application.




FIGURE 1.4 – Radarbot

3.2 Étude comparative

Le tableau 1.1 présente une étude des avantages et des inconvénients de chaque solution de détection de panneaux routiers existante sur le marché. Le but est de comparer les fonctionnalités de ces applications, détecter leurs inconvénients et proposer notre solution pour y remédier.

TABLEAU 1.1 – Étude comparative des applications

Application	Avantages	Inconvénients
My Drive Assist	-Alertes vocaux -Gratuite. -Offre un système de récompense. -Fonctionne en temps réel.	-Ne détecte que les panneaux de vitesse. -Une connexion de données mobile est requise.
RadarBot	-Alertes vocaux -Fonctionne dans tous les pays. -Fonctionne en temps réel. -Fonctionne hors ligne.	-Contient des versions payantes. -Affiche des publicités.

Notre solution va fournir une application mobile vérifiant les principaux avantages de ces applications et va fournir un système supplémentaire d'évaluation et de mise à jour. En effet, avant de mettre en production un modèle de reconnaissance, une étape de test et d'amélioration est appliquée à travers une plateforme de test développée dans le cadre de ce projet, pour aboutir à la fin à un système efficace et performant.

4 Processus de développement

Pour la réalisation d'un projet, l'application d'une méthodologie de travail est une étape primordiale pour atteindre les objectifs attendus sans dépassement des délais prévus. Pour la gestion des projets Data Science, certaines méthodologies sont proposées telles que la méthodologie KDD (annexe 1) , la méthodologie SEMMA (annexe 2) et la méthodologie CRISP-DM que nous introduisons dans cette section. Nous choisissons d'adopter cette méthodologie pour organiser le processus de développement de notre logiciel. Nous présentons également dans cette section une étude comparative de ces méthodologies pour argumenter notre choix.

4.1 Cross Industry Standard Process for Data Mining CRISP DM

CRISP DM [4] est une méthodologie qui a été proposée par IBM en 1996 pour organiser les projets de fouille de données. Elle est devenu le processus le plus utilisé pour le développement des projets de sciences de données et trouve son application dans des domaines variés : ingénierie, médecine, marketing, etc... Cette méthode est décrite comme un processus hiérarchique et itératif et comporte six phases : la phase de compréhension du métier, la phase de compréhension des données, la phase de préparation des données, la phase de modélisation des algorithmes appliqués sur les données, la phase d'évaluation et la phase de déploiement. Ces phases sont représentées dans le modèle de cycle de vie du logiciel comme le montre la figure 1.5




FIGURE 1.5 – Méthodologie CRISP-DM
[4]

- **Compréhension du métier** : Cette phase consiste à fixer les objectifs et les exigences du projet en se posant les questions métiers et en comprenant la problématique à résoudre ou à améliorer par la science des données ainsi que l'évaluation des outils et des techniques à adopter.
- **Compréhension des données** : Cette phase est généralement la plus longue du projet. Elle implique l'étude des données collectées et leur exploration pour vérifier la qualité des données et trouver les informations cachées afin de construire un

échantillon représentatif qui nous permet d'éviter les problèmes inattendus dans les phases suivantes.

- **Préparation des données** : C'est la phase qui contient toutes les activités nécessaires afin de construire l'ensemble de données final. Elle comporte le nettoyage, l'intégration et la transformation des données pour les rendre compatibles avec les algorithmes à utiliser.
- **Modélisation** : Dans cette phase les algorithmes sont choisis et appliqués avec des jeux de paramètres pour trouver les valeurs optimales. Généralement le retour à l'étape précédente est jugé nécessaire afin d'améliorer la performance des algorithmes.
- **Évaluation** : À ce niveau les modèles et les étapes qui précèdent leur construction sont évalués tout en s'assurant que le projet respecte les objectifs métiers.
- **Déploiement** : Après la création du modèle, les résultats sont organisés et présentés au client final et le modèle est déployé pour le mettre en mode production.

4.2 Étude comparative des méthodologies

Nous nous intéressons dans cette section à la comparaison des processus de développement KDD, SEMMA et CRISP-DM afin d'argumenter le choix de la méthodologie appropriée à notre projet. Nous allons en premier lieu exposer les points communs et les points de différence. Le 1.2 illustre les correspondances et les contrastes entre les étapes de ces processus.

TABLEAU 1.2 – Étude comparative des méthodologies de développement des logiciels dans le domaine des sciences des données

KDD	SEMMA	Crisp-DM
*	*	Compréhension du métier
Sélection	Échantillonner	Compréhension des données
Prétraitement	Explorer	
Transformation	Modifier	Préparation des données
Data mining	Modèle	Modélisation
Évaluation	Évaluer	Évaluation
*	*	Déploiement

Nous notons plusieurs similarités entre les méthodologies : elles suivent la même séquence d'étapes et impliquent des tâches de pré-traitement très complexes. Cependant, ces processus de développement diffèrent par la présence de l'étape initiale (compréhension du métier) et l'étape finale (déploiement) dans la méthodologie Crisp-DM. Nous comparons également les avantages et les inconvénients de ces méthodologies comme le montre le tableau 1.3.

TABLEAU 1.3 – Avantages et inconvénients des méthodologies de développement des logiciels dans le domaine des sciences des données

Méthodologies	Avantages	Inconvénients
KDD	- Processus itératif. - Traitement de grandes quantités des données. - Description technique détaillée sur l'analyse des données	-Manque de l'aspect métier. -Des boucles de retour inévitables qui ne sont pas nécessaires. -Les auteurs ne donnent pas assez d'information sur les itérations entre étapes.
SEMMA	- Possibilité de retour à la phase d'exploration pour l'ajout supplémentaire de données.	-Absence d'étude du métier. -Absence d'étape explicite pour utiliser les connaissances découvertes.
Crisp-DM	-Traite l'aspect métier. -Possibilité de relancer ou d'affiner une partie du processus	-Informations limitées sur les boucles et les retours. -Le modèle n'est pas mis a jour depuis son lancement.

Selon ces études comparatives, la méthodologie CRISP-DM accorde une grande importance à la phase de compréhension du métier et est caractérisée par une fluidité de séquençage de ses étapes grâce à son caractère itératif bien défini qui la distingue

par rapport aux autres processus. A travers cette étude comparative, nous justifions notre choix de la méthodologie CRISP-DM comme processus de développement de notre logiciel.

4.3 Application de la méthodologie CRISP-DM

Nous détaillons l'application de la méthodologie Crisp-DM à travers le diagramme de Gantt, qui est un diagramme de planification de projet, comme illustré par la figure 1.6.




FIGURE 1.6 – Diagramme de Gantt

Notre projet va être réalisé selon les phases suivantes :

- La recherche et la collecte des documents selon les exigences du projet.
- L'étude des différents concepts métier comme les catégories des panneaux routiers, la vision par ordinateur, le Deep Learning, le Cloud Computing...
- La préparation des données en récupérant des bases de données d'apprentissage et de test publiques annotées telles que les bases décrites dans la section 4.1.1 et 4.2.1.
- Le développement des modèles de détection et de classification.
- Lancer plusieurs itérations de la méthodologie CRISP afin d'améliorer les prédictions du système de reconnaissance.
- La réalisation de la plateforme de test des modèles de reconnaissances.
- L'implémentation de l'application mobile destiné au conducteur.
- La rédaction du rapport au fur et à mesure de la réalisation de la totalité de ces tâches.

Conclusion

A travers ce chapitre, nous avons présenté l'organisme d'accueil TALAN. Nous avons également exposé la problématique et la solution proposée. Une étude de l'existant est aussi incluse dans ce chapitre. Nous avons enfin défini le processus de développement du logiciel adopté et son application. Dans le prochain chapitre nous décrivons les fonctionnalités que notre logiciel doit fournir pour répondre aux besoins du client.

2

Spécification des besoins

Introduction

Dans ce chapitre nous allons identifier les acteurs de notre système, analyser les besoins fonctionnels et les décrire à travers des diagrammes de cas d'utilisation. Nous identifions aussi les besoins non fonctionnels.

1 Spécification des besoins

Le but d'un projet est de satisfaire les besoins d'un client. Il faut analyser correctement ces besoins avant d'imposer une solution, donc la spécification des besoins constitue la phase de départ de toute application à développer indépendamment de son domaine. L'analyse des besoins fonctionnels permet de déduire les principales fonctionnalités requises du logiciel. L'analyse des besoins non fonctionnels permet de déterminer les principales caractéristiques de qualité du logiciel.

1.1 Acteurs

Un acteur représente un rôle joué par une entité externe qui interagit avec le système. Notre solution interagit avec trois acteurs :

Administrateur : celui qui administre la plateforme de test. Il a les droits de gérer les différentes entités existantes.

Testeur : c'est l'acteur responsable d'exécuter les tests des modèles et d'évaluer leurs prédictions à partir de la plateforme de test.

Conducteur : c'est l'utilisateur de l'application mobile qui l'assiste pendant la conduite.

1.2 Besoins Fonctionnels

❖ Le système doit permettre au testeur de :

- Exécuter deux types de test :

- Test total de comparaison** : en utilisant des métriques d'évaluation, comparer la performance des modèles d'apprentissage afin de sélectionner celui ayant les meilleures performances de reconnaissance.

- Test unitaire ciblé** : appliquer un modèle de reconnaissance sur une seule vidéo. Si la prédiction est erronée, la rectifier par étiquetage et intégrer les images qui contiennent les panneaux dans la base d'apprentissage afin d'élargir cette dataset et renforcer la robustesse du système.

- Lancer un réapprentissage du modèle de classification à partir de nouvelles vidéos étiquetées.

- Sauvegarder les vidéos annotées par les modèles, les résultats de classification et les résultats d'évaluation des performances de reconnaissance.

- Visualiser les résultats de prédiction et d'évaluation des modèles de reconnaissance à l'aide d'un dashboard.

❖ Le système doit permettre à l'administrateur de :

- Gérer les testeurs (créer et supprimer des comptes testeurs).

- Lancer toutes les fonctionnalités destinées aux testeurs.

❖ Le système doit permettre au conducteur de :

Être averti de la présence des panneaux routiers pendant la conduite à l'aide d'une application mobile selon deux forme :

- Cadrer les panneaux routier et afficher leurs noms en temps réel sur la vidéo en

streaming.

- Lancer un signal sonore lors de la détection de chaque panneau routier.

❖ Pour répondre aux besoins fonctionnels précédemment décrits, le système doit :

- Segmenter spatialement une scène routière pouvant être complexe, et localiser tous les panneaux routiers y figurant.
- Classifier les panneaux routiers détectés en indiquant leurs noms.

1.3 Besoins non Fonctionnels

Les besoins non fonctionnels décrivent les objectifs liés aux performances du système et aux contraintes de son environnement. Les besoins non fonctionnels que cette solution doit vérifier sont les suivants :

- Robustesse : Le système doit retourner des résultats précis et corrects malgré les conditions qu'il peut confronter.
- Fiabilité : L'application doit être disponible en continuité et doit assurer un temps de réponse raisonnable indépendamment du volume de données traitées ou du nombre de panneaux à détecter.
- Extensibilité : La solution conçue doit être extensible tolérant l'ajout facile de nouveaux modules l'adaptant à de nouveaux besoins qui peuvent apparaître dans le futur.
- Documentation technique : Le code de l'application doit être documenté afin d'assurer sa lisibilité et sa compréhensibilité. La documentation doit comprendre la définition et l'explication des APIs, des structures de données et des algorithmes.

2 Diagrammes de cas d'utilisation

Le diagramme de cas d'utilisation Use Case ([UC](#)) décrit la vue fonctionnelle statique du logiciel à développer. Il ne fournit pas d'information sur la structure interne. En utilisant les diagrammes de cas d'utilisation, nous présentons dans cette partie une modélisation générale et détaillée des différentes fonctionnalités requises du logiciel permettant de répondre aux besoins du client.

2.1 Diagramme de cas d'utilisation général

Dans le diagramme de cas d'utilisation global illustré par la figure 2.1, nous regroupons tous les cas d'utilisation de base afin d'avoir une vue globale du fonctionnement de notre système. Cette figure expose les divers cas d'utilisation destinés au testeur, à l'administrateur et au conducteur.




FIGURE 2.1 – Diagramme de cas d'utilisation général

2.2 Raffinement du cas d'utilisation «Réaliser un test total de comparaison»

Ce cas d'utilisation doit offrir aux testeurs la possibilité d'évaluer les performances de plusieurs méthodes de reconnaissance sur la même base de vidéos de test contenant des panneaux routiers. Cette évaluation permettra de comparer le taux de reconnaissance de ces méthodes afin de déployer le meilleur modèle intelligent pour une exploitation finale par le conducteur. La figure 2.2 illustre le diagramme raffiné du cas d'utilisation «Réaliser un test total de comparaison».




FIGURE 2.2 – Cas d'utilisation «Réaliser un test total de comparaison»

À l'issue de ce diagramme raffiné, et pour mieux comprendre le fonctionnement de ce CU, nous allons le décrire textuellement dans le tableau 2.1.

TABLEAU 2.1 – Description textuelle du CU «Réaliser un test total de comparaison»

Titre	réaliser un test total de comparaison
Acteur	testeur
Pré-conditions	testeur authentifié.
Post-conditions	résultats d'évaluation visualisés
Scénario principal	1) le testeur sélectionne les méthodes d'apprentissage à évaluer. 2) le testeur sélectionne la base de contenant les panneaux à détecter et à reconnaître. 3) le système affiche la liste des vidéos à traiter. 4) le testeur lance le processus d'évaluation. 5) le système détecte et classifie les panneaux routiers. 6) le système affiche les résultats de prédiction en appliquant des métriques d'évaluation.

2.3 Raffinement du cas d'utilisation «Réaliser un test unitaire ciblé»

Ce cas d'utilisation doit offrir aux testeurs la possibilité de lancer le processus de détection et de classification pour une seule méthode d'apprentissage sur une vidéo de test. Ce test a pour objectif de vérifier les prédictions du modèle et de les corriger en cas d'échec en indiquant les vraies prédictions. La figure 2.3 illustre le diagramme raffiné du cas d'utilisation «Réaliser un test unitaire ciblé».




FIGURE 2.3 – Cas d'utilisation «Réaliser un test unitaire ciblé»

Nous expliquons ce cas d'utilisation à l'aide du tableau 2.2 .

TABEAU 2.2 – Raffinement du cas d'utilisation «Réaliser un test unitaire ciblé»

Titre	réaliser un test unitaire ciblé
Acteur	testeur
Pré-conditions	testeur authentifié.
Post-conditions	résultats d'évaluation visualisés.
Scénario principal	1) Le testeur sélectionne une méthode de reconnaissance. 2) Le testeur sélectionne une vidéo contenant les panneaux à détecter et à reconnaître. 3) le testeur lance le processus de reconnaissance. 4) le système détecte et classe les panneaux routiers. 5) le système affiche les résultats de prédiction en cadrant les panneaux routiers et en affichant leurs noms sur la vidéo traitée.

Nous allons raffiner dans le tableau 2.3 le CU «Analyser les données»

TABLEAU 2.3 – Description textuelle du CU «Analyser les données»

Titre	analyser les données.
Acteur	testeur
Pré-conditions	1) testeur authentifié. 2) vidéo traitée (panneaux routiers détectés et classifiés).
Post-conditions	prédictions corrigées.
Scénario principal	1) le système affiche un formulaire de correction. 2) le testeur saisit le nombre totale des panneaux dans la vidéo et le nombre des panneaux non détectés. 3) le testeur sélectionne les prédictions correctes. 4) le testeur corrige les fausses prédictions (étiquetage).

2.4 Raffinement du cas d'utilisation «Être averti de la présence des panneaux routiers»

Le conducteur disposant de l'application mobile est averti à l'aide des alertes sonores et des boites englobantes étiquetées indiquant la présence d'un panneau. La figure 2.4 illustre le diagramme raffiné du cas d'utilisation «Être averti de la présence de panneaux routiers».




FIGURE 2.4 – Cas d'utilisation «Être averti de la présence de panneaux routiers»

Le précédent UC est expliqué à l'aide du tableau 2.4.

TABEAU 2.4 – Description textuelle du CU «Être averti de la présence de panneaux routiers»

Titre	être averti de la présence de panneaux routiers.
Acteur	conducteur
Pré-conditions	application mobile lancée avec lancement automatique de la capture vidéo (streaming).
Post-conditions	conducteur averti en temps réel.
Scénario principal	1) le système détecte les panneaux en temps réel les panneaux à partir du streaming. 2) le système classe les panneaux. 3) le système déclenche en temps réel des alertes sonores indiquant les noms des panneaux détectés. 4) le système affiche en temps réel sur le streaming des boîtes englobantes étiquetées contenant les panneaux détectés.

Conclusion

Dans ce chapitre, nous avons présenté les besoins fonctionnels et les besoins non fonctionnels de notre solution. Ensuite, nous avons détaillé les différents cas d'utilisation. Le prochain chapitre est destiné à la modélisation interne statique et dynamique de notre solution.

3

Étude conceptuelle

Introduction

Dans ce chapitre, nous allons spécifier la vue statique et celle comportementale de notre solution tout en appliquant des patrons d'architecture et des diagrammes UML.

1 Vue statique de l'application

Dans cette partie, nous commençons par décrire la conception architecturale générale de notre logiciel, puis nous détaillons la composition interne de chaque module de notre système.

1.1 Architecture logique du logiciel

La figure [3.1](#) représente un diagramme paquetage modélisant les modules globaux qui composent notre système.




FIGURE 3.1 – Diagramme de paquetage

Les modules globaux qui composent notre solution sont :

- **Plateforme d'évaluation** : permet de lancer un test de reconnaissance de panneaux routiers sur une vidéo ou une base de vidéos en appliquant un ou plusieurs méthodes d'apprentissage définies dans le module intelligent. La plateforme d'évaluation exploite également le service de calcul de l'IaaS Cloud pour lancer un éventuel réapprentissage du modèle de reconnaissance et le service de stockage pour sauvegarder l'ensemble d'informations de prédiction.
- **IaaS du Cloud** : présente un service de calcul qui permet, en spécifiant les ressources associées, l'apprentissage rapide des modèles de reconnaissance en accédant aux bases de données existants dans le service de stockage du Cloud. Les modèles entraînés seront ensuite intégrés dans le module intelligent.
- **Module intelligent** : un ensemble de modèles intelligents générés par des méthodes d'apprentissage pour la détection et la classification des panneaux routiers qui peuvent être intégrés dans l'application mobile.

- **Application mobile** : elle consomme le modèle de reconnaissance entraîné à partir du module intelligent pour détecter et classifier les panneaux en temps réel sur une vidéo en streaming afin d'assister le conducteur.

1.2 Plateforme d'évaluation

La plateforme d'évaluation sera implémentée sous forme d'une application web qui sera conçue selon le patron d'architecture Model View Template (MVT). Ce patron modélise généralement les applications web [5], tel est le cas de ce module, et comporte trois composants principaux qui sont Model View et Template comme le présente la figure 3.2.




FIGURE 3.2 – Le patron d'architecture MVT

- **Model** : agit comme une interface pour les bases de données et forme la structure logique derrière l'application web.
- **View** : exécute la logique métier et interagit avec le modèle. Il accepte la requête HTTP issues de l'utilisateur, puis met à jour le Template avec les données récupérées sous forme de réponses HTTP.
- **Template** : agit comme une couche de présentation et est essentiellement codé en HTML.

La figure 3.3 présente l'application du patron MVT sur notre plateforme de test en détaillant sous forme de classes chaque partie de ce patron.




FIGURE 3.3 – Application du patron MVT sur la plateforme d'évaluation

Le Model se compose de :

- La classe utilisateur réfère au testeur et à l'administrateur.
- La classe notification retourne des informations spécifiques à chaque utilisateur.
- la classe vidéo représente la vidéo sur laquelle s'effectue les tests.
- la classe historique contient des informations détaillées sur les tests effectués.

Le Template principale dans notre cas est Home, elle permet l'accès aux plusieurs autres Template qui sont : profil, test (unitaire et total), historique et vidéos.

Le View est l'intermédiaire entre le Model et le Template, il permet l'exécution des différentes fonctionnalités.

1.3 Module intelligent

Notre module intelligent de reconnaissance est conçu selon le patron Blackboard. Ce patron permet de modéliser les systèmes utilisés dans le domaine de l'intelligence artificielle comme les systèmes de reconnaissance de données [6]. Le patron Blackboard est constitué de trois composants :

- **Blackboard** : c'est un espace volatil (RAM : espace de travail qui représente les entrée-sorties du système) ou non volatil (Bases de données) de stockage de données qui fournit une interface aux Knowledge-sources pour lire et écrire les données comme pour les systèmes de reconnaissance : les bases de données (apprentissage et test)
- **Knowledge-source** : "condition-action rules" : si la "condition" est vérifiée au niveau du Blackboard alors l'"action" doit être réalisée pour modifier le contenu du Blackboard. A titre d'exemple, dans le cadre des systèmes de reconnaissance utilisant une méthode d'apprentissage, si l'entrée est déjà vu par le système alors sa classe est reconnue.
- **Control** : organise l'exécution des Knowledge-source et gère périodiquement l'accès de lecture ou de modification au Blackboard. Pour le même exemple des systèmes de reconnaissance : le programme principal qui lance l'apprentissage et la reconnaissance.

La figure qui suit présente le patron d'architecture Blackboard.




FIGURE 3.4 – Le patron d'architecture Blackboard

L'application de ce patron sur notre module intelligent est donnée par la figure 3.5




FIGURE 3.5 – Application du patron d’architecture Blackboard sur le module intelligent

- Le Blackboard est composé de l’ensemble de base de données d’apprentissage et de test.
- Le Knowledge Source contient les méthodes de reconnaissance.
- Le control englobe les pré-traitement effectués sur les bases de données et qui sont utiles pour améliorer les performances des méthodes de reconnaissance.

1.4 IaaS du Cloud

La figure 3.6 présente l’architecture microservices qui est composée d’un ensemble de services légers, mono-responsabilité et autonomes. fournie ces fonctionnalités à un programme client à l’aide d’une API.




FIGURE 3.6 – Le patron d’architecture micro-services

Le patron d’architecture micro-services modélise le module IaaS du Cloud faisant partie de notre solution. En effet, le service de stockage de données et le service de calcul accéléré sont des microservices exploités par notre plateforme d’évaluation et par notre module intelligent comme le montre la figure 3.1.

1.5 Application mobile

L’application mobile est conçue selon le patron MVC. Il s’agit d’un modèle de conception logicielle utilisé pour implémenter des interfaces utilisateur et qui met l’accent sur la séparation de la représentation des données des composants qui interagissent et traitent les données [5]. Selon la figure 3.7, le patron MVC contient 3 composants :

- **Model** : c’est le composant central de cette architecture et gère les données, la logique métier ainsi que d’autres contraintes de l’application.
- **View** : traite la façon dont les données seront affichées à l’utilisateur et fournit divers composants de représentation des données récupérées à partir du modèle.
- **Controller** : manipule le Model et récupère les requêtes des utilisateurs à partir de la vue et agit sur le modèle.




FIGURE 3.7 – Le patron d'architecture MVC

L'application du patron MVC sur notre module mobile est donné par la figure 3.8 :




FIGURE 3.8 – Application du patron d'architecture MVC sur l'application mobile

Le composant Controller se compose de deux principales activités : MainActivity qui lance le streaming et RecongnitionActivity qui fait appel au Model contenant le détecteur

et le classifieur qui traitent les données provenant du streaming et mettent à jour le View en notifiant l'activity main et l'activity recognition pour modifier l'affichage.

2 Vue dynamique de l'application

Le diagramme de séquences et d'activités sont des moyens graphiques pour représenter le comportement dynamique du logiciel. A ce niveau de conception, les diagrammes de séquences décrivent les interactions entre les objets qui composent le logiciel. L'enchaînement de ces échanges peut être également décrit dans un diagramme d'activités partitionnés en faisant apparaître les actions réalisées par chaque objet.

2.1 Diagramme de séquences «Détecter et classier les panneaux routiers»

La figure 3.9 décrit le processus de détection et de classification de panneaux routiers contenus dans une vidéo.




FIGURE 3.9 – Diagramme de séquences «Détecter et classier les panneaux routiers»

Le détecteur reçoit la vidéo, la partitionne en un ensemble de frames, et localise tous les panneaux routiers existant dans chaque frame. Après cet étape de détection, le détecteur envoie au classifieur les frames traités contenant des boîtes englobantes délimitant les zones contenant les panneaux routiers. Pour chaque zone détectée, le classifieur extrait un ensemble de descripteurs caractérisant l'objet à reconnaître et prédit son nom.

2.2 Diagramme de séquences «Réaliser un test total de comparaison»

La figure 3.10 détaille les interactions effectuées entre les objets composant le logiciel pour réaliser une évaluation des performances de plusieurs méthodes d'apprentissage sur une base de vidéos contenant des panneaux routiers à reconnaître.




FIGURE 3.10 – Diagramme de séquences «Réaliser un test total de comparaison»

Le testeur lance l'interface de test total de comparaison et charge la base de vidéos contenant les panneaux. Ensuite, il choisit les méthodes d'apprentissage qui vont être évaluées. Puis, le processus de reconnaissance est lancé comme expliqué dans le fragment "détecter et classifier les panneaux". Enfin, les performances de ces méthodes sont affichées selon des métriques d'évaluation des prédictions retournées.

2.3 Diagramme de séquences «Réaliser un test unitaire ciblé et analyser les résultats de prédiction»

La figure 3.11 détaille les différentes interactions effectuées entre les objets composant le logiciel pour réaliser une évaluation des prédictions d'une seule méthode de reconnaissance (détecteur + classifieur) sur une seule vidéo contenant des panneaux routiers à reconnaître.




FIGURE 3.11 – Diagramme de séquences «Réaliser un test unitaire ciblé et analyser les résultats de prédiction»

Lorsque le testeur lance l'interface du test unitaire ciblé, il sélectionne la méthode d'apprentissage à tester et la vidéo à traiter. Ensuite, il lance le processus de reconnaissance, en utilisant le fragment " détecter et classifier les panneaux routiers", et attend les résultats de prédiction. Le système affiche ensuite sur la vidéo les boîtes englobantes délimitant les panneaux routiers dans la scène en affichant les noms correspondants au-dessus.

Comme suite de cette fonctionnalité de prédiction, le testeur analyse les résultats visuels de prédiction, rectifie les prédictions erronées et enregistre les nouvelles annotations. Ces nouvelles données permettent d'augmenter la base de vidéos d'apprentissage et permettent par la suite de relancer un apprentissage de la méthode de reconnaissance afin

d'augmenter ses performances.

2.4 Diagramme d'activités partitionnés «Détection des panneaux routiers avec l'application mobile»

La figure 3.12 présente le diagramme d'activités partitionnés décrivant le processus de détection et de classification des panneaux routiers lancé par le conducteur à travers l'application mobile. Cette application envoie un signal sonore en cas de présence de panneaux routiers et affiche en temps réel sur les frames du streaming des boîtes englobantes délimitant les panneaux routiers détectés avec le nom correspondant dessus.




FIGURE 3.12 – Diagramme d'activités partitionnés «Détection des panneaux routiers avec l'application mobile»

Conclusion

Dans ce chapitre nous avons présenté l'une des plus importantes phases du processus de développement d'un projet qui est la conception à l'aide des diagrammes qui décrivent la composition interne du méta-système proposé et l'enchaînement de la communication entre les différents objets qui le composent. Nous présentons dans le prochain chapitre les détails du module intelligent en décrivant les étapes du processus de reconnaissance et le protocole expérimental appliqué.

4

Processus de reconnaissance et protocole expérimental

Introduction

Dans ce chapitre, nous détaillons davantage notre module intelligent. La fonctionnalité principale de ce module est la reconnaissance des panneaux routiers. Nous définissons ainsi le processus de reconnaissance et ses principales étapes : la détection et la classification. Nous décrivons les méthodes d'apprentissage appliquées, les métriques d'évaluation utilisées et les données exploitées afin de générer des modèles de reconnaissance performants.

1 Approches de reconnaissance

La reconnaissance des objets est une application de la vision par ordinateur. La vision par ordinateur est un sous-domaine de Intelligence Artificielle (IA) qui a pour mission de faire doter les machines par une capacité de perception qui simule la perception humaine.

Notre solution consiste à développer un système intelligent capable de reconnaître les panneaux routiers. Il s'agit d'un processus qui inclue deux phases importantes qui sont la détection des panneaux et leurs classification. Il existe deux approches pour réaliser ceci :

- **Approche end-to-end** : cette approche consiste à réaliser un modèle complet qui prend en charge tout le processus de reconnaissance. L'image est, alors, observée par une chaîne de couches de réseaux de neurones une seule fois, et le réseau de réseaux neuronaux retourne directement tous les objets présents dans l'image avec leurs classes respectives [7] (la vitesse d'inférence est généralement optimisée).

- **Approche séquentielle** : cette approche consiste à réaliser deux modèles pour chaque phase du processus à savoir un modèle de détection suivie d'un modèle de classification. L'image est, dans un premier temps, envoyée à un modèle chargé d'identifier quelles sont les zones d'intérêt de l'image qui contiennent des objets. Par la suite, chaque zone est envoyée au second modèle qui détermine la classe de l'objet en question. Cette décomposition augmente la précision de localisation et de classification d'une part et diminue la vitesse d'inférence d'autre part étant donné que la complexité augmente. [7].

Dans notre cas nous avons privilégié l'alternative qui met l'accent sur la précision de la reconnaissance imposée par les critères de qualité requis de notre solution avec une optimisation du temps d'inférence. La figure 4.1 schématise l'approche séquentielle de reconnaissance que nous avons adoptée pour notre module intelligent.




FIGURE 4.1 – Processus de reconnaissance selon l'approche séquentielle

La phase de détection d'objets dans notre contexte consiste à extraire les caractéristiques des objets contenus dans des images ou des frames de vidéos afin de localiser l'objet recherché dans cet image appelée également une opération de segmentation spatiale. En effet, le modèle de détection reçoit une séquence de frames où un frame peut contenir plusieurs panneaux. Dans chaque frame, les régions pouvant contenir les pan-

neaux sont recherchées en extrayant un ensemble de caractéristiques génériques à l'aide de descripteurs de couleur ou de forme pour décider sur l'existence du panneau routier indépendamment de son nom. Les régions d'intérêt localisées sont ensuite consommées par un classifieur qui va également extraire des caractéristiques de forme et couleur plus spécifiques pour décider sur la classe du panneau d'où la prédiction de son nom.

Pour réaliser ce processus de reconnaissance, il faut appliquer une méthode d'apprentissage en utilisant par exemple les méthodes les plus performantes de nos jours : les méthodes du Deep Learning.

2 Méthodes d'apprentissage profond (DL) appliquées

2.1 Principe

Le Deep Learning fait partie de l'IA, dérivée du Machine Learning (apprentissage automatique), où les machines sont capables d'apprendre par elles-mêmes, contrairement à la programmation qui se contente de s'exécuter selon des règles prédéterminées.

Le Deep Learning s'appuie sur un réseau de neurones convolutif (Convolutional neural network (CNN)) s'inspirant du cerveau humain (figure 4.2) [8]. Ce réseau permet de reconnaître et de classifier des caractéristiques particulières à partir d'images et est largement utilisés pour analyser des images. Ce genre de réseau neuronal a gagné en popularité ces dernières années en raison de ses performances remarquables dans une multitude de tâches de vision par ordinateur telles que la reconnaissance d'image (et vidéo), classification d'image, détection d'objets, etc.




FIGURE 4.2 – Architecture CNN

La structure de cet algorithme est la suivante :

- **Backbone CSPDarknet53** : est responsable de l'extraction des caractéristiques de l'image d'entrée de taille 416×416 . Le réseau contient 53 couches de convolution [11].
- **Le Neck** : il combine le Pooling Pyramidal Spatial (SPP) et le Path Aggregation Network (PANet), où la structure SPP est utilisée pour sélectionner les caractéristiques les plus importantes tandis que la structure PANet vise à améliorer le processus de segmentation tout en préservant les informations spatiales [12].
- **Head** : c'est la couche dense, elle récupère les régions proposées par le réseau (RPN) elle effectue une prédiction finale du type de l'objet détecté, et est composée d'un vecteur contenant les coordonnées de la boîte englobante prédite (centre, hauteur, largeur), le score de confiance de la prédiction et l'étiquette.

Les régions proposés par le réseau sont nombreuses, pour cette raison que YOLO applique le Non-maximum Suppression (NMS) qui sert à préserver que les régions contenant réellement les objets d'intérêts parmi ces nombreuses régions qui se chevauchent.

❖ Yolov4 Tiny

C'est une version simplifiée de YOLOv4 [13]. La figure 4.4 illustre la structure du réseau de YOLOv4-Tiny.




FIGURE 4.4 – Architecture YOLOV4 Tiny

Il se compose de :

- **Backbone CSPDarknet53-tiny** : ayant comme premier module le CBL qui est composé de la couche de convolution (Conv), la normalisation par lots (BN) et la fonction d'activation Leaky-Relu (Leaky).

- **Le Neck** : le SPP et le PANet de YOLO-v4 sont également remplacés par le Feature Pyramid Networks ([FPN](#)) qui intègre les caractéristiques de différents niveaux pour assurer l'intégrité des informations et réduire le temps de détection mais une précision inférieure à celle de YOLO-v4.
- **Head** : il est alimenté par les caractéristiques obtenue par le FPN pour générer la prédiction finale.

Le tableau 4.1 résume les structures de différents méthodes de détection testées.

TABLEAU 4.1 – Structuration des méthodes de détection

Nom du modèle	input size	Backbone	Couches supplé- mentaire
YOLO v4	416*416	CSPDarknet53	Neck, Head
YOLO v4 Tiny	416*416	CSPDarknet53 tiny	Neck Head
SSD	300*300	VGG-16/ResNet..	4 groupements de conv + 2 FC
Faster R-CNN	600*600	VGG-16/ResNet	RPN + ROI pooling layer + 2 FC

2.3 Méthodes d'apprentissage profond pour la classification

Au cours de cette phase, nous avons eu recours à plusieurs méthodes de classification comme MobileNet et ResNet. Bien que les performances de ces méthodes sont élevées sur les bases de test, ces performances s'atténuent en cas d'utilisation réelle en temps réel sur le streaming. Cette dégradation de performances peut être dû à la complexité de l'architecture de ces méthodes et un sur-apprentissage des données. En effet, le tableau 4.2 compare les caractéristiques de l'architecture CNN basique et les méthodes MobileNet et ResNet. Cette comparaison prouve la différence de complexité entre ces méthodes. Ainsi, nous choisissons d'adopter la version classique des réseaux CNN en simplifiant sa construction en couches et en introduisant un composant dotant la méthode par l'invariance spatiale appelé Spatial Transformer Network ([STN](#)).

TABLEAU 4.2 – Structuration des méthodes de classification

Nom du modèle	Backbone	Convolution	Pooling	FC
MobileNet	224*224	22 couches	1 :Average	1 couche
ResNet	224*224	11 couches	2 :Average/max	1 couche
CNN	32*32	2 couches	2 :Max	2 couches

- Architecture du modèle de classification :
la figure 4.5 illustre la structure du modèle de classification.




FIGURE 4.5 – Architecture du modèle de classification

En effet, les réseaux de neurones convolutifs sont limités par le manque de capacité à être spatialement invariants par rapport aux données d'entrée. Nous introduisons le module STN, qui permet explicitement la manipulation spatiale des données au sein du réseau. Donc il peut être inséré dans des architectures convolutives existantes, donnant aux réseaux de neurones la possibilité de transformer spatialement les caractéristiques extraites à partir de l'image d'entrée. Autrement dit, ce composant permettra d'aboutir à des modèles invariants à l'échelle, à la rotation..etc.

L'union des deux réseaux STN et CNN fonctionne comme suit : Les données entrante passent tout d'abord par le STN, en particulier par la section de localisation qui se compose de 2 couche de convolution, 2 Max Pooling et 2 Fully connected (ou Dense Layer comme dans la figure 4.5). La sortie est dirigée vers le Grid Generator qui se charge de générer une grille de coordonnées qui correspondent à un ensemble de points caractérisant l'objet transformé, puis vers le Sampler qui prend en entrée les caractéristiques d'entrée et la grille générée pour les fusionner. A ce point l'image est projetée et prête à être classifiée par le réseau CNN qui se compose de 2 couches de convolution, 2 Max Pooling en appliquant la fonction d'activation RELU qui permet

de filtrer les valeurs négative et à la fin 2 Dense Layer en retournant les probabilités de l'appartenance à chaque classe sous forme d'un vecteur.

3 Métriques d'évaluation des algorithmes

Pour évaluer les performances d'un système informatique utilisant un algorithme de Machine Learning en particulier de Deep Learning, un ensemble de critères doivent être vérifiés et validés. Ce pendant, il existe plusieurs métriques d'évaluations à savoir l'exactitude, la précision, le rappel, F1-score.. Nous définissons dans la suite les métriques d'évaluation appliquées dans notre cas afin de choisir l'algorithme d'apprentissage qui permet d'optimiser les performances de notre système de reconnaissance de panneaux routiers.

- L'exactitude (Accuracy) : L'exactitude est le quotient de la division du nombre des valeurs correctement prédites par l'ensemble des prédictions effectuées. Il s'agit de la mesure la plus courante utilisée pour évaluer les problèmes de classification.

$$\textbf{Exactitude} = \frac{\text{Nombre de predictions correctes}}{\text{Nombre total des prédictions}} \quad (4.1)$$

- Précision : La précision indique la proportion des prédictions positives correctes positives par rapport au nombre de prédictions positives correctes et erronées.

$$\textbf{Précision} = \frac{TP}{TP + FP} \quad (4.2)$$

Dans le cadre d'une classification multiclassées. la précision est calculée pour chaque classe i , puis une moyenne totale est calculée pour toutes les classes de nombre n comme suit :

$$\textbf{Précision}_t = \frac{\sum_{i=1}^n \text{precision}_i}{n} \quad (4.3)$$

- Rappel :Le rappel présente le pourcentage des prédictions prédites correctement par rapport au nombre de prédictions qui sont réellement positives.

$$\textbf{Rappel} = \frac{TP}{TP + FN} \quad (4.4)$$

4 Préparation des données

Les différentes catégories des panneaux routiers traitées par notre solution sont définies dans l'annexe 4.

4.1 Données pour la détection

4.1.1 Bases de données

Cette partie décrit les différentes bases de données publiques contenant des images du monde réel comportant de divers panneaux routiers dans de différentes situations.

- **GTSDb** : German Traffic Sign Detection Benchmark ([GTSDb](#)) [14] est une dataset dédiée aux chercheurs qui s'intéressent aux domaines de la vision par ordinateur, de la reconnaissance des formes et de l'aide à la conduite basée sur l'image.
- **Lisa tiny** : ce jeu de données provient de la base de données LISA. Cette base de données a été développée dans le contexte de "l'Evaluation Method of Deep Learning-Based Embedded Systems for Traffic Sign Detection" [15] ce qui s'aligne avec notre projet.
- **Custom** : une base de données contenant des images de situation réelle sur la route récupérée à partir de la plateforme GitHub [16].

Le tableau 4.3 décrit ces différentes base de données.

TABLEAU 4.3 – Les bases de données exploitées pour la détection de panneaux routiers

Dataset	Nombre de classe	Nombre d'images	Résolution	Format
GTSDb	4	900	1360*800	ppm
Lisa-Tiny	9	900	640x480 1024x522	- png
Custom	1	1656	1024x640	png

La figure 4.6 présente un extrait d'images de la dataset GTSDb, Lisa-Tiny et Custom.



FIGURE 4.6 – Extrait des datasets GTSDB, Lisa-Tiny et Custom

4.1.2 Prétraitement sur les données

La qualité et la quantité d'images sont deux critères primordiaux afin d'avoir une bonne précision de localisation d'objet, en particulier les panneaux routiers. De ce fait, nous avons opté pour la fusion des différents datasets en une seule base de données et l'unification du format des images.

- Uniformisation des images des bases de données :

Cette étape vise à avoir le même type des datasets citées préalablement vu qu'ils ne présentent pas le même nombre de classe. Les transformations ci-dessous ont été effectuées afin de réaliser cette tâche :

- **Transformation en format YOLO** : Le format YOLO est une sorte d'annotation associée à l'image sous la forme d'un fichier texte qui contient les informations de tous les objets cibles. Ces informations sont essentiellement la classe de l'objet, les coordonnées du point central du box de l'objet détecté ainsi que sa hauteur et sa largeur. Pour ce faire, nous avons appliqué un "Script" qui permet de générer, à partir d'un fichier d'annotation (qui présente pour chaque image les coordonnées des panneaux), les fichiers texte nécessaires pour chaque image. Cette transformation a été appliquée sur les deux datasets GTSDB et Lisa Tiny.

- **Unification des classes** : puisque notre détecteur se charge d'extraire les panneaux routiers présents dans un frame indépendamment de leurs noms, nous unifions les classes des trois bases de données en une seule classe qui est "panneau".

- Intégration des bases de données

A ce niveau, toutes les images des différents datasets ont le même format avec le même nombre de classes, nous sommes alors capable de réaliser le fusionnement des trois datasets pour aboutir à une dataset générique ayant plus que 3450 images. Nous avons ensuite fractionné cette dataset en 2 parties : 70% de la dataset sont des données d'apprentissage et le reste pour le test.

4.2 Données pour la classification

4.2.1 Bases de données

GTSRB : German Traffic Sign Recognition Benchmark ([GTSRB](#)) est fourni par le groupe "Institut für Neuroinformatik". Ce dataset a été publié pour un concours organisé en 2011. L'ensemble de données de GTSRB est extrait d'une vidéo de 10 heures qui a été enregistrée sur différents types de routes en Allemagne.

Exploration des données :

Le tableau [4.4](#) présente les caractéristiques de cette base de données

TABLEAU 4.4 – Caractéristiques de la base de données de classification

Dataset	Nombre de classe	Nombre d'images	Résolution	Format
GTSRB	43	50.000 (dont 39.209 images d'apprentissage)	de 15*15 à 250*250	ppm

La figure [4.7](#) présente des images extraites de la bases données GTSRB représentant les 43 classes de ce dataset GTSRB.




FIGURE 4.7 – Portion de la dataset GTSRB

La figure 4.8 montre le nombre d’images d’apprentissage de la base de données GTSRB pour chaque classe de ses 43 classes.




FIGURE 4.8 – Distribution du Dataset d’apprentissage GTSRB sur les 43 classes

4.2.2 Prétraitement sur les données

La figure 4.8 montre que le nombre d'images d'apprentissage pour certaines classes de la base de données GTSRB est réduit. Ce déséquilibre de la base d'apprentissage mène à de mauvaises performances de reconnaissance. Nous dupliquons ainsi ces images en appliquant un ensemble de transformations géométriques comme suit :

- **Rotation** : un panneau peut être capturé à partir de différents angles de vue. Ainsi, les images générées par rotation pour le même panneau représente ces différentes vues de capture. Cependant, les classes ne doivent pas subir les mêmes types de rotation car ceci peut changer la classe du panneau (comme le cas du panneau de "Ahead" est différent de celui "Keep left"). Donc nous appliquons selon la nature des panneaux 4 types de rotation (voir figure 4.9) qui sont :
 - horizontally flippable (rotation horizontale)
 - vertically flippable (rotation verticale)
 - both flippable (rotation horizontale et verticale)
 - cross flippable (rotation diagonale)




FIGURE 4.9 – Appliquer le "Flipping" sur la dataset d'apprentissage GTSRB

- **Zoom** : Dans une scène réelle, un panneau peut être très proche, ainsi nous pouvons appliquer un agrandissement sur les images comme le montre la figure 4.10.



FIGURE 4.10 – Agrandissement des images de la dataset d’apprentissage GTSRB

- **Éclairage** : nous changeons l’éclairage des images afin de développer un classifieur robuste au changement de la luminosité.




FIGURE 4.11 – Changement d’éclairage des images de la dataset d’apprentissage GTSRB

- **Clahe gray** :

Pour produire un classifieur robuste aux variations de la couleur (dégradation de la couleur, background chargé...), nous appliquons sur la dataset d’apprentissage le Clahe gray qui sert à modifier la couleur des images en noir et blanc. La figure 4.12 présente des images extraites de la base de données d’apprentissage GTSRB qui ont subi la transformation de la couleur en gray.




FIGURE 4.12 – Application de Clahe gray sur la dataset d’apprentissage GTSRB

Lors de l’apprentissage, le modèle doit apprendre à reconnaître les panneaux indépendamment de leurs couleurs mais également, dans les phases de test, nous devons

appliquer le Clahe gray sur les données avant de les alimenter au modèle de classification.

L'application de ces transformations nous a aidé à obtenir une base de données d'apprentissage équilibrée, comme le montre la figure 4.13.




FIGURE 4.13 – Distribution équilibrée de la base de données d'apprentissage GTSRB sur ses 43 classes

Conclusion

Tout au long de ce chapitre, nous avons détaillé la phase de réalisation des modèles en passant par les étapes de la méthodologie Crisp-DM. Pour chaque modèle, nous avons commencé par la préparation données, puis la modélisation pour arriver à l'évaluation. Dans le chapitre qui suit, nous intégrons ces modèles dans une plateforme d'évaluation et une application mobile.

5

Réalisation

Introduction

Ce chapitre constitue le dernier volet de ce rapport, il traite la phase qui a pour objectif l'implémentation de notre solution. Nous commençons, tout d'abord, par la description de l'environnement travail utilisé. Ensuite, nous décrivons le travail réalisé à travers les interfaces du méta-système et les résultats d'évaluation du module intelligent.

1 Environnement de travail

Un environnement de travail désigne l'ensemble des outils et des éléments matériels et techniques exploités pour l'implémentation et la réalisation de la solution proposée.

1.1 Environnement logiciel

La figure 5.1 englobe les logos de différents outils et framework utilisés pour la réalisation du travail.




FIGURE 5.1 – Outils et framework utilisés

- **Visual Studio :**

C'est un éditeur de code source développé par Microsoft permettant de générer plusieurs types d'applications. Il dispose d'un riche écosystème d'extensions pour plusieurs langages tels que C, Java, Python, PHP. Les fonctionnalités incluent la prise en charge du débogage et l'intégration du Git.

- **Android Studio :**

C'est l'IDE officiel pour le développement d'application Android, créé par Google et basé sur IntelliJ IDEA.

- **GitMind :**

C'est un logiciel de modélisation en ligne et gratuit qui permet de concevoir un logiciel. Nous utilisons cet outil pour réaliser les diagrammes de classes, de séquences, d'activités et de paquetage.

- **GitHub**

Nous avons eu recours à GitHub pour réaliser le contrôle de versions distribuées. Il s'agit d'un logiciel open source qui a été conçu pour traiter tout type de projet en gérant des branches de code ce qui facilite le travail en équipe et l'intégration du travail.

- **Framework Django :** Django est un framework gratuit et open source écrit en Python et s'inspire du modèle MVT. Il s'agit d'un ensemble de composants qui aident à

développer des sites web. Nous avons utilisé Django pour développer notre plateforme d'évaluation.

- **Flask** : c'est un framework Python léger qui donne une flexibilité de création des APIs. Nous avons utilisé ce framework pour créer les APIs des modèles pour les consommer dans la plateforme d'évaluation
- **Tensorflow Lite** : est un framework d'apprentissage en profondeur open source. Il permet de convertir un modèle pré-entraîné dans TensorFlow en un format plus petit destiné aux applications mobile. En effet, les modèles TensorFlow Lite peuvent effectuer presque toutes les tâches qu'un modèle TensorFlow standard peut effectuer. Dans notre cas, les modèles que nous avons développés sont basés sur le framework Pytorch. Nous avons commencé, tout d'abord, par les convertir en TensorFlow par la suite, vers TensorFlow Lite pour pouvoir les intégrer dans notre application mobile. Selon les expérimentations, le modèle YOLO-v4 Tiny est considéré comme un modèle rapide. De plus sa précision est acceptable pour cela, nous décidons de l'employer dans l'application mobile.

1.2 Environnement Cloud (IaaS)

Nous décrivons dans cette partie les services Cloud exploités pour réaliser notre solution.

- **Google Colab** :

C'est l'approche la plus pratique. Il s'agit d'un notebook pour exécuter le code. Cependant, étant donné que ses ressources sont gratuites, celui-ci impose des limites d'utilisation du GPU (12 heures). Nous avons utilisé cet outil pour tester plusieurs modèles avant de sélectionner lesquels à adopter.

- **Microsoft Azure** :

Microsoft Azure est une plateforme Cloud qui offre des ressources à la demande et simplifie l'utilisation des technologies et des services comme le stockage des données.

- **Azure ML** :

Azure Machine permet d'accélérer et de gérer le cycle de vie des projets Machine Learning ([ML](#)) spécialement pour faire apprendre et déployer les modèles [17].

— **MLflow :**

C'est un framework populaire qui permet la construction de modèles d'apprentissage, l'ajustement, la gestion des versions et le déploiement [18]. MLflow offre plusieurs fonctionnalités parmi lesquels nous avons utilisé le composant MLflow Tracking qui permet d'enregistrer les paramètres, les versions de code, les valeurs des métriques ainsi que les fichiers de sortie de l'exécution du code d'apprentissage automatique.

— **Azure Blob Storage :**

C'est une solution de stockage d'objets offerte par Microsoft Azure permettant de stocker des quantités massives de données non structurées dont les images et les vidéos qui sont notre cibles [19].




FIGURE 5.2 – Technologies Cloud utilisées

1.3 Outils d'implémentation

Nous présentons, dans le tableau 5.1 les caractéristiques de notre machine utilisé lors de la réalisation de notre solution.

TABLEAU 5.1 – Outils d'implémentation

Composants	Description
Microprocesseur	Intel Core i5 7th generation
Ram	8 Go
Disque dur	256 Go
Système d'exploitation	Windows 10, 64bits

1.4 Diagramme de déploiement

La figure 5.3 met en position l'infrastructure physique du système et la manière dont ses composants sont répartis ainsi les relations entre eux.




FIGURE 5.3 – Diagramme de déploiement

La plateforme web se compose de trois composants principale qui sont : Train (ou Retrain), le test et le Dashsboard. Pour lancer un apprentissage (ou un réapprentissage), le fichier MLscript se lance en utilisant ML flow qui assure la gestion des versions et qui est relié à Azure ML qui lance les Jobs en générant des fichier de Log contenant les artificats. Lors d'un test, ce composant utilise les modèles de détection et de classification du module intelligent en stockant les résultats dans Azure Blob Storage qui forme notre service de stockage, il est possible également de consulter les informations à partir de ce service à l'aide du Dashboard. Une fois un modèle est validé, il sera déployé dans l'application mobile générant un fichier d'installation signRecongntion.apk.

2 Plateforme d'évaluation

Cette section est consacrée à la description de la plateforme web d'évaluation.

2.1 Les interfaces graphiques de la plateforme d'évaluation

- Interface «Authentification»

Avant d'accéder à la plateforme, il est indispensable de s'authentifier à l'aide de l'interface présente dans la figure 5.4.




FIGURE 5.4 – Interface «Authentification»

2.1.1 Interfaces graphiques destinées à l'administrateur

- Interface «Ajouter un testeur»

La création des comptes des testeurs n'est effectuée que par l'administrateur. Après la création, les coordonnées du compte seront envoyées au testeur en question par mail, voir la figure 5.5.




FIGURE 5.5 – Interface «Ajouter un testeur»

- Interface «Liste des testeurs»

La figure 5.6 montre que l'administrateur peut consulter et supprimer les comptes des testeur.




FIGURE 5.6 – Interface «Liste des testeurs»

- Interface «Dashboard»

L'administrateur doit surveiller différents types d'informations à travers le dashboard. Nous distinguons 3 types d'informations : informations générales, informations par modèle d'apprentissage et informations sur la dataset, ce qui est présenté par les figures 5.7, 5.8 et 5.9.




FIGURE 5.7 – Interface «Dashboard d'informations générales»




FIGURE 5.8 – Interface «Dashboard d'informations par modèle»




FIGURE 5.9 – Interface «Dashboard d'informations sur la Dataset»

2.1.2 Interfaces graphiques destinées au testeur

- Interface «Test total de comparaison»

La figure 5.10 présente le test total de comparaison. Le testeur lance le test après avoir sélectionné l'ensemble des modèles de détection à évaluer qui seront associés à la meilleure configuration du modèle de classification CNN générée automatiquement par le service cloud.




FIGURE 5.10 – Interface «Test total de comparaison»

- Interface «Résultat de test total de comparaison»

Les résultats de test total de comparaison sont présentés par la figure 5.11. Ainsi, le testeur compare la performance des modèles choisis.



FIGURE 5.11 – Interface «Résultat de test total de comparaison»

- Interface «Test unitaire ciblé»

Cette fonctionnalité permet de réaliser un test avancé sur un modèle de reconnaissance spécifique et une vidéo bien déterminée comme le montre la figure 5.12.




FIGURE 5.12 – Interface «Test unitaire ciblé»

- Interface «Rectification des prédictions»

La figure 5.13 montre que le testeur peut cocher les prédictions qui sont correctes et corriger celles qui sont fausses.




FIGURE 5.13 – Interface «Rectification des prédictions»

- Interface «Résultat de test unitaire ciblé»

La figure 5.14 illustre le résultat de test unitaire ciblé obtenu qui englobe de divers informations tels que le FPS et le temps de traitement.




FIGURE 5.14 – Interface «Résultat de test unitaire ciblé»

- Interface «Historiques des tests»

Après la réalisation des tests, le testeur peut consulter l'historique d'évaluation présenté par la figure 5.15.




FIGURE 5.15 – Interface «Historiques des tests»

- Interface «Authentification Azure»

Pour pouvoir bénéficier des fonctionnalités de l'IaaS du Cloud tel que le service de calcul pour l'apprentissage des modèles de reconnaissances, le testeur doit saisir les coordonnées de son compte Azure comme le montre la figure 5.16.

FIGURE 5.16 – Interface «Authentification Azure»

- Interface «Lancer un apprentissage»

L'interface présentée par la figure 5.17 permet au testeur de lancer l'apprentissage d'un modèle de classification en configurant ses paramètres comme le nombre d'epochs et le learning rate.

FIGURE 5.17 – Interface «Lancer un apprentissage»

- Interface «Lancer un ré-apprentissage»

La figure 5.18 présente l'interface dédiée au lancement du ré-apprentissage de modèle de classification. Chaque version du modèle possède un "Run ID" qui sera sélectionné par le testeur pour lancer son ré-apprentissage.

RUN_ID	EXPERIMENT_ID	STATUS	ARTIFACT_URI	START_TIME	END_TIME	METRICS.VALIDATION_LOSS	METRICS.TF
☐ Traffic-Signs-Classification-MLflow_1653166245_02a0f90c	a9fc0e32-efe7-435c-8345-39506b2ba605	FINISHED		May 21, 2022, 8:50 p.m.	May 21, 2022, 8:53 p.m.	0.5091622449102856	0.449185643
☒ Traffic-Signs-Classification-MLflow_1653165849_b658cbcd	a9fc0e32-efe7-435c-8345-39506b2ba605	FINISHED		May 21, 2022, 8:44 p.m.	May 21, 2022, 8:45 p.m.	38.98393972314675	4.036412702
☐ Traffic-Signs-Classification-MLflow_1653164979_73747efe	a9fc0e32-efe7-435c-8345-39506b2ba605	FINISHED		May 21, 2022, 8:30 p.m.	May 21, 2022, 8:30 p.m.	26.955159321826063	4.131310539
☐ Traffic-Signs-Classification-MLflow_1653143641_dc1d6e2a	a9fc0e32-efe7-435c-8345-39506b2ba605	FINISHED		May 21, 2022, 2:34 p.m.	May 21, 2022, 2:36 p.m.	0.5136037357810403	0.419226959

Lancer le réapprentissage

FIGURE 5.18 – Interface «Lancer un réapprentissage»

- Interface «Suivie du status d'apprentissage (ou de ré-apprentissage)»

Le testeur peut suivre l'état d'apprentissage ou de ré-apprentissage des modèles qui passe de "Preparing" à "Succeeded" si l'apprentissage (ou le ré-apprentissage) est achevé ou de "Preparing" à "Failed" si un problème est survenu comme le montre la figure 5.19.

Vous pouvez choisir entre :

STATUS : Preparing

RUN : Run(Experiment: Traffic-Signs-Classification-MLflow, Id: Traffic-Signs-Classification-MLflow_1653168031_679aec12, Type: azureml.scriptrun, Status: Preparing)

FIGURE 5.19 – Interface «Suivie du status d'apprentissage (ou de ré-apprentissage)»

- Interface «Lancement du job dans Azure»

Les jobs présentés par la figure 5.20 sont capturés dans le portail Azure et correspondent aux courbes "Validation Loss" résultantes de l'apprentissages des modèles.




FIGURE 5.20 – Interface «Lancement du job dans Azure»

- Interface «Caractéristiques du Compute»

Afin de pouvoir lancer l'apprentissage ou le reapprentissage, nous avons eu recours à une machine performante présentée par la figure 5.21.




FIGURE 5.21 – Interface «Caractéristiques du Compute»

- Interface «Historique des vidéos traitées dans la plateforme»

Les vidéos sur lesquelles se sont effectués les tests, sont sauvegardées dans Azure Blob Storage. Le testeur peut les consulter comme le montre les figures 5.22 et 5.23.




FIGURE 5.22 – Interface «Historique des vidéos traitées dans la plateforme»




FIGURE 5.23 – Interface «Stockage des vidéos dans Azure Blob Storage»

2.2 Expérimentations

2.2.1 Performances de détection

- Paramétrage

Le tableau 5.2 présente la configuration d'un ensemble de paramètres du modèle d'apprentissage YOLO pour l'expérimentation réalisée de détection de panneaux routiers.

TABLEAU 5.2 – Paramètres d'apprentissage des modèles de détection

Batch Size	64
Learning Rate	0.00216
Subdivision	64
Nombre itérations	2000
Nombre de classe	1

- Évaluation des résultats

Une fois l'apprentissage est lancé, nous pouvons suivre la variation des métriques générés comme le mean average Precision (**maP**) et la fonction Loss . Les figures 5.24 et 5.25 sont respectivement de YOLO-v4 et YOLO-v4 tiny.




FIGURE 5.24 – Les courbe maP et Loss de YOLO-v4 sur les données d'apprentissage




FIGURE 5.25 – Les courbe maP et Loss de YOLO-v4 Tiny sur les données d'apprentissage

La courbe Loss du modèle YOLO-v4 montre des impulsions ce qui explique sa lourdeur

donnant une courbe maP qui atteint 90%. Contrairement a YOLO-v4 Tiny dont la courbe Loss a rapidement convergé donc il a rapidement appris et la précision est environ 80% ce qui approuve que YOLO-V4 est plus précis que YOLO-V4 Tiny.

Nous avons testé ces modèles sur une base de test. Les résultats d'évaluation des détecteurs YOLO-V4 et YOLO-V4 Tiny sur la base de données de test obtenus sont résumés dans le tableau 5.3.

Notons bien que le Frame Per Second (FPS) donne le nombre d'image traité dans une seconde (pour expliciter la vitesse de traitement d'un vidéo), sa valeur dépend du processeur utilisé : étant donnée un processeur GPU puissant nous aurons une vitesse allant jusqu'à quatre ou cinq fois plus vite qu'un processeur CPU.

TABLEAU 5.3 – Évaluation de performance de YOLO-v4, YOLO-v4 Tiny, SSD et Faster R-CNN

Nom du modèle	FPS	Précision	Recall
YOLO V4	14	86%	87%
YOLO V4 Tiny	25	77%	75%
SSD	10	75%	73%
Faster R-CNN	7	78%	80%

Le tableau 5.3 prouve la compatibilité des méthodes YOLO V4 et YOLO V4 Tiny avec le mode temps réel (FPS élevé : capacité de traiter un nombre d'images élevé par seconde, et précision de reconnaissance élevée).

- **Résultats visuels de test avec YOLO-V4 et YOLO-V4 Tiny**

Les figures 5.26 et 5.27 montrent les résultats visuels de détection de panneaux routiers par, respectivement, les modèles YOLO-V4 et YOLO-V4 Tiny.



FIGURE 5.26 – Résultat de test avec YOLO-V4

Nous remarquons que YOLO-V4 a détecté tous les panneaux correctement.



FIGURE 5.27 – Résultat de test avec YOLO-V4 Tiny

Nous remarquons que YOLO-V4 Tiny a détecté tous les panneaux mais en détectant un autre qui n'est pas classé comme un panneau routier (il se trouve au centre de l'image en couleur verte).

2.2.2 Performances de classification

• Évaluation des résultats

La figure 5.28 représente l'évolution de la fonction Loss de notre classifieur après insertion du composant STN.




FIGURE 5.28 – Validation Loss avec STN

Nous remarquons que le classifieur a nettement évolué. De ce fait, les panneaux détectés sont majoritairement bien classés. Le tableau 5.4 décrit cette évolution et décrit également les résultats d'évaluation de classification des méthodes Deep MobileNet et ResNet.

TABLEAU 5.4 – Résultats de classification sur notre base de test avec le même environnement d’enregistrement entre la base de test et la base d’apprentissage

Modèle	Loss	Accuracy
CNN normal	0.037	80%
CNN amélioré (insertion du STN)	0.027	89%
MobileNet	0.03	87%
ResNet	0.027	91%

Les tableaux 5.4 et 5.5 décrivent les résultats de classification sur deux bases de test différentes. La première base de vidéos de test représente la base décrite dans la section 4.2 du chapitre 4, dont les vidéos sont enregistrées dans le même environnement que la base d’apprentissage. Le deuxième tableau décrit les résultats de classification sur une nouvelle base de test dont les vidéos sont enregistrées dans un environnement routier réel mais différent de l’environnement d’enregistrement de la base d’apprentissage. Nous remarquons que les performances des méthodes MobileNet et ResNet se dégradent clairement sur la nouvelle base de test contrairement à la méthode CNN classique, ce qui prouve la robustesse de l’architecture Deep simple de la méthode CNN dans ce genre de situation et le risque de sur-apprentissage pour les autres méthodes comme indiqué dans la section 2.3 du chapitre 4.

TABLEAU 5.5 – Résultats de classification sur une nouvelle base de test avec un environnement d’enregistrement différent entre la base d’apprentissage et la base de test

Modèle	Accuracy
CNN normal	75.62%
CNN amélioré (insertion du STN)	86.78%
MobileNet	51%
ResNet	69%

- **Résultats visuels de test du classifieur**

La figure 5.29 montre les résultats visuels de classification de panneaux routiers avant et après l’application du STN et Clahe Gray.




FIGURE 5.29 – Résultat de test du classifieur avec et sans STN et Clahe Gray

Nous remarquons que avant l'application du Clahe Gray, le classifieur a du mal à reconnaître les panneaux à fond jaune.

- **Robustesse de notre système de reconnaissance**

La combinaison des 2 modèles a donné un modèle performant qui répond parfaitement au défis fixés au début de ce rapport qui sont : La multi détection, les panneaux inclinés, la distance par rapport au panneau, l'éclairage ambiant ainsi que la précision, ce qui est illustré par la figure 5.30.




FIGURE 5.30 – Robustesse de notre système de reconnaissance

- **Autres travaux de la littérature**

Il existe d'autre travaux de reconnaissance de panneaux routiers dans la littérature [20] [21] [22]. Il s'avère difficile de comparer les performances de notre module de reconnaissance avec les performances des autres systèmes de reconnaissance des panneaux routiers puisque les conditions de test sont différentes. En effet, les autres systèmes ont été séparément testés sur les bases de données publiques mentionnées dans la section 4 du chapitre 4, contrairement à notre protocole expérimental où nous

avons fusionné trois bases dont l'une n'est pas publique. Aussi, certains travaux ont testé un sous ensemble de classes de panneaux contrairement à notre cas où nous avons testé les 43 classes des panneaux routiers. Certains travaux ont également classifié une seule catégorie de panneaux routiers (panneaux de vitesses ou panneaux radar) ou ont classifié seulement par catégorie de panneaux et non par classe (nom spécifique du panneau), contrairement à notre cas où nous avons testé toutes les catégories de panneaux routiers en donnant le nom exacte du panneau. Ainsi, et selon les résultats de reconnaissance présentés dans ce rapport, nous affirmons que le système de reconnaissance que nous proposons présente des performances élevées et nous le considérons innovant. Ce travail fera prochainement l'objet d'un article scientifique.

3 Application mobile

Dans cette section, nous décrivons les interfaces de notre application mobile dédiée au conducteur.

La figure 5.31 représente la première interface de notre application mobile. Le conducteur doit cliquer sur le bouton "Start" pour lancer la caméra.




FIGURE 5.31 – Interface principale de l'application mobile "MODY test"

Une fois la caméra est lancée, le module intelligent commence à fonctionner en streaming. Il détecte et classifie les panneaux en temps réel en déclenchant une alerte sonore

portant le nom du panneau.

L'application affiche également sur le streaming des boîtes englobantes étiquetées qui délimitent les panneaux routiers et indique visuellement leurs noms comme le montre la figure 5.32.




FIGURE 5.32 – Interfaces de l'application mobile de détection et classification de panneaux routiers

Conclusion

A travers ce chapitre, nous avons décrit les outils et les résultats de réalisation des différents modules que nous avons conçu pour aboutir à une solution utile qui répond au objectifs fixés.

Conclusion générale

Les panneaux routiers font partie de notre infrastructure routière, ils fournissent des informations aux usagers de la route. En effet, la négligence de ces panneaux lors de la conduite est un facteur primordiale des accidents sur la route. Dans ce contexte, un système de reconnaissance de panneaux routiers peut être proposé en vue d'aider le conducteur à veiller les panneaux lors de la conduite.

C'est dans ce cadre que s'inscrit notre stage de fin d'études en vue d'obtention du diplôme d'ingénieur en génie logiciel de l'Institut Supérieur des Sciences Appliquées et de Technologie de Sousse (ISSATSo). Ce stage a été réalisé au sein de l'entreprise tunisienne TALAN. Le sujet de ce stage est la conception et le développement d'un méta-système d'aide à la conduite pour détecter et reconnaître les panneaux routiers en temps réel.

Tout d'abord, nous avons mis en oeuvre une plateforme de test ayant la capacité d'évaluer, en se basant sur des métriques d'évaluation préalablement fixés, la performance de différents méthodes d'apprentissage profond pour la détection qui sont YOLO v4, YOLO v4 tiny, SSD et Faster R-CNN, ceci est à l'aide de deux formes de test : le premier est un test unitaire ciblé permettant une analyse détaillée sur un modèle bien déterminé avec l'augmentation de la base d'apprentissage lorsque les testeurs rectifient ses prédictions, le second est un test total de comparaison qui s'effectue sur une base de test. La plateforme permet aussi de créer plusieurs versions de méthodes de classification CNN ou de lancer le réapprentissage d'un modèle existant. Tout ce processus est effectué en vue de générer des modèles robustes, précis et capable de fonctionner en temps réel afin de les insérer dans l'application mobile que nous avons développé et dont le rôle est d'appuyer la diligence des conducteurs lors de la conduite en les alertant à l'aide d'une labélisation sur l'écran et un signal sonore portant le nom des panneaux.

L'une des majeures difficultés que nous avons rencontrées est la génération d'un modèle de reconnaissance précis et fonctionnant en temps réel. Cependant, nous avons réussi à surmonter plusieurs difficultés et à produire un modèle de reconnaissance robuste et

performant en temps réel grâce à une étude avancée des méthodes d'apprentissage avec une large expérimentation.

Ce travail m'a été très instructif non seulement sur le plan technique en me donnant la chance pour découvrir le domaine de la science des données mais aussi sur le plan professionnel, le développement de la solution a été une véritable occasion de vivre de près l'expérience du travail au sein d'une société, qui exige la ponctualité et l'intégration dans un groupe de travail ce qui m'a permis d'améliorer mes capacités de communication. Nous estimons avoir réussi et surtout satisfait les objectifs initialement fixés, ce qui a été prouvé par notre équipe au sein de la société. Néanmoins, notre solution est encore d'actualité et ne s'arrête pas à ce niveau, elle est susceptible d'avoir de nouvelles évolutions. Ainsi, nous proposons d'automatiser le déploiement de la meilleure version du modèle dans l'application mobile ce qui impose la mise en place d'une architecture Big data facilitant ce processus.

Références

- [1] Talan tunisie. <https://tn.talan.com>. Consulté le 01-02-2022.
- [2] My drive assist application. <https://www.androidlista.fr/item/android-apps/551904/mydriveassist/>. Consulté le 03-02-2022.
- [3] Radartbot application. https://play.google.com/store/apps/details?id=com.vialsoft.radarbot_free&hl=fr&gl=US. Consulté le 03-02-2022.
- [4] Crisp dm. <https://www.datascience-pm.com/10-ways-to-manage-a-data-science-project/>. Consulté le 05-02-2022.
- [5] Architecture mvc et mvt. <https://www.geeksforgeeks.org/difference-between-mvc-and-mvt-design-patterns/>. Consulté le 10-04-2022.
- [6] Selma BELGACEM. Cours : Les patrons d'architecture. 2020–2021.
- [7] Michaël Freylinger et Jean-François Verdin. Détection et reconnaissance de signaux routiers dans un flux vidéo. 2005–2006.
- [8] Architecture cnn. <https://zephyrnet.com/fr/introduction-de-base-au-r%C3%A9seau-de-neurones-convolutifs-dans-l%27apprentissage-en-profondeur/>. Consulté le 16-03-2022.
- [9] Gtsrb dataset. <https://pjreddie.com/>. Consulté le 12-03-2022.
- [10] Architecture yolo-v4. <https://www.mdpi.com/1424-8220/22/3/1082/htm>. Consulté le 11-03-2021.
- [11] Xintao Liang Yujing Wang Changyue Zhou Qingyan Wang, Qi Zhang and Vladimir Ivanovich Mikulovich. Traffic lights detection and recognition method based on the improved yolov4 algorithm. page 20.
- [12] Yuzhe Lin Zhaoxiang Qin, Zheng Guo. An implementation of face mask detection system based on yolov4 architecture. page 7.

- [13] LANMEI WANG KUN ZHOU1 ANLIANG CHU GUIBAO WANG and LIZHE WANG. An improved light-weight traffic sign recognition algorithm based on yolov4-tiny. page 9.
- [14] Gtsdb dataset. https://benchmark.ini.rub.de/gtsdb_news.html. Consulté le 27-02-2022.
- [15] Gtsrb dataset. <https://www.kaggle.com/datasets/mmontiel/tiny-lisa-traffic-sign-detection-dataset>. Consulté le 12-03-2022.
- [16] Custom dataset. <https://drive.google.com/file/d/1gQD10ovQDyjM1UEWl6IEn2mzgS6KNppX/view>. compte github : aryan0141, Consulté le 10-04-2022.
- [17] Azure ml. <https://azure.microsoft.com/fr-fr/services/machine-learning/>. Consulté le 07-04-2022.
- [18] Mlflow. <https://mlflow.org/>. Consulté le 17-04-2022.
- [19] Azure blob storage. <https://azure.microsoft.com/fr-fr/services/storage/blobs/>. Consulté le 15-04-2022.
- [20] Huarong Xu Yi Yang, Hengliang Luo and Fuchao Wu. Towards real-time traffic sign detection and classification. page 10.
- [21] Mahammad A. Hannan Aini Hussain Salina A. Samad Pin J. Ker Safat B. Wali, Majid A. Abdullah and Muhamad Bin Mansor. Vision-based traffic sign detection and recognition systems : Current trends and challenges. page 29.
- [22] Yanxiang Li Yuchen Liu, Gang Shi and Ziyu Zhao. M-yolo : Traffic sign detection algorithm applicable to complex scenarios. page 21.
- [23] Cloud computing. <https://azure.microsoft.com/fr-fr/overview/what-is-cloud-computing/#benefits>. Consulté le 19-03-2022.
- [24] Les services du cloud. <https://www.techtarget.com/searchitchannel/definition/cloud-service-provider-cloud-provider>. Consulté le 07-04-2022.
- [25] Les panneaux d'indication. <https://codedelaroute.io/blog/panneau-indication/>. Consulté le 11-02-2022.
- [26] Les panneaux d'interdiction. <https://codedelaroute.io/blog/panneau-interdiction/>. Consulté le 11-02-2022.
- [27] Les panneaux de danger. <https://codedelaroute.io/blog/panneaux-danger/>. Consulté le 11-02-2022.

- [28] Les panneaux d'obligation. <https://codedelaroute.io/blog/planche-tous-panneaux/>. Consulté le 11-02-2022.

Annexe

1. Knowledge Discovery in Databases

Knowledge Discovery in Databases (KDD) est un processus utilisé dans la fouille de données proposé en 1996 par osama Fayyad. Cette méthodologie se base sur l'extraction des connaissances et des motifs valides et utiles à partir des grandes masses de données moyennant des méthodes automatiques ou semi-automatiques.

Le processus est composé par 5 tâches principales dans lesquelles la fouille de données représente seulement une seule étape dans le processus et qui est accompagnée par les tâches de pré-traitement, échantillonnage et transformation. Ces tâches sont décrites par la figure 1




FIGURE 1 – Méthodologie KDD

- **Sélection** : Cette étape est consacrée à la sélection d'un ensemble de données pour créer un échantillon qui fera l'objet du processus d'exploration
- **Pré-traitement** : Cette tâche est dédiée au nettoyage et au pré-traitement des données cibles afin d'obtenir des résultats plus fiables. Au cours de cette étape les analystes essaient d'éliminer le bruit créé par les valeurs aberrantes ou les valeurs manquantes.
- **Transformation** : C'est l'étape la plus importante pour réussir le projet de fouille de données. Dans cette étape nous cherchons des méthodes pour mieux représenter les données telles que : la réduction des dimensions et la transformation des

attributs.

- **Exploration de données** : Au cours de cette étape, les analystes choisissent et implémentent les algorithmes qui sont adaptés au problème : Régression, Classification etc..
- **Evaluation** : Cette étape consiste à interpréter les résultats issus de l'étape précédente et évaluer les modèles.

Le processus de KDD est considéré itératif où nous pouvons refaire les étapes précédentes. Le problème de ce processus, est le manque de guidage pour l'utilisateur.

2. Processus SEMMA

Le processus SEMMA a été développé par l'institut SAS comme étant un processus de conduire les projets d'exploration des données. SEMMA signifie Sample, Explore, Modify, Model, Assess qui sont les étapes principales de ce processus. Il facilite l'application des techniques d'exploration et de visualisation des données, la sélection et la transformation des variables prédictives, la modélisation des variables pour assurer la précision du modèle.

- **Échantillon** : Cette tâche consiste à créer un échantillon de données par l'extraction d'une partie d'un ensemble de données suffisamment grande pour contenir les informations importantes et suffisamment petite pour qu'elle soit traitée rapidement.
- **Explorer** : Cette étape consiste à explorer les données et chercher les tendances où les anomalies imprévues pour mieux les comprendre.
- **Modifier** : Consiste à modifier les données en créant, sélectionnant et transformant les variables pour faciliter le processus de sélection du modèle.
- **Modèle** : Cette étape consiste à modéliser les données afin de permettre à la machine de chercher automatiquement une combinaison de données et des mécanismes pour assurer une prédiction fiable et attendre le résultat souhaité.
- **Évaluer** : Cette étape consiste à évaluer les données, évaluer l'utilité et la fiabilité des résultats du processus d'exploration de données et estimer les performances du modèle

3. Le Cloud Computing

Le Cloud computing est devenu indispensable pour la réalisation des solutions à haute performance. En effet, nous avons choisi de l'impliquer pour accélérer le traitement

d'apprentissage qui est connu par sa lourdeur d'une part, et d'autre part, il sera le meilleur emplacement pour le stockage de données lourdes à savoir les vidéos et les images. Nous décrivons dans cette section le concept du Cloud Computing en déterminant ses différents services et avantages.

- **Définition**

Le cloud computing fait référence à la livraison de ressources et de services à la demande par internet, il forme une infrastructure dans laquelle la puissance de calcul et de stockage est élevée et est gérée par un ou plusieurs serveurs distants situés dans un centre de stockage sécurisé avec accès limité. [23]

Le type de cloud que nous utilisons est l'Infrastructure as a Service (**IaaS**) offrant ainsi des ressources de calcul et de stockage payées à la demande selon un quota d'utilisation.. Cette puissance de calcul et de stockage est procurée par un fournisseur de services cloud et elle est adaptable automatiquement à la demande des consommateurs de services du cloud. Il existe également d'autre types de cloud à savoir le Software as a Service (**SaaS**) et le Platform as a Service (**PaaS**).

Les intervenants du Cloud sont :

- **Un consommateur de cloud** : C'est une organisation (ou une personne) qui possède un contrat ou un accord formel avec les fournisseurs de cloud pour exploiter les ressources offertes et accéder aux services fournis.
- **Un fournisseur de cloud** : C'est l'organisation qui fournit les ressources informatiques et qui est chargée de fournir des services cloud aux consommateurs de cloud.

La figure 2 illustre l'échange entre les consommateurs et les fournisseurs du cloud. Le fournisseur de cloud est également responsable de toutes les tâches de gestion et d'administration nécessaires pour assurer le fonctionnement continu de l'ensemble de l'infrastructure Cloud. Les grands fournisseurs de services cloud de nos jours sont Amazon, Microsoft, Google, Alibaba et IBM.

- **Services**

Les services du cloud qu'un fournisseur peut procurer sont [24] :

- Stocker, sauvegarder et récupérer des données : il est possible de transférer des données vers un système de stockage cloud (**IaaS**) depuis n'importe quel emplacement et n'importe quel appareil à travers le réseau Internet.
- Tester et créer des applications : le cloud offre des environnements de développement et de test Backend as a Service (**BaaS**) facilement exploitables permettant




FIGURE 2 – Fournisseurs et consommateurs du Cloud

la génération d'applications performantes.

- Analyse de données volumineuses : c'est l'une des fonctionnalités offertes par le cloud computing (SaaS) permettant d'exploiter de vastes quantités de données structurées comme les données tabulaires et non structurées comme les images et les vidéos

- **Avantages**

Le Cloud Computing presente plusieurs avantages parmi lesquels :

- **Mobilité** : le cloud computing permet un accès mobile aux données de l'entreprise via les smartphones et les appareils.
- **Scalabilité** : le cloud permet d'augmenter ou réduire la capacité de stockage selon les besoins d'exploitation, ce qui permet d'adapter le service de stockage selon l'évolution des besoins du client.
- **Intégrité** : le cloud offre des fonctionnalités de traitement et de stockage persistant de données en appliquant des techniques de sécurité avancées.
- **Collaboration** : l'infrastructure du cloud offre des fonctionnalités avancées de collaboration, de gestion multi-tâches et de partage aux différentes expertises (équipe de conception, équipe de développement, équipe d'assurance de qualité, équipe d'opérations, équipe de sécurité...) appartenant à la même organisation.

Dans le contexte de notre travail, nous exploitons le cloud pour stocker les dataset et pour consommer des ressources de calcul permettant de réaliser un apprentissage des modèles sur des machines de hautes performance ayant un Graphics Processing

Unit (GPU) important permettant d'aboutir à des résultats rapidement. Nous avons choisi, ainsi, d'utiliser Microsoft Azure qui nous offre un crédit grâce à la convention avec l'entreprise TALAN.

4. Les catégories des panneaux routiers

Bien connaître les panneaux de signalisation routière et leur signification est indispensable pour obtenir son code de la route et conduire une voiture en toute sécurité. Le rôle des panneaux routiers est d'informer les conducteurs sur la route, les prévenir d'un danger ou leur prescrire une obligation ou une interdiction.

Généralement les panneaux routiers sont classés en 4 grandes familles, selon une typologie obéissant à la forme et à la couleur des panneaux.

- **Les panneaux d'indication** : Ce sont des panneaux de forme carré. Ils ont souvent un fond bleu ou un fond blanc avec une bordure bleue [25]. Ces informations peuvent soit signaler une direction, un obstacle ou encore un emplacement. La figure 3 illustre cette catégorie.




FIGURE 3 – Les panneaux d'indication

- **Les panneaux d'interdiction** : Ce sont les panneaux ronds avec un fond blanc et une bordure rouge. Ils peuvent aussi avoir un fond rouge [26]. Le type de l'action interdite est représenté sur le panneau comme le montre la figure 4



FIGURE 4 – Les panneaux d'interdiction

- **Les panneaux de danger** : Ce sont les panneaux de signalisation triangulaires avec un fond blanc et de bordure rouge [27]. Chaque panneau annonce un danger précis à l'aide d'un symbole noir, en fonction du risque présent sur la route (figure 5)



FIGURE 5 – Les panneaux de danger

- **Les panneaux d'obligation** : Ce sont des panneaux ronds à fond bleu. Ils permettent d'indiquer des obligations de direction [28]. Cette catégorie est présentée par la figure 6



FIGURE 6 – Les panneaux d'obligation