



IT DEPARTMENT

End of Studies Project Report

Presented to Obtain:

National Diploma of Computer Engineering

SPECIALTY: SOFTWARE ENGINEERING - SOFTWARE ARCHITECTURE

Agentic AI Voice Platform: A Multi-Agent Architecture for Telecom Support

Hosting Company



Elaborated by:

Chouaib Saad

Presented on the:

09/07/2024 in front of the jury:

President:

Me. First Name

ISSAT of Sousse

Examiner:

Mr. First Name

ISSAT of Sousse

Academic supervisor:

Me. Khmaja Maha

ISSAT of Sousse

Company supervisor:

Mr. Ayoub Mejri

Amsys Consulting

Academic Year: 2025 / 2026

Subject Code : FI-GL24-103



Dédicace

À ma très chère mère, pour son amour inconditionnel et ses sacrifices sans cesse renouvelés, et à l'âme aimée de mon défunt père, dont la mémoire et l'esprit demeurent la lumière qui éclaire chacun de mes pas. Ce travail vous est d'abord destiné.

À mes frères, pour la chaleur, les rires et le soutien sans faille qui ont toujours rendu les moments difficiles plus légers.

À mon cher ami Bilel Dhahri, pour son soutien sincère, ses conversations franches et cette forme d'amitié qui rend les défis les plus exigeants surmontables. Merci d'avoir été présent.

À toutes celles et tous ceux qui ont cru en moi avant que je n'y crois moi-même, ce travail vous est dédié.

Chouaib Saad



Remerciements

Je tiens en premier lieu à exprimer ma profonde gratitude à mon encadrante pédagogique, **Madame Maha Khemaja**, pour la qualité de son encadrement, sa disponibilité constante et la pertinence de ses retours. Son expertise et ses encouragements, à chaque étape de ce travail, ont été déterminants dans l'atteinte du résultat présenté ici.

Je remercie également mon encadrant professionnel, **Monsieur Ayoub Mejri**, pour sa confiance, son accompagnement technique et son soutien continu, depuis la phase de conception jusqu'à la réalisation finale. Son regard professionnel a sensiblement enrichi à la fois la profondeur technique et la pertinence métier du projet.

Mes remerciements sincères s'adressent à toute l'équipe de la société **Amsys Consulting** pour son accueil chaleureux et l'environnement professionnel stimulant qu'elle m'a offert. La possibilité de travailler aux côtés d'ingénieurs expérimentés a constitué un complément précieux à ma formation académique.

Je tiens à exprimer ma reconnaissance aux honorables membres du jury pour avoir accepté de consacrer leur temps et leur expertise à l'évaluation de ce travail. Je leur suis profondément redevable de l'attention qu'ils porteront à ce projet.

Mes remerciements vont enfin à l'ensemble du corps enseignant et du personnel administratif de l'**Institut Supérieur des Sciences Appliquées et de Technologie de Sousse**, pour le soutien apporté tout au long de mon parcours universitaire.

Chouaib Saad



Résumé

Ce projet de fin d'études, réalisé au sein de la société Amsys Consulting, porte sur la conception et la réalisation d'une plateforme conversationnelle temps réel destinée à l'automatisation de la relation client dans le secteur des télécommunications. La plateforme prend en charge de bout en bout les demandes courantes d'un abonné, en voix comme en texte, en français, en arabe et en anglais.

Le système repose sur une architecture en ports et adaptateurs qui maintient les règles métier indépendantes de toute dépendance technique, et sur un ensemble de cinq agents conversationnels spécialisés dont le contexte est assemblé selon les besoins de chaque échange. Les réponses factuelles sont ancrées dans la documentation de l'opérateur au moyen d'une chaîne de recherche procédant par filtres successifs, conçue pour admettre son ignorance plutôt que produire une réponse infondée. Toute opération engageant le compte d'un client est précédée d'une vérification d'identité, soumise à des règles métier déterministes rendant un verdict motivé et tracé, puis exécutée de manière à ne pouvoir l'être deux fois. Chaque acte conséquent est inscrit dans un registre chaîné dont l'altération est détectable. Lorsque l'autonomie n'est pas appropriée, la conversation est transmise à un conseiller humain accompagnée du dossier complet, ou un rappel est négocié sur les disponibilités réelles.

Le travail a été conduit selon un cycle itératif et incrémental, chaque incrément étant mesuré avant d'être conservé. Le système réalisé compte vingt quatre services conteneurisés, une chaîne vocale temps réel dotée d'une solution de repli à chaque étape, deux interfaces web et un dispositif d'observabilité. Les mesures conduites sur la recherche documentaire ont mis en évidence une inversion des scores de similarité entre langues, qui a imposé une révision de la méthode de sélection des passages.

Mots clés : plateforme conversationnelle, agents spécialisés, traitement temps réel, recherche augmentée par récupération, architecture hexagonale, règles métier déterministes, traçabilité, télécommunications.



Abstract

This final year project, carried out at Amsys Consulting, covers the design and implementation of a real time conversational platform for customer service automation in the telecommunications sector. The platform handles a subscriber's routine requests end to end, over voice and text, in French, Arabic and English.

The system rests on a ports and adapters architecture that keeps business rules independent of any technical dependency, and on a set of five specialised conversational agents whose context is assembled according to the needs of each exchange. Factual answers are grounded in the operator's own documentation through a retrieval chain built as a sequence of filters, designed to admit ignorance rather than produce an unfounded answer. Every operation affecting a customer account is preceded by an identity check, submitted to deterministic business rules returning a justified and traceable verdict, then executed in a way that prevents it from happening twice. Each consequential act is written to a chained ledger in which tampering is detectable. When autonomy is not appropriate, the conversation is handed over to a human advisor together with the complete case file, or a callback is negotiated against real advisor availability.

The work followed an iterative and incremental lifecycle, each increment being measured before being kept. The delivered system comprises twenty four containerised services, a real time voice chain with a fallback at every stage, two web interfaces and an observability layer. Measurements carried out on documentary retrieval revealed an inversion of similarity scores across languages, which required revising the passage selection method.

Keywords : conversational platform, specialised agents, real time processing, retrieval augmented generation, hexagonal architecture, deterministic business rules, traceability, telecommunications.



TABLE DES MATIÈRES

LISTE DES FIGURES	viii
LISTE DES TABLEAUX	x
Liste des abréviations	xi
Introduction Générale	1
1 Présentation générale du projet	3
1.1 Présentation de l'organisme d'accueil	4
1.2 Présentation du projet	5
1.2.1 Cadre général du projet	5
1.2.2 Problématique	6
1.2.3 Solution proposée	7
1.2.4 Objectifs du projet	7
1.3 Étude de l'existant	8
1.3.1 Le dispositif en place chez les opérateurs	8
1.3.2 Les plateformes commerciales d'automatisation conversationnelle	9
1.3.2.1 PolyAI	9
1.3.2.2 Cognigy	9
1.3.2.3 Parloa	10
1.3.3 Synthèse comparative	10
1.4 Chronologie du projet	12
1.5 Processus de développement	13
1.5.1 Le choix d'un cycle itératif et incrémental	13
1.5.2 La forme concrète des itérations	14
1.5.3 Vérification continue	14
2 Spécification des besoins	16
2.1 Identification des acteurs	17

2.1.1	Acteurs principaux	17
2.1.2	Acteurs secondaires	18
2.2	Besoins fonctionnels	19
2.2.1	Conduite de la conversation	19
2.2.2	Construction du contexte client	19
2.2.3	Ancrage documentaire des réponses	19
2.2.4	Traitement des actions sensibles	19
2.2.5	Gestion des tickets	20
2.2.6	Escalade et rappel	20
2.2.7	Espace client	20
2.2.8	Supervision et administration	20
2.2.9	Récapitulatif	21
2.3	Besoins non fonctionnels	21
2.3.1	Performance et comportement temps réel	21
2.3.2	Fiabilité et disponibilité	22
2.3.3	Robustesse et tolérance aux pannes	22
2.3.4	Sécurité et confidentialité	22
2.3.5	Traçabilité et auditabilité	22
2.3.6	Extensibilité et maintenabilité	22
2.3.7	Passage à l'échelle	23
2.3.8	Interopérabilité et portabilité	23
2.3.9	Testabilité	23
2.3.10	Ergonomie	23
2.3.11	Récapitulatif	23
2.4	Diagrammes de cas d'utilisation	24
2.4.1	Diagramme de cas d'utilisation général	24
2.4.2	Cas d'utilisation : obtenir une réponse documentaire	25
2.4.2.1	Diagramme du cas	25
2.4.2.2	Description textuelle	25
2.4.2.3	Diagramme de séquence système	27
2.4.3	Cas d'utilisation : exécuter une opération sensible	27
2.4.3.1	Diagramme du cas	27
2.4.3.2	Description textuelle	27
2.4.3.3	Diagramme de séquence système	29
2.4.4	Cas d'utilisation : escalader vers un conseiller humain	29
2.4.4.1	Diagramme du cas	29

2.4.4.2	Description textuelle	29
2.4.4.3	Diagramme de séquence système	31
3	Conception	33
3.1	Vue statique de l'application	34
3.1.1	Architecture logique du logiciel	34
3.1.1.1	Le principe retenu	34
3.1.1.2	Les ports du domaine	34
3.1.1.3	Découpage en contextes métier	35
3.1.1.4	Décomposition en composants	37
3.1.2	Diagrammes de classes	38
3.1.2.1	Modèle du domaine	38
3.1.2.2	Hierarchie des agents conversationnels	38
3.1.2.3	Moteur de décision déterministe	39
3.1.3	Conception de la base de données	41
3.1.3.1	Organisation en schémas	41
3.1.3.2	Modèle entités associations	41
3.1.3.3	Deux asymétries assumées	41
3.2	Vue dynamique de l'application	42
3.2.1	Diagrammes de séquence	43
3.2.1.1	Déroulement d'un tour de parole	43
3.2.1.2	Déroulement d'une action sensible	43
3.2.2	Diagrammes d'activités	44
3.2.2.1	Ingestion documentaire	44
3.2.2.2	Recherche documentaire	46
3.2.3	Diagrammes d'états transitions	46
3.2.3.1	Cycle de vie d'une conversation	46
3.2.3.2	Cycle de vie d'un ticket	47
3.3	Conception du système agentique	48
3.3.1	Principe et pipeline de raisonnement	49
3.3.2	Décomposition en agents spécialisés	49
3.3.2.1	Motivation	49
3.3.2.2	Déclaration unique des domaines	50
3.3.2.3	Passage de relais entre agents	51
3.3.3	Construction du contexte	51
3.3.3.1	Un contexte assemblé et non accumulé	51

3.3.3.2	Mémoire courte et mémoire longue	52
3.3.4	Garde fous et comportement déterministe	54
3.3.4.1	Nature des garde fous	54
3.3.4.2	Le sentiment comme signal de décision	54
3.3.4.3	Déterminisme là où il compte	55
3.3.5	Du prompt au harnais	56
3.4	Conception de la sécurité et du contrôle d'accès	56
3.4.1	Deux frontières distinctes	56
3.4.2	Authentification et gestion de session	56
3.4.3	Autorisation fondée sur le rôle	57
3.4.4	Isolation des données entre clients	58
3.4.5	Vérification d'identité renforcée	59
3.4.6	Traçabilité	59
4	Réalisation	61
4.1	Technologies	63
4.1.1	Principe de sélection	63
4.1.2	Technologies par couche	63
4.1.3	Le rôle de la couche temps réel	64
4.2	Outils d'implémentation	65
4.2.1	Environnement matériel	65
4.2.2	Environnement logiciel	66
4.3	La chaîne de traitement temps réel	67
4.3.1	Vue d'ensemble et principe du budget	67
4.3.2	Établissement de la session et transport	67
4.3.2.1	Rôle	67
4.3.2.2	Réalisation	67
4.3.2.3	Ce que le choix a coûté	68
4.3.2.4	Sortie vers la téléphonie	68
4.3.3	Détection de fin d'énoncé et gestion des tours de parole	68
4.3.3.1	Rôle	68
4.3.3.2	Réalisation	69
4.3.3.3	Génération anticipée	69
4.3.4	Transcription de la parole	69
4.3.4.1	Rôle et métriques	69
4.3.4.2	Réalisation	69

4.3.4.3	Chaîne de repli	70
4.3.5	Raisonnement	70
4.3.5.1	Rôle et critères de sélection	70
4.3.5.2	Le compromis évité	71
4.3.5.3	Réalisation	71
4.3.5.4	Travaux sur l'exécution locale	72
4.3.6	Récupération documentaire sous contrainte temps réel	72
4.3.6.1	Le problème particulier de cette étape	72
4.3.6.2	Encodage des textes	73
4.3.6.3	Recherche en trois filtres	73
4.3.6.4	Ce que le choix a coûté	74
4.3.7	Synthèse vocale	74
4.3.7.1	Rôle et métrique déterminante	74
4.3.7.2	Une exigence éliminatoire	74
4.3.7.3	Réalisation	75
4.3.7.4	Une mesure inattendue	75
4.3.7.5	Positionnement des fournisseurs retenus	75
4.3.8	Gestion des interruptions et budget global	76
4.3.8.1	Interruption	76
4.3.8.2	Budget de latence	76
4.4	Concurrence et gestion des ressources	78
4.4.1	Deux échelles de concurrence	78
4.4.2	Isolation des conversations	78
4.4.3	Isolation des opérations concurrentes	78
4.4.3.1	L'identité d'opération	78
4.4.3.2	Ce que l'identité ne doit pas contenir	78
4.4.3.3	Garantie sous concurrence réelle	79
4.4.4	Ordonnancement des écritures d'audit	79
4.4.5	Isolation des écritures secondaires	79
4.4.6	Découplage de l'enregistrement conversationnel	80
4.5	Architecture physique et évolution temporelle	81
4.5.1	Topologie de déploiement	81
4.5.2	Chaîne d'observabilité	81
4.5.2.1	Une instrumentation qui ne dépend de rien	81
4.5.2.2	Collecte et restitution	82
4.5.2.3	Trois décisions de conception	82

4.5.2.4	L'identifiant de corrélation	83
4.5.3	Une protection au démarrage	83
4.5.4	Évolution temporelle d'un échange	84
4.6	Interfaces de l'application	84
4.6.1	Portail client	84
4.6.2	Console d'administration et de supervision	85
4.6.3	Systèmes intégrés et environnement d'exécution	87
4.7	Vérification et évaluation	88
4.7.1	Principe retenu	88
4.7.2	Familles de vérifications	89
4.7.3	Vérification par injection de défaillance	89
4.7.4	Contrôle d'intégrité	89
4.8	Résultats et statistiques	90
4.8.1	Statut des mesures présentées	90
4.8.2	Qualité de la recherche documentaire	90
4.8.2.1	Le problème du seuil unique	90
4.8.2.2	L'inversion qui a imposé une évaluation conjointe	91
4.8.2.3	Coût de la solution retenue	92
4.8.3	Volumétrie du système réalisé	93
4.8.4	Comportement en situation de défaillance	93
4.9	Problèmes rencontrés	94
4.9.1	Une dégradation silencieuse de la recherche documentaire	94
4.9.2	L'inversion des scores de similarité	95
4.9.3	Un modèle de mécontentement à la fois trop sensible et trop indulgent	95
4.9.4	Un risque de confusion entre services	96
4.9.5	Une identité d'opération trop inclusive	96
4.9.6	La contrainte de mémoire et ses conséquences	96
Conclusion Générale		98
Bibliographie		100
Nétographie		102
Annexe A : Fondements de la recherche augmentée par récupération		104
Annexe B : Métriques de la chaîne vocale		107

Annexe C : Notions relatives aux systèmes agentiques	111
Annexe D : Modèle détaillé de sécurité et d’audit	113

LISTE DES FIGURES

1.1	Logo de la société Amsys Consulting	5
1.2	Diagramme de Gantt du projet	12
1.3	Cycle itératif et incrémental appliqué au projet	14
2.1	Carte des besoins fonctionnels par domaine	21
2.2	Diagramme de cas d'utilisation général de la plateforme	25
2.3	Diagramme du cas d'utilisation Obtenir une réponse documentaire	26
2.4	Diagramme de séquence système du cas Obtenir une réponse documentaire	27
2.5	Diagramme du cas d'utilisation Exécuter une opération sensible	28
2.6	Diagramme de séquence système du cas Exécuter une opération sensible	29
2.7	Diagramme du cas d'utilisation Escalader vers un conseiller humain	30
2.8	Diagramme de séquence système du cas Escalader vers un conseiller humain	31
3.1	Architecture hexagonale de la plateforme	35
3.2	Diagramme de paquetages des contextes métier	36
3.3	Diagramme de composants de la plateforme	37
3.4	Diagramme de classes du modèle du domaine	39
3.5	Diagramme de classes de la hiérarchie des agents	40
3.6	Diagramme de classes du moteur de politique	40
3.7	Modèle entités associations des schémas centraux	42
3.8	Diagramme de séquence du traitement d'un tour de parole	43
3.9	Diagramme de séquence d'une action sensible	44
3.10	Diagramme d'activités de l'ingestion documentaire	45
3.11	Diagramme d'activités de la recherche documentaire	47
3.12	Diagramme d'états transitions d'une conversation	48
3.13	Diagramme d'états transitions d'un ticket	48
3.14	Pipeline de raisonnement d'un agent	49
3.15	Orchestration des agents et transitions	51
3.16	Assemblage du contexte d'un agent	53

3.17	Modèle de sécurité de la plateforme	57
4.1	Chaîne de traitement temps réel et contribution des étapes	67
4.2	Positionnement qualitatif des fournisseurs de la chaîne vocale	76
4.3	Répartition du budget de latence par étape	77
4.4	Gestion de la concurrence et des ressources	80
4.5	Diagramme de déploiement de la plateforme	81
4.6	Chronogramme d'un échange conversationnel complet	84
4.7	Portail client : assistant conversationnel et facturation	85
4.8	Portail client : demandes en cours et historique des échanges	85
4.9	Console d'administration : inspection des décisions et des verdicts	86
4.10	Console d'administration : registre d'audit et vérification d'intégrité	86
4.11	Console d'administration : supervision de l'activité	86
4.12	Console d'administration : gouvernance du comportement	87
4.13	Console d'administration : escalade et disponibilités	87
4.14	Intégrations effectives	87
4.15	Tableaux de bord de supervision	88
4.16	Collecte des mesures et topologie en exécution	88
4.17	Familles de vérifications et propriétés protégées	89
4.18	Séparation entre réponses pertinentes et bruit selon la méthode d'évaluation	92
4.19	Volumétrie du système réalisé	93



LISTE DES TABLEAUX

1.1	Avantages et inconvénients des systèmes existants	11
1.2	Positionnement de la solution proposée par rapport aux plateformes étudiées . .	12
1.3	Phases du projet et résultats associés	13
2.1	Acteurs de la plateforme et modes d'interaction	18
2.2	Besoins non fonctionnels et propriétés architecturales associées	24
2.3	Description textuelle du cas Obtenir une réponse documentaire	26
2.4	Description textuelle du cas Exécuter une opération sensible	28
2.5	Description textuelle du cas Escalader vers un conseiller humain	30
3.1	Déclaration unique des domaines de spécialité	50
3.2	Sources du contexte et conditions de sollicitation	52
3.3	Comportement du modèle d'accumulation du mécontentement	55
3.4	Comportements rendus déterministes et motifs associés	55
3.5	Matrice des droits par rôle	58
4.1	Technologies retenues par couche	64
4.2	Caractéristiques du poste de développement	65
4.3	Environnement logiciel de développement	66
4.4	Chaîne de repli de la transcription	70
4.5	Chaîne de repli du modèle de langue	72
4.6	Filtres successifs de la recherche documentaire	73
4.7	Chaîne de repli de la synthèse vocale	75
4.8	Répartition du délai entre la fin de l'énoncé et le début de la réponse	77
4.9	Scores de proximité mesurés sur le corpus documentaire	91
4.10	Comparaison des modèles évalués pour la recherche documentaire	93
4.11	Comportement du système en situation de défaillance provoquée	94



Liste des abréviations

API	Application Programming Interface, interface de programmation applicative
ASR	Automatic Speech Recognition, reconnaissance automatique de la parole
BM25	Best Matching 25, fonction de pondération lexicale
CER	Character Error Rate, taux d'erreur sur les caractères
CIN	Carte d'Identité Nationale
CQRS	Command Query Responsibility Segregation, séparation des responsabilités de commande et de requête
DDD	Domain Driven Design, conception pilotée par le domaine
DER	Diarization Error Rate, taux d'erreur de segmentation en locuteurs
G2P	Grapheme to Phoneme, conversion graphème phonème
GLPI	Gestionnaire Libre de Parc Informatique
HNSW	Hierarchical Navigable Small World, structure d'index vectoriel
HTTP	HyperText Transfer Protocol
IDF	Inverse Document Frequency, fréquence inverse de document
ITN	Inverse Text Normalization, normalisation inverse du texte
JWT	JSON Web Token, jeton d'accès signé
LLM	Large Language Model, grand modèle de langue
MCD	Mel Cepstral Distortion, distorsion cepstrale sur l'échelle de Mel
MCP	Model Context Protocol, protocole de mise à disposition de capacités
MFCC	Mel Frequency Cepstral Coefficients, coefficients cepstraux sur l'échelle de Mel
MOS	Mean Opinion Score, note moyenne d'opinion
MSISDN	Mobile Station International Subscriber Directory Number, numéro d'appel de l'abonné
NVMe	Non Volatile Memory express, interface de stockage à semi conducteurs
ONNX	Open Neural Network Exchange, format d'échange de modèles
OTel	OpenTelemetry, cadre de collecte de traces et de métriques
PESQ	Perceptual Evaluation of Speech Quality, évaluation perceptuelle de la qualité vocale
PII	Personally Identifiable Information, données à caractère personnel

RAG	Retrieval Augmented Generation, génération augmentée par récupération
RBAC	Role Based Access Control, contrôle d'accès fondé sur les rôles
REST	Representational State Transfer, style d'architecture d'interface applicative
RRF	Reciprocal Rank Fusion, fusion par rangs réciproques
RTF	Real Time Factor, facteur temps réel
SIM	Subscriber Identity Module, module d'identité de l'abonné
SIP	Session Initiation Protocol, protocole d'établissement de session
SMTP	Simple Mail Transfer Protocol
SNR	Signal to Noise Ratio, rapport signal sur bruit
SOLID	Single responsibility, Open closed, Liskov substitution, Interface segregation, Dependency inversion
SSML	Speech Synthesis Markup Language, langage de balisage pour la synthèse vocale
STOI	Short Time Objective Intelligibility, intelligibilité objective à court terme
STT	Speech To Text, transcription de la parole en texte
TND	Dinar tunisien
TTFA	Time To First Audio, délai avant le premier fragment audio
TTFB	Time To First Byte, délai avant le premier octet
TTFT	Time To First Token, délai avant le premier jeton
TTS	Text To Speech, synthèse vocale
UML	Unified Modeling Language, langage de modélisation unifié
UUID	Universally Unique Identifier, identifiant universellement unique
VAD	Voice Activity Detection, détection d'activité vocale
WebRTC	Web Real Time Communication, communication temps réel pour le web
WER	Word Error Rate, taux d'erreur sur les mots
WIL	Word Information Lost, information de mot perdue



Introduction Générale

Le secteur des télécommunications repose sur une relation client de masse. Un opérateur traite chaque jour un volume considérable de sollicitations, dont la très grande majorité porte sur des opérations courantes : consulter un solde, régler une facture, recharger une ligne, activer une option, signaler une connexion dégradée ou débloquer une carte SIM. Ces demandes suivent un cheminement stable, s'appuient sur des informations déjà détenues par l'opérateur et aboutissent à un nombre restreint d'actions bien identifiées. Elles mobilisent pourtant une part importante du temps des conseillers, tandis que les canaux automatisés existants, construits autour d'arborescences de menus, imposent au client de traduire son besoin dans le vocabulaire du système et ne transportent pratiquement aucun contexte d'une étape à la suivante. Les progrès récents des modèles de langue et des technologies vocales rendent aujourd'hui envisageable une prise en charge conversationnelle de ces demandes, à condition de résoudre deux difficultés simultanément : tenir le rythme d'un échange parlé, et garantir qu'un système capable d'agir sur un compte client ne le fasse jamais sans autorisation vérifiable.

Le présent projet, réalisé au sein de la société Amsys Consulting, porte sur la conception et la réalisation d'une plateforme conversationnelle temps réel destinée à l'automatisation de la relation client dans ce secteur. La plateforme prend en charge les demandes fréquentes de bout en bout, en voix comme en texte et dans trois langues, en s'appuyant sur un ensemble d'agents spécialisés. Elle ancre ses réponses factuelles dans la documentation propre à l'opérateur plutôt que dans la mémoire du modèle, soumet toute action engageant un compte à des règles métier déterministes produisant un verdict motivé, exécute les opérations approuvées de manière à ce qu'elles ne puissent être réalisées deux fois, consigne chaque acte conséquent dans un registre dont l'altération est détectable, et transmet la conversation à un conseiller humain, accompagnée du dossier complet, lorsque l'autonomie n'est pas appropriée. Deux interfaces web complètent l'ensemble : un portail destiné au client et une console de supervision et d'administration destinée aux équipes internes.

Ce rapport est organisé en quatre chapitres. Le premier situe le projet dans son cadre, présente l'organisme d'accueil, expose la problématique et les objectifs retenus, examine les solutions existantes et décrit la chronologie ainsi que le processus de développement appliqué. Le deuxième traduit ces objectifs en spécifications : acteurs, besoins fonctionnels, besoins non fonctionnels et cas d'utilisation. Le troisième présente la conception du système, sa vue statique

et sa vue dynamique, puis détaille la conception de la couche agentique et celle du contrôle d'accès. Le quatrième expose la réalisation : technologies employées, chaîne de traitement temps réel étudiée étape par étape, gestion de la concurrence, architecture de déploiement, interfaces produites, campagne de vérification, résultats obtenus et difficultés rencontrées. Une conclusion générale dresse le bilan du travail accompli et présente les perspectives d'évolution de la plateforme.

Présentation générale du projet

Sommaire

1.1	Présentation de l'organisme d'accueil	4
1.2	Présentation du projet	5
1.2.1	Cadre général du projet	5
1.2.2	Problématique	6
1.2.3	Solution proposée	7
1.2.4	Objectifs du projet	7
1.3	Étude de l'existant	8
1.3.1	Le dispositif en place chez les opérateurs	8
1.3.2	Les plateformes commerciales d'automatisation conversationnelle	9
1.3.3	Synthèse comparative	10
1.4	Chronologie du projet	12
1.5	Processus de développement	13
1.5.1	Le choix d'un cycle itératif et incrémental	13
1.5.2	La forme concrète des itérations	14
1.5.3	Vérification continue	14

Introduction

Ce premier chapitre situe le projet dans son contexte. Nous présentons d'abord la société qui a accueilli le stage, puis le cadre métier dans lequel s'inscrit la plateforme développée. Nous exposons ensuite la problématique qui a motivé ce travail, l'idée de solution retenue pour y répondre et les objectifs que nous nous sommes fixés. Une étude des solutions existantes permet de positionner notre proposition par rapport à l'offre du marché. Le chapitre se termine par la chronologie du projet et par le processus de développement que nous avons appliqué.

1.1 Présentation de l'organisme d'accueil

Fondée en 2009, Amsys Consulting est une société internationale de conseil et d'ingénierie technologique qui accompagne ses clients dans leur transformation numérique. Son activité s'articule autour de trois lignes de services complémentaires : l'ingénierie informatique, les solutions automatisées et le conseil métier. Ces trois axes sont déployés sur un large éventail de secteurs, ce qui conduit les équipes à intervenir aussi bien sur des systèmes d'information existants que sur des projets construits à partir d'une page blanche.

Au fil de son développement, la société a élargi son périmètre géographique aux marchés européen et asiatique. Elle a par ailleurs structuré une practice dédiée à l'intelligence artificielle et à l'apprentissage automatique, chargée d'industrialiser les travaux menés dans ce domaine plutôt que de les cantonner à des expérimentations isolées. C'est dans le prolongement direct de cette expertise que s'inscrit le présent projet, à l'intersection de l'intelligence artificielle conversationnelle, de la recherche d'information et des opérations télécom.

La figure 1.1 présente l'identité visuelle de la société.

Amsys Consulting s'appuie sur un cadre rigoureux en matière de sécurité de l'information et de qualité de service, ainsi que sur des partenariats stratégiques avec les principaux fournisseurs de services cloud. Ce socle n'est pas resté un élément de contexte : il a directement structuré plusieurs choix techniques du projet. Les frontières de sécurité, les pratiques d'observabilité et l'architecture d'infrastructure décrites dans les chapitres suivants en découlent en grande partie, et plusieurs décisions que nous justifions par la suite ne s'expliquent pleinement qu'à la lumière de ces exigences internes.




FIGURE 1.1 – LOGO DE LA SOCIÉTÉ AMSYS CONSULTING

1.2 Présentation du projet

1.2.1 Cadre général du projet

Le projet se situe dans le domaine de la relation client des opérateurs de télécommunications. Un opérateur traite quotidiennement un volume considérable d'interactions entrantes, et la distribution de ces demandes est fortement déséquilibrée. Une minorité de sollicitations correspond à des situations complexes, singulières, qui justifient pleinement l'intervention d'un conseiller expérimenté. La grande majorité relève au contraire d'opérations courantes au déroulement prévisible : consulter un solde, régler une facture, recharger une ligne prépayée, activer une option, signaler une connexion dégradée ou demander le déblocage d'une carte SIM.

Ces opérations courantes partagent trois caractéristiques qui les rendent particulièrement adaptées à une automatisation conversationnelle. Elles suivent un cheminement stable d'une occurrence à l'autre. Elles s'appuient sur des informations déjà présentes dans le système d'information de l'opérateur. Elles aboutissent enfin à un nombre restreint d'actions bien identifiées. Le logiciel que nous avons développé prend place précisément à cet endroit : il se positionne en amont du conseiller humain, prend en charge les demandes qu'il peut résoudre de bout en bout, et réserve l'attention humaine aux situations qui la requièrent réellement.

Ce positionnement impose une contrainte de fonctionnement qui gouverne l'ensemble des décisions techniques présentées dans ce rapport. Un échange parlé n'est perçu comme naturel que si la réponse survient dans le rythme d'une conversation ordinaire. Au delà d'un certain délai, l'interlocuteur ne perçoit plus une hésitation mais une défaillance : il répète sa phrase, se reprend, ou abandonne. Cette contrainte transforme chaque étape du traitement en une question de budget. Comprendre la parole, retrouver le contexte du client, consulter la documentation de l'opérateur, raisonner, décider, agir puis répondre à voix haute sont autant d'étapes qui consomment une part d'un temps total qui ne peut pas s'allonger. Nous reviendrons sur cette

contrainte tout au long du rapport, car elle explique un grand nombre de choix qui paraîtraient arbitraires sans elle.

Le cadre du projet comporte enfin une dimension linguistique. Le contexte d'exploitation visé est multilingue : le français constitue la langue principale, l'arabe et l'anglais sont également pris en charge. Cette exigence n'est pas un simple paramètre de configuration. Elle influe sur le choix des modèles, sur la qualité de la recherche documentaire et sur la manière dont le système bascule d'une langue à l'autre en cours de conversation.

1.2.2 Problématique

Les canaux de relation client actuellement en service reposent majoritairement sur trois mécanismes : des serveurs vocaux interactifs organisés en arborescence de menus, des scripts destinés à guider les conseillers, et une procédure d'escalade par création de ticket. Cet ensemble fonctionne, mais il produit une expérience dont les limites sont bien documentées dans le secteur.

Le premier symptôme est le temps d'attente. Le second est la répétition : le client s'identifie une première fois auprès du serveur vocal, puis de nouveau auprès du conseiller, parfois une troisième fois lors d'un transfert. Le troisième symptôme est la perte de contexte. À chaque transition entre services, le client doit reformuler sa demande, car l'information rassemblée à l'étape précédente ne circule pas avec lui.

Deux conséquences en découlent. La première est d'ordre opérationnel. Une part significative du temps des conseillers est absorbée par des tâches au déroulement prévisible, qui n'exploitent ni leur expérience ni leur capacité d'analyse, et qui pourraient être résolues sans intervention manuelle. La seconde est d'ordre commercial. La friction ressentie à ce stade du parcours affecte directement la satisfaction, dans un secteur où le changement d'opérateur est devenu simple et où l'attrition constitue un enjeu majeur.

Une automatisation naïve de ces échanges ne résout cependant qu'une partie du problème, et en introduit une autre. Un système conversationnel adossé à un modèle de langue produit un texte plausible, ce qui n'équivaut pas à un texte exact. Sur un domaine documentaire, une réponse inexacte engendre une insatisfaction. Sur une opération qui engage un compte client, elle engendre un incident : un paiement passé pour un montant erroné, une ligne réactivée sans autorisation, une option souscrite à l'insu du titulaire. La difficulté ne se limite donc pas à faire comprendre et répondre une machine. Elle consiste à obtenir un comportement dont on puisse démontrer, après coup, qu'il était correct.

C'est cette double exigence qui définit la problématique traitée dans ce projet. Il s'agit de résoudre les demandes courantes en conversation naturelle, dans un rythme temps réel, tout en garantissant que chaque action ayant une conséquence pour le client demeure encadrée,

justifiée et vérifiable. La première partie de l'exigence relève de la performance et de la qualité conversationnelle. La seconde relève de la maîtrise du comportement et de la traçabilité. Aucune des deux ne peut être sacrifiée au bénéfice de l'autre.

1.2.3 Solution proposée

La solution que nous proposons est une plateforme conversationnelle auto hébergée, capable de prendre en charge de bout en bout les demandes fréquentes d'un client d'opérateur télécom, en voix comme en texte, en français, en arabe et en anglais.

L'idée directrice tient en une séparation nette entre deux responsabilités que les systèmes conversationnels confondent habituellement. D'un côté, la compréhension du langage, la conduite du dialogue et la formulation de la réponse, pour lesquelles un modèle de langue est l'outil approprié. De l'autre, la décision d'agir sur le compte d'un client, qui ne relève pas du modèle mais d'un ensemble de règles métier explicites, évaluées de manière déterministe et indépendantes de toute interprétation. Le modèle propose, les règles disposent.

Autour de cette séparation, la plateforme organise quatre garanties complémentaires. Les réponses factuelles sont ancrées dans la documentation propre à l'opérateur plutôt que dans la mémoire du modèle, et le système admet explicitement son ignorance lorsque cette documentation ne contient pas la réponse. Toute action sensible est précédée d'une vérification d'identité et suivie d'un verdict explicite, dont le motif est conservé. Chaque acte conséquent est inscrit dans un registre dont l'intégrité peut être contrôlée ultérieurement. Enfin, lorsque l'autonomie n'est pas appropriée, la conversation est transmise à un conseiller humain accompagnée du dossier complet de ce qui a été compris, tenté et décidé.

Ce dernier point mérite d'être souligné, car il inverse une hypothèse courante. Le transfert vers un humain n'est pas traité comme l'échec du système automatique, mais comme l'un de ses résultats normaux, prévu et outillé au même titre que la résolution autonome.

1.2.4 Objectifs du projet

Les objectifs énoncés ci après structurent la suite du rapport. Chacun se traduit au chapitre suivant en besoins fonctionnels ou non fonctionnels, et trouve au chapitre de réalisation la description du mécanisme qui le satisfait.

- Résoudre de façon autonome les demandes courantes d'un client, en dialogue parlé naturel, sans passage par une arborescence de menus.
- Tenir un rythme conversationnel temps réel, en gérant correctement les interruptions du client et les silences de fin de tour de parole.

- Ancrer chaque réponse factuelle dans la documentation de l'opérateur, et faire admettre au système son ignorance plutôt que produire une réponse plausible mais infondée.
- Soumettre chaque action sensible à des règles métier déterministes produisant un verdict explicite, assorti de l'identifiant de la règle qui l'a motivé.
- Garantir qu'une action approuvée est exécutée une fois et une seule, même en cas de reprise ou de tentative concurrente.
- Rendre vérifiable après coup tout acte ayant une conséquence pour le client, au moyen d'un registre dont l'altération est détectable.
- Transférer la conversation à un conseiller humain, ou négocier un rappel lorsque aucun conseiller n'est disponible, en transmettant dans les deux cas le contexte complet de l'échange.
- Conserver la maîtrise de la plateforme en privilégiant les composants ouverts et l'hébergement interne partout où cela préserve le contrôle sur les données et sur l'évolution du système.
- Offrir aux équipes d'exploitation les moyens de superviser, d'auditer et de faire évoluer le comportement du système sans intervention sur le code.

Ces objectifs sont volontairement formulés en termes de propriétés vérifiables plutôt qu'en termes de fonctionnalités. Cette formulation nous engage : elle rend possible, au chapitre de réalisation, la démonstration que chacun d'eux est effectivement tenu.

1.3 Étude de l'existant

Avant de concevoir notre solution, nous avons examiné ce qui existe déjà, à deux niveaux. Le premier niveau est celui du dispositif que les opérateurs exploitent aujourd'hui. Le second est celui des plateformes commerciales d'automatisation conversationnelle qui se positionnent sur ce marché.

1.3.1 Le dispositif en place chez les opérateurs

Le dispositif historique combine un serveur vocal interactif, une équipe de conseillers outillée par des scripts, et un système de gestion de tickets pour les demandes qui ne se résolvent pas au premier contact. Sa robustesse tient à sa simplicité : le parcours est entièrement déterminé à l'avance et son comportement est parfaitement prévisible. Cette même propriété constitue sa limite. Une arborescence de menus ne peut couvrir que les cas anticipés lors de sa conception, elle impose au client de traduire son besoin dans le vocabulaire du système, et elle ne transporte pratiquement aucune information d'une étape à la suivante.

1.3.2 Les plateformes commerciales d'automatisation conversationnelle

Trois acteurs européens structurent aujourd'hui ce segment. Nous les avons retenus parce qu'ils couvrent le même besoin que notre projet et qu'ils représentent trois approches différentes du problème.

1.3.2.1 PolyAI

PolyAI est un éditeur britannique d'assistants vocaux destinés à l'automatisation du service client. La plateforme prend en charge les appels entrants et sortants, le débordement de file d'attente, le routage par intention et l'escalade vers un conseiller, avec une prise en charge multilingue étendue et des intégrations vers les systèmes de gestion de la relation client, les plateformes de réservation, les systèmes de paiement et les logiciels de centre de contact [17]. Ses points forts reconnus sont la qualité de la voix synthétisée et la gestion des tours de parole, y compris les interruptions et les corrections en cours d'énoncé.

La solution est livrée comme un service géré. Ce choix de distribution simplifie considérablement le déploiement, mais il place la chaîne de raisonnement interne hors du périmètre de l'équipe cliente. La décomposition en agents spécialisés, la stratégie de recherche documentaire et le contrôle granulaire des politiques métier ne constituent pas des surfaces de conception exposées, et l'adaptation à un système d'information particulier passe par une intégration conduite par l'éditeur.

1.3.2.2 Cognigy

Cognigy est une plateforme allemande d'intelligence artificielle conversationnelle pour l'entreprise, qui couvre les canaux voix, dialogue en ligne et messagerie, avec des connecteurs natifs vers les principaux environnements de centre de contact. Le produit a évolué vers des capacités agentiques, avec des agents capables de collaborer et de partager une mémoire contextuelle lors des passages de relais [18]. Son environnement de conception en low-code permet à des profils non techniques de construire et de faire évoluer des parcours, ce qui accélère nettement le déploiement initial.

Ce même choix de conception constitue la contrepartie. Un éditeur visuel définit implicitement l'ensemble des compositions possibles. La profondeur de personnalisation reste donc bornée par ce que l'outil expose, notamment sur la logique d'orchestration, sur la définition fine des agents spécialisés et sur l'articulation entre la couche de raisonnement et des politiques métier maintenues à l'extérieur de la plateforme.

1.3.2.3 Parloa

Parloa est une plateforme européenne d'automatisation vocale conçue spécifiquement pour les opérations de centre de contact. Elle couvre le cycle de vie complet des agents, de la définition à l'optimisation, avec une gouvernance de production comprenant le versionnement et des garde-fous appliqués aux instructions du modèle, ainsi qu'une téléphonie opérée en propre [19]. Son alignement sur les indicateurs propres aux centres d'appels et sa rapidité de mise en service constituent ses principaux atouts.

Le produit est positionné comme une offre verticalement intégrée plutôt que comme une architecture ouverte. Cette intégration explique sa cohérence de bout en bout, et restreint dans le même mouvement la possibilité pour une équipe externe de composer ses propres agents, de définir sa propre stratégie de récupération documentaire et d'appliquer ses propres règles déterministes sur les actions sensibles.

1.3.3 Synthèse comparative

Le tableau 1.1 récapitule les avantages et les inconvénients de chacun de ces systèmes au regard du besoin exprimé au paragraphe précédent.

Système existant	Avantages	Inconvénients
Serveur vocal interactif et scripts de conseillers	Comportement entièrement prévisible. Coût de mise en oeuvre faible. Aucune dépendance à un modèle de langue.	Ne couvre que les cas anticipés. Impose au client le vocabulaire du système. Ne transporte pas le contexte d'une étape à l'autre. Génère attente, réidentifications et transferts.
PolyAI	Qualité vocale élevée. Gestion fine des tours de parole. Couverture multilingue étendue. Intégrations métier éprouvées.	Service géré : la chaîne de raisonnement n'est pas exposée. Décomposition agentique et stratégie documentaire non maîtrisables. Adaptation dépendante de l'éditeur. Auto hébergement non proposé.
Cognigy	Couverture multicanale. Capacités agentiques avec mémoire partagée. Conception en low-code accessible aux profils métier. Déploiement initial rapide.	Personnalisation bornée par l'éditeur visuel. Orchestration et politiques métier difficilement externalisables. Contrôle limité sur la couche de récupération documentaire.
Parloa	Conception centrée sur la voix. Gestion du cycle de vie des agents. Gouvernance de production et versionnement. Téléphonie opérée en propre.	Offre verticalement intégrée. Composition d'agents propres restreinte. Règles déterministes sur actions sensibles non maîtrisables par l'équipe cliente.

TABLE 1.1 – AVANTAGES ET INCONVÉNIENTS DES SYSTÈMES EXISTANTS

Trois manques reviennent d'un système à l'autre, et ce sont eux qui définissent l'espace dans lequel notre proposition s'inscrit. Le premier est l'absence de surface de contrôle explicite sur la décision : aucune de ces plateformes n'expose un mécanisme de règles déterministes que l'équipe cliente définisse et fasse évoluer elle-même, alors que ce sont ces règles qui protègent les opérations engageant un compte client. Le deuxième est la maîtrise limitée de l'ancrage documentaire, qui conditionne pourtant l'exactitude des réponses. Le troisième est l'impossibilité de conserver l'ensemble sous contrôle interne, ce qui pèse lorsque les données traitées relèvent de la vie privée des abonnés.

Le tableau 1.2 positionne la solution proposée sur ces critères. Nous y reviendrons au chapitre de réalisation, où chacune de ces lignes sera rattachée au mécanisme qui la met en oeuvre.

Critère	PolyAI	Cognigy	Parloa	Solution proposée
Interaction vocale temps réel	Oui	Oui	Oui	Oui
Décomposition en agents spécialisés maîtrisée par l'équipe	Non	Partielle	Non	Oui
Ancrage documentaire configurable de bout en bout	Non	Partielle	Non	Oui
Règles déterministes explicites sur les actions sensibles	Non exposées	Limitées	Limitées	Explicites
Traçabilité vérifiable des décisions	Non exposée	Partielle	Partielle	Registre vérifiable
Spécialisation métier télécom	Générique	Générique	Générique	Native
Auto hébergement possible	Non	Partiel	Non	Oui

TABLE 1.2 – POSITIONNEMENT DE LA SOLUTION PROPOSÉE PAR RAPPORT AUX PLATEFORMES ÉTUDIÉES

1.4 Chronologie du projet

Le projet s'est déroulé de mars à août 2026. Nous l'avons organisé en six phases successives, chacune produisant un ensemble cohérent et démontrable plutôt qu'un simple lot de travaux. La figure 1.2 présente le diagramme de Gantt correspondant, et le tableau 1.3 précise ce que chaque phase a produit.




FIGURE 1.2 – DIAGRAMME DE GANTT DU PROJET

Période	Phase	Résultat principal
Mars	Cadrage et étude	Compréhension du domaine, étude de l'existant, spécification des besoins, choix de l'architecture cible et des principes structurants.
Avril	Fondations	Mise en place du socle applicatif, du modèle de données, de la séparation en contextes métier et des interfaces entre couches.
Mai	Chaîne vocale temps réel	Premier échange parlé de bout en bout, gestion des tours de parole et des interruptions, chaînes de repli entre fournisseurs.
Juin	Décision et exécution	Services métier, chaîne décision, politique et exécution, exécution idempotente des actions sensibles, registre d'audit.
Juillet	Connaissance et intégration	Chaîne d'ingestion et de récupération documentaire, intégration au système de gestion de tickets, escalade et planification de rappels.
Août	Interfaces et durcissement	Portail client, console d'administration, observabilité, campagne de vérification, corrections et rédaction du présent rapport.

TABLE 1.3 – PHASES DU PROJET ET RÉSULTATS ASSOCIÉS

Ces phases se recouvrent partiellement. Plusieurs travaux engagés lors d'une phase se sont poursuivis pendant la suivante, notamment l'optimisation de la chaîne vocale, qui a fait l'objet d'ajustements jusqu'aux dernières semaines à mesure que les mesures de latence se précisaient.

1.5 Processus de développement

1.5.1 Le choix d'un cycle itératif et incrémental

Nous avons conduit ce projet selon un cycle de vie itératif et incrémental. Ce choix ne relève pas d'une préférence méthodologique mais d'une contrainte propre au sujet.

Un cycle séquentiel suppose que le comportement attendu du logiciel puisse être spécifié complètement avant d'être construit. Cette hypothèse ne tenait pas ici. Une part importante des décisions de conception dépendait de grandeurs qui n'existent qu'une fois le composant en fonctionnement : le temps réellement consommé par une étape de la chaîne vocale, la qualité effective d'une recherche documentaire sur un corpus multilingue, le comportement d'un modèle face à une instruction ambiguë. Ces grandeurs ne se déduisent pas d'une étude préalable, elles se mesurent. Le développement devait donc procéder par constructions succes-

sives, chacune suffisamment complète pour être mesurée, puis conservée, corrigée ou remplacée selon le résultat obtenu.

1.5.2 La forme concrète des itérations

Chaque itération a pris la forme d'un incrément numéroté, associé à une branche de développement dédiée et à un document décrivant son contenu, son intention et son résultat. Le projet compte à son terme cent douze incréments de ce type, pour deux cent soixante validations enregistrées dans l'historique du dépôt.

Cette granularité fine répond à un besoin précis. Un incrément qui isole une modification unique reste réversible : si une mesure ultérieure invalide un choix, il est possible de revenir sur ce choix sans défaire ce qui a été construit autour. Nous avons appliqué cette règle avec une rigueur particulière aux mécanismes que nous qualifions de porteurs, ceux dont dépend une garantie du système. Une modification touchant l'un d'eux fait l'objet d'un incrément à part entière, accompagné de la justification du changement.

La figure 1.3 illustre le cycle appliqué à chaque incrément.




FIGURE 1.3 – CYCLE ITÉRATIF ET INCRÉMENTAL APPLIQUÉ AU PROJET

1.5.3 Vérification continue

La mesure occupant une place centrale dans ce cycle, elle devait être disponible en permanence et non à l'issue du développement. Nous avons donc constitué progressivement un ensemble de vérifications automatisées couvrant les comportements que le système doit garantir quelles que soient ses évolutions ultérieures : le caractère déterministe des décisions, l'exécution unique des actions sensibles, le refus de répondre en l'absence de source documentaire, le comportement en cas de défaillance d'un fournisseur externe, et le respect de la langue de

l'échange. Le chapitre de réalisation revient en détail sur cet ensemble et sur ce que chaque famille de vérifications protège.

Conclusion

Ce chapitre a établi le cadre du projet. Nous avons présenté la société d'accueil, puis délimité le domaine d'application et la contrainte de temps réel qui le gouverne. L'analyse de la problématique a fait apparaître une exigence double : traiter les demandes courantes en conversation naturelle, et garantir simultanément que toute action engageant un client demeure encadrée et vérifiable. L'étude de l'existant a montré que les dispositifs en place et les plateformes commerciales disponibles répondent partiellement à la première exigence et laissent la seconde hors du contrôle de l'équipe cliente. Nous avons enfin exposé la chronologie du projet et le cycle itératif et incrémental qui a permis de conduire des choix de conception dépendant de mesures.

Le chapitre suivant traduit ces objectifs en spécifications. Nous y identifions les acteurs du système, nous formulons les besoins fonctionnels et non fonctionnels qui en découlent, et nous détaillons les principaux cas d'utilisation qui structureront ensuite la conception.

Spécification des besoins

Sommaire

2.1	Identification des acteurs	17
2.1.1	Acteurs principaux	17
2.1.2	Acteurs secondaires	18
2.2	Besoins fonctionnels	19
2.2.1	Conduite de la conversation	19
2.2.2	Construction du contexte client	19
2.2.3	Ancrage documentaire des réponses	19
2.2.4	Traitement des actions sensibles	19
2.2.5	Gestion des tickets	20
2.2.6	Escalade et rappel	20
2.2.7	Espace client	20
2.2.8	Supervision et administration	20
2.2.9	Récapitulatif	21
2.3	Besoins non fonctionnels	21
2.3.1	Performance et comportement temps réel	21
2.3.2	Fiabilité et disponibilité	22
2.3.3	Robustesse et tolérance aux pannes	22
2.3.4	Sécurité et confidentialité	22
2.3.5	Traçabilité et auditabilité	22
2.3.6	Extensibilité et maintenabilité	22
2.3.7	Passage à l'échelle	23
2.3.8	Interopérabilité et portabilité	23
2.3.9	Testabilité	23
2.3.10	Ergonomie	23
2.3.11	Récapitulatif	23
2.4	Diagrammes de cas d'utilisation	24
2.4.1	Diagramme de cas d'utilisation général	24
2.4.2	Cas d'utilisation : obtenir une réponse documentaire	25
2.4.3	Cas d'utilisation : exécuter une opération sensible	27
2.4.4	Cas d'utilisation : escalader vers un conseiller humain	29

Introduction

Le chapitre précédent a fixé les objectifs du projet. Ce chapitre les traduit en spécifications exploitables. Nous identifions d'abord les acteurs qui interagissent avec la plateforme, car c'est de leurs attentes respectives que découlent les fonctionnalités attendues. Nous formulons ensuite les besoins fonctionnels, puis les besoins non fonctionnels qui fixent les critères de qualité auxquels le système doit satisfaire. Le chapitre se termine par les cas d'utilisation, présentés sous forme de diagrammes puis détaillés pour les trois plus déterminants d'entre eux.

2.1 Identification des acteurs

Un acteur désigne une entité extérieure au système qui interagit avec lui pour en obtenir un service. Nous distinguons les acteurs principaux, qui utilisent directement la plateforme, des acteurs secondaires, qui sont des systèmes tiers sollicités par elle.

2.1.1 Acteurs principaux

Quatre acteurs principaux ont été retenus. Les trois derniers correspondent à une hiérarchie de responsabilités croissantes, chaque niveau disposant des droits du niveau inférieur augmentés des siens.

- **Le client.** Abonné de l'opérateur. Il s'adresse à la plateforme pour obtenir une information ou faire réaliser une opération sur sa ligne. Il interagit principalement par la voix, et accède par ailleurs à un portail où il retrouve sa situation, ses demandes et l'historique de ses échanges.
- **Le conseiller.** Agent du service client. Il prend en charge les conversations qui lui sont transmises par la plateforme et traite les demandes de rappel qui lui sont attribuées. Il dispose du niveau de droits le plus bas parmi les profils internes.
- **Le superviseur.** Responsable de la supervision opérationnelle. Il observe l'activité de la plateforme, consulte les conversations et les décisions prises, suit les indicateurs et organise la disponibilité des conseillers.
- **L'administrateur.** Responsable de la configuration et de la gouvernance du système. Il gère les comptes, les règles métier, les référentiels et la base documentaire, et dispose des moyens de contrôle de l'intégrité des enregistrements.

2.1.2 Acteurs secondaires

La plateforme ne détient pas les données métier de l'opérateur : elle les consulte et agit sur elles au travers de systèmes tiers, qui constituent autant d'acteurs secondaires.

- **Le système de gestion de tickets.** Il demeure la référence pour tout ce qui concerne les tickets. La plateforme y crée, consulte, met à jour et clôture les tickets des clients.
- **Les systèmes métier de l'opérateur.** Ils portent la facturation et les soldes, la supervision du réseau et le provisionnement des services. La plateforme les interroge pour construire le contexte du client et leur adresse les actions approuvées.
- **Le service de notification.** Il achemine les confirmations et les avis destinés aux clients comme aux conseillers.

Le tableau 2.1 récapitule le rôle de chaque acteur et son mode d'interaction avec la plateforme.

Acteur	Type	Responsabilité principale	Mode d'interaction
Client	Principal	Exprimer une demande et obtenir sa résolution	Conversation vocale ou textuelle, portail client
Conseiller	Principal	Traiter les conversations transmises et les rappels attribués	Console de supervision, reprise d'appel
Superviseur	Principal	Observer l'activité, suivre les indicateurs, organiser les disponibilités	Console de supervision
Administrateur	Principal	Configurer les règles, les référentiels et la base documentaire, contrôler l'intégrité	Console d'administration
Système de gestion de tickets	Secondaire	Détenir la référence des tickets	Interface de programmation applicative
Systèmes métier de l'opérateur	Secondaire	Détenir les données de facturation, de réseau et de provisionnement	Interfaces de service internes
Service de notification	Secondaire	Acheminer les confirmations et les avis	Interface de service interne

TABLE 2.1 – ACTEURS DE LA PLATEFORME ET MODES D'INTERACTION

2.2 Besoins fonctionnels

Les besoins fonctionnels décrivent ce que le système doit faire. Nous les avons regroupés par domaine et identifiés individuellement, afin que chacun puisse être suivi jusqu'au chapitre de réalisation.

2.2.1 Conduite de la conversation

La plateforme doit permettre au client d'engager un échange parlé ou écrit et de le mener à son terme sans contrainte de formulation. Elle doit conserver le fil de la conversation d'un tour de parole au suivant, de sorte que le client n'ait jamais à répéter une information déjà donnée. Elle doit identifier l'intention exprimée et, lorsque la demande demeure ambiguë, poser une question de clarification unique et précise plutôt qu'une série de questions fermées. Elle doit accepter d'être interrompue à tout moment et reprendre la main sans perdre l'état de l'échange. Elle doit enfin pouvoir changer de langue en cours de conversation à la demande du client.

2.2.2 Construction du contexte client

La plateforme doit reconstituer automatiquement la situation du client au moment où il s'adresse à elle : son profil, son abonnement, sa situation de facturation, ses demandes récentes et l'historique de ses échanges antérieurs. Cette reconstitution doit être conditionnelle plutôt que systématique, chaque élément n'étant sollicité que lorsque la nature de la demande le justifie, afin de ne pas alourdir inutilement le traitement.

2.2.3 Ancrage documentaire des réponses

La plateforme doit répondre aux questions documentaires en s'appuyant sur la documentation propre à l'opérateur, et non sur les connaissances générales du modèle de langue. Lorsque cette documentation ne contient pas de réponse à la question posée, le système doit le signaler explicitement au client plutôt que produire une réponse vraisemblable. La base documentaire doit pouvoir être alimentée et mise à jour par l'administrateur sans intervention sur le code.

2.2.4 Traitement des actions sensibles

Toute opération engageant le compte du client doit être précédée d'une vérification d'identité, puis soumise à un jeu de règles métier produisant un verdict explicite. Ce verdict doit prendre l'une des trois valeurs suivantes : autorisée, refusée, ou à transmettre à un conseiller. Il doit être accompagné de l'identifiant de la règle qui l'a motivé et d'une justification lisible.

Une action autorisée doit être exécutée une fois et une seule, y compris en cas de reprise ou de tentative concurrente. Le résultat doit être confirmé verbalement au client.

2.2.5 Gestion des tickets

La plateforme doit pouvoir consulter les tickets existants d'un client, en créer de nouveaux, les mettre à jour et les clôturer lorsque le problème est résolu. Elle doit connaître l'historique des tickets du client afin d'éviter la création de doublons et de tenir compte des difficultés déjà signalées.

2.2.6 Escalade et rappel

La plateforme doit reconnaître les situations qui appellent une intervention humaine, qu'elles résultent d'une règle métier, d'une demande explicite du client ou d'un mécontentement persistant. Lorsqu'un conseiller est disponible, elle doit lui transférer la conversation. Dans le cas contraire, elle doit proposer un rappel, négocier un créneau compatible avec les disponibilités réelles des conseillers, réserver ce créneau et en informer le client. Dans les deux cas, le conseiller concerné doit recevoir le dossier de l'échange.

2.2.7 Espace client

Le client doit disposer d'un espace personnel lui permettant de consulter son profil, sa situation de facturation, ses demandes, ses rappels programmés et l'historique de ses conversations. Il doit également pouvoir consulter et effacer les informations que la plateforme conserve de ses échanges antérieurs, et n'accéder en aucun cas aux données d'un autre client.

2.2.8 Supervision et administration

Les profils internes doivent disposer des moyens d'observer et de gouverner le système. Cela recouvre la consultation des conversations et de leurs transcriptions, l'inspection des décisions et des verdicts rendus, le suivi des indicateurs d'activité, la gestion des conseillers et de leurs disponibilités, l'administration des règles métier et des référentiels, la gestion de la base documentaire et le contrôle de l'intégrité du registre des opérations.

2.2.9 Récapitulatif

La figure 2.1 récapitule ces besoins sous forme de carte, un bloc par domaine. Cette vue d'ensemble sert de repère pour la suite du rapport : la conception du chapitre suivant s'organise autour des mêmes domaines.




FIGURE 2.1 – CARTE DES BESOINS FONCTIONNELS PAR DOMAINE

2.3 Besoins non fonctionnels

Les besoins non fonctionnels expriment les propriétés de qualité attendues du système. Nous avons écarté les formulations générales pour ne retenir que les exigences réellement structurantes pour ce projet, chacune étant rattachée à la propriété qu'elle impose à l'architecture.

2.3.1 Performance et comportement temps réel

C'est l'exigence dominante. Un échange parlé n'est perçu comme naturel que si la réponse survient dans le rythme d'une conversation ordinaire. Cette exigence se décline en un budget de temps réparti entre les étapes du traitement : détection de fin de tour de parole, transcription, raisonnement, récupération documentaire, synthèse vocale et acheminement. Aucune étape ne peut être considérée isolément, puisque le dépassement de l'une consomme la marge de toutes les autres.

2.3.2 Fiabilité et disponibilité

La défaillance d'un fournisseur externe ne doit pas interrompre une conversation en cours. Le système doit prévoir, pour chaque étape dépendant d'un service tiers, une solution de repli capable de prendre le relais sans que le client en perçoive autre chose qu'une variation de qualité.

2.3.3 Robustesse et tolérance aux pannes

Le système doit continuer à fonctionner de manière dégradée mais correcte lorsqu'un composant non essentiel à l'échange devient indisponible. En particulier, une défaillance de la couche d'enregistrement ne doit jamais compromettre la conversation elle-même. À l'inverse, aucune défaillance ne doit être silencieuse : elle doit rester visible pour le diagnostic.

2.3.4 Sécurité et confidentialité

L'accès aux fonctions du système doit être conditionné à une authentification, puis à une autorisation fondée sur le rôle. Un client ne doit pouvoir accéder qu'à ses propres données. Les opérations sensibles doivent exiger une vérification d'identité distincte de la simple ouverture de session. Les données personnelles doivent être masquées partout où leur valeur exacte n'est pas nécessaire. En l'absence d'information d'autorisation exploitable, le système doit refuser plutôt qu'autoriser.

2.3.5 Traçabilité et auditabilité

Tout acte ayant une conséquence pour un client doit laisser une trace exploitable indiquant qui a agi, sur quoi, à quel moment, avec quel résultat et en vertu de quelle règle. Ces traces doivent être organisées de telle sorte qu'une modification rétroactive soit détectable et non simplement découragée.

2.3.6 Extensibilité et maintenabilité

Le remplacement d'un fournisseur de transcription, de synthèse vocale ou de modèle de langue ne doit pas se propager au-delà de la couche qui l'intègre. L'ajout d'un domaine métier ou d'une nouvelle capacité ne doit pas imposer la révision des composants existants. Les règles métier doivent rester indépendantes de toute bibliothèque tierce.

2.3.7 Passage à l'échelle

La plateforme doit prendre en charge plusieurs conversations simultanées, chacune disposant de son propre état, sans interférence entre elles. Les opérations concurrentes menées au sein d'une même conversation doivent être isolées les unes des autres.

2.3.8 Interopérabilité et portabilité

Les échanges avec les systèmes de l'opérateur et avec le système de gestion de tickets doivent reposer sur des interfaces standard. L'ensemble doit être déployable sous forme de conteneurs, indépendamment du système hôte.

2.3.9 Testabilité

Les composants portant une garantie du système doivent pouvoir être vérifiés isolément et de manière reproductible. Cette exigence conditionne directement la conception : elle impose que la logique de décision soit exempte d'effets de bord.

2.3.10 Ergonomie

L'interaction principale étant vocale, la qualité perçue tient à la nature de l'échange : formulations brèves, absence d'énumérations lues à voix haute, prise en compte immédiate des interruptions. Les interfaces destinées aux profils internes doivent privilégier la lisibilité de l'information opérationnelle.

2.3.11 Récapitulatif

Le tableau 2.2 associe à chaque besoin non fonctionnel la propriété architecturale qui en découle.

Réf.	Exigence	Propriété imposée à l'architecture
BNF01	Performance temps réel	Budget de latence réparti par étape et mesuré de bout en bout.
BNF02	Fiabilité et disponibilité	Chaîne de repli pour chaque dépendance externe de la chaîne vocale.
BNF03	Robustesse	Découplage de l'enregistrement et de la conversation ; aucune défaillance silencieuse.
BNF04	Sécurité et confidentialité	Authentification, autorisation par rôle, isolation des données, vérification d'identité renforcée, masquage, refus par défaut.
BNF05	Traçabilité	Enregistrement de chaque acte conséquent et détection des altérations rétroactives.
BNF06	Extensibilité	Dépendances externes confinées derrière des interfaces internes.
BNF07	Maintenabilité	Règles métier indépendantes de toute bibliothèque tierce.
BNF08	Passage à l'échelle	État par conversation et isolation des opérations concurrentes.
BNF09	Interopérabilité	Interfaces standard vers les systèmes tiers.
BNF10	Portabilité	Déploiement conteneurisé de l'ensemble des composants.
BNF11	Testabilité	Logique de décision déterministe et exempte d'effets de bord.
BNF12	Ergonomie	Réponses brèves adaptées à l'oral et prise en compte immédiate des interruptions.

TABLE 2.2 – BESOINS NON FONCTIONNELS ET PROPRIÉTÉS ARCHITECTURALES ASSOCIÉES

2.4 Diagrammes de cas d'utilisation

2.4.1 Diagramme de cas d'utilisation général

Le diagramme de la figure 2.2 présente une vue d'ensemble des cas d'utilisation de la plateforme et de leur répartition entre les acteurs. Le client y accède aux cas relevant de la conversation et de son espace personnel. Les profils internes accèdent aux cas de supervision et d'administration, selon la hiérarchie de droits établie plus haut. Les systèmes tiers apparaissent en acteurs secondaires des cas qui les sollicitent.

Trois cas d'utilisation structurent l'ensemble du système et méritent un traitement détaillé. Le premier couvre le trajet complet d'une question documentaire, de la parole du client jusqu'à la réponse ancrée dans la documentation. Le deuxième couvre l'exécution d'une opération enga-




FIGURE 2.2 – DIAGRAMME DE CAS D’UTILISATION GÉNÉRAL DE LA PLATEFORME

geant le compte du client, qui concentre l’essentiel des garanties de sûreté de la plateforme. Le troisième couvre le passage à un conseiller humain, qui constitue la frontière entre l’autonomie du système et l’intervention humaine. Chacun fait l’objet d’un diagramme, d’une description textuelle et d’un diagramme de séquence système décrivant son scénario nominal.

2.4.2 Cas d’utilisation : obtenir une réponse documentaire

2.4.2.1 Diagramme du cas

Ce cas d’utilisation, présenté à la figure 2.3, décrit la situation la plus fréquente : le client pose une question portant sur les offres, les procédures ou les conditions de service, et attend une réponse exacte.

2.4.2.2 Description textuelle

Le tableau 2.3 détaille le déroulement de ce cas.




FIGURE 2.3 – DIAGRAMME DU CAS D'UTILISATION OBTENIR UNE RÉPONSE DOCUMENTAIRE

Cas d'utilisation : obtenir une réponse documentaire	
Acteur principal	Client
Acteurs secondaires	Aucun
Objectif	Obtenir une réponse exacte à une question portant sur les offres, les procédures ou les conditions de service.
Préconditions	Une conversation est établie entre le client et la plateforme. La base documentaire est disponible et indexée.
Postconditions	Le client a reçu soit une réponse ancrée dans la documentation, soit l'indication explicite que l'information n'est pas disponible. L'échange est enregistré.
Scénario nominal	1. Le client formule sa question à l'oral. 2. Le système transcrit la parole et identifie l'intention documentaire. 3. Le système interroge la base documentaire avec une requête dérivée de la question. 4. Le système reçoit les passages pertinents accompagnés de leur source. 5. Le système formule une réponse brève, fondée uniquement sur ces passages. 6. Le système énonce la réponse et propose au client d'en obtenir le détail. 7. L'échange est consigné dans le journal de conversation.
Alternative A : demande ambiguë	À l'étape 2, si l'intention ne peut être déterminée avec certitude, le système pose une question de clarification unique, puis reprend à l'étape 1.
Alternative B : absence de réponse	À l'étape 4, si aucun passage ne satisfait les critères de pertinence, le système indique au client qu'il ne dispose pas de cette information et lui propose une prise en charge alternative. Le cas se termine.
Alternative C : interruption	À toute étape postérieure à 5, le client peut interrompre l'énoncé. Le système cesse de parler immédiatement et traite le nouveau tour de parole.

TABLE 2.3 – DESCRIPTION TEXTUELLE DU CAS OBTENIR UNE RÉPONSE DOCUMENTAIRE

2.4.2.3 Diagramme de séquence système

La figure 2.4 représente le scénario nominal sous forme d'échanges entre le client et le système, considéré ici comme une boîte noire.




FIGURE 2.4 – DIAGRAMME DE SÉQUENCE SYSTÈME DU CAS OBTENIR UNE RÉPONSE DOCUMENTAIRE

2.4.3 Cas d'utilisation : exécuter une opération sensible

2.4.3.1 Diagramme du cas

Ce cas, présenté à la figure 2.5, concentre les garanties de sûreté de la plateforme. Il couvre toute opération produisant un effet sur le compte du client, qu'il s'agisse d'un règlement, d'un report d'échéance, d'une recharge, d'un changement de forfait ou d'une opération sur la carte SIM ou sur la ligne.

2.4.3.2 Description textuelle

Le tableau 2.4 détaille ce cas, qui est le plus contraint de la plateforme.




FIGURE 2.5 – DIAGRAMME DU CAS D'UTILISATION EXÉCUTER UNE OPÉRATION SENSIBLE

Cas d'utilisation : exécuter une opération sensible	
Acteur principal	Client
Acteurs secondaires	Systèmes métier de l'opérateur
Objectif	Faire exécuter une opération produisant un effet sur le compte du client, avec la garantie qu'elle est autorisée, exécutée une seule fois et consignée.
Préconditions	Une conversation est établie. Le client est rattaché à un compte. L'opération demandée figure parmi les opérations reconnues par le système.
Postconditions	L'opération a été exécutée et confirmée, ou refusée avec un motif, ou transmise à un conseiller. Dans tous les cas, un verdict motivé et une trace vérifiable ont été enregistrés.
Scénario nominal	1. Le client exprime la demande d'opération. 2. Le système récapitule l'opération et sollicite une confirmation verbale explicite. 3. Le client confirme. 4. Le système vérifie l'identité du client si cette vérification n'est pas déjà valide. 5. Le système constitue le contexte de la décision à partir de la situation vérifiée du client. 6. Le système soumet l'opération aux règles métier, qui rendent un verdict motivé. 7. Le verdict étant favorable, le système transmet l'opération au système métier concerné, en garantissant qu'une reprise éventuelle ne produira pas de seconde exécution. 8. Le système consigne l'opération et son verdict dans le registre. 9. Le système confirme le résultat au client à l'oral.
Alternative A : identité non confirmée	À l'étape 4, si la vérification échoue après le nombre d'essais autorisé, l'opération est abandonnée, le client en est informé, et le refus est consigné.
Alternative B : opération refusée	À l'étape 6, si le verdict est défavorable, le système énonce au client le motif du refus dans des termes compréhensibles. L'opération n'est pas transmise. Le verdict est consigné.

2.4.3.3 Diagramme de séquence système

La figure 2.6 représente le scénario nominal de ce cas. Elle met en évidence la confirmation verbale, la vérification d'identité et le caractère bloquant du verdict, qui conditionne toute transmission au système métier.




FIGURE 2.6 – DIAGRAMME DE SÉQUENCE SYSTÈME DU CAS EXÉCUTER UNE OPÉRATION SENSIBLE

2.4.4 Cas d'utilisation : escalader vers un conseiller humain

2.4.4.1 Diagramme du cas

Ce cas, présenté à la figure 2.7, décrit le passage de la prise en charge automatique à la prise en charge humaine. Il peut être déclenché par une règle métier, par une demande explicite du client ou par la constatation d'un mécontentement persistant au fil de la conversation.

2.4.4.2 Description textuelle

Le tableau 2.5 détaille ce cas.




FIGURE 2.7 – DIAGRAMME DU CAS D’UTILISATION ESCALADER VERS UN CONSEILLER HUMAIN

Cas d’utilisation : escalader vers un conseiller humain	
Acteur principal	Client
Acteurs secondaires	Conseiller, service de notification
Objectif	Confier la demande à un conseiller humain, immédiatement si possible, à une échéance convenue sinon, sans perte du contexte déjà constitué.
Préconditions	Une conversation est établie. Une condition d’escalade est satisfaite.
Postconditions	La conversation a été transférée à un conseiller, ou un rappel a été réservé sur un créneau réel et le conseiller concerné en a été avisé. Le dossier de l’échange est disponible dans les deux cas.
Scénario nominal	1. Le système constate la condition d’escalade et l’annonce au client. 2. Le système constitue le dossier de l’échange : demande exprimée, éléments compris, opérations tentées et verdicts rendus. 3. Le système recherche un conseiller disponible correspondant au domaine de la demande. 4. Un conseiller étant disponible, le système le réserve. 5. Le système transfère l’appel vers ce conseiller. 6. Le conseiller prend en charge la conversation, muni du dossier.
Alternative A : aucun conseiller disponible	À l’étape 3, si aucun conseiller n’est disponible, le système en informe le client et lui propose un rappel. Il présente des créneaux issus des disponibilités réelles, convient d’un créneau avec le client, le réserve, puis confirme l’horaire retenu. Le conseiller concerné est avisé avec le dossier.
Alternative B : échec du transfert	À l’étape 5, si le transfert échoue, le conseiller réservé est libéré, le client en est informé sans ambiguïté, et le système bascule sur la proposition de rappel décrite en alternative A.
Alternative C :	Si le client décline la proposition de rappel, le système clôt l’échange

2.4.4.3 Diagramme de séquence système

La figure 2.8 représente le scénario nominal et son alternative principale, la planification d'un rappel.




FIGURE 2.8 – DIAGRAMME DE SÉQUENCE SYSTÈME DU CAS ESCALADER VERS UN CONSEILLER HUMAIN

Conclusion

Ce chapitre a transformé les objectifs du projet en spécifications exploitables. Nous avons identifié quatre acteurs principaux, organisés selon une hiérarchie de droits, et trois familles d'acteurs secondaires correspondant aux systèmes que la plateforme sollicite sans les posséder. Nous avons ensuite formulé trente quatre besoins fonctionnels répartis en huit domaines, puis douze besoins non fonctionnels dont chacun impose une propriété identifiée à l'architecture. Les cas d'utilisation ont enfin été présentés dans leur ensemble, et détaillés pour les trois qui structurent le système : la réponse documentaire, l'opération sensible et l'escalade vers un conseiller.

Ces trois cas font apparaître une même exigence sous des formes différentes. La réponse documentaire impose que le système sache reconnaître les limites de ce qu'il sait. L'opération sensible impose qu'il sache reconnaître les limites de ce qu'il a le droit de faire. L'escalade impose qu'il sache reconnaître les limites de ce qu'il peut traiter seul. Le chapitre suivant montre

comment l'architecture de la solution répond à ces trois exigences, en présentant d'abord la vue statique du système, puis sa vue dynamique, avant de détailler la conception de la couche agentique et celle du contrôle d'accès.

Conception

Sommaire

3.1	Vue statique de l'application	34
3.1.1	Architecture logique du logiciel	34
3.1.2	Diagrammes de classes	38
3.1.3	Conception de la base de données	41
3.2	Vue dynamique de l'application	42
3.2.1	Diagrammes de séquence	43
3.2.2	Diagrammes d'activités	44
3.2.3	Diagrammes d'états transitions	46
3.3	Conception du système agentique	48
3.3.1	Principe et pipeline de raisonnement	49
3.3.2	Décomposition en agents spécialisés	49
3.3.3	Construction du contexte	51
3.3.4	Garde fous et comportement déterministe	54
3.3.5	Du prompt au harnais	56
3.4	Conception de la sécurité et du contrôle d'accès	56
3.4.1	Deux frontières distinctes	56
3.4.2	Authentification et gestion de session	56
3.4.3	Autorisation fondée sur le rôle	57
3.4.4	Isolation des données entre clients	58
3.4.5	Vérification d'identité renforcée	59
3.4.6	Traçabilité	59

Introduction

Le chapitre précédent a établi ce que le système doit faire. Celui ci décrit comment il est construit pour le faire. Nous présentons d'abord la vue statique, c'est à dire l'organisation des éléments qui composent la plateforme et les relations qu'ils entretiennent, puis sa vue dynamique, c'est à dire la manière dont ces éléments collaborent dans le temps. Nous détaillons ensuite la conception de la couche agentique, qui constitue l'apport principal de ce travail, et celle du contrôle d'accès, qui en conditionne la sûreté. Conformément à l'usage, cette partie reste indépendante des technologies employées : celles ci sont introduites au chapitre suivant.

3.1 Vue statique de l'application

3.1.1 Architecture logique du logiciel

3.1.1.1 Le principe retenu

L'architecture repose sur une séparation en couches concentriques, selon le patron dit hexagonal, également appelé architecture en ports et adaptateurs [2, 3]. Ce choix découle directement de deux besoins non fonctionnels établis au chapitre précédent : l'extensibilité, qui exige qu'un changement de fournisseur externe ne se propage pas dans le système, et la testabilité, qui exige que la logique de décision puisse être vérifiée sans dépendre d'un environnement.

Au centre se trouve le domaine métier, qui porte les entités, les objets valeur et les règles, et qui ne dépend de rien : il ignore par construction l'existence des interfaces, des bases de données et des fournisseurs externes. Il déclare en revanche des interfaces abstraites, les ports, exprimant ce dont il a besoin sans dire comment le lui fournir. Autour viennent les adaptateurs, qui les implémentent.

La direction des dépendances s'en trouve inversée : l'infrastructure se conforme au contrat du domaine, et non l'inverse. Remplacer un fournisseur revient dès lors à écrire un adaptateur, sans toucher aux règles.

La figure 3.1 présente cette organisation.

3.1.1.2 Les ports du domaine

Le domaine déclare treize ports, chacun correspondant à une capacité dont il a besoin et dont il refuse de connaître la réalisation. Ils se répartissent en trois familles.




FIGURE 3.1 – ARCHITECTURE HEXAGONALE DE LA PLATEFORME

- **Conduite de la décision.** Les ports de décision, de politique et d'exécution portent respectivement la proposition d'une action candidate, le verdict motivé qui la tranche et sa réalisation idempotente.
- **Accès au métier de l'opérateur.** Les ports de relation client, de facturation, de solde, de paiement, de provisionnement et de supervision réseau donnent accès aux données et aux opérations détenues par les systèmes de l'opérateur.
- **Services transverses.** Les ports de connaissance, d'audit, de notification et de gestion de tickets couvrent la recherche documentaire, l'enregistrement infalsifiable, l'acheminement des avis et le cycle de vie des tickets.

Le port de politique mérite une remarque particulière, car il déclare deux capacités et non une seule. La première évalue une action avant son exécution. La seconde évalue une réponse avant son émission, ce qui permet de contrôler ce que le système s'apprête à dire au client, et non uniquement ce qu'il s'apprête à faire. Cette symétrie est délibérée : une réponse qui divulguerait une donnée personnelle ou formulerait un engagement non fondé constitue un incident au même titre qu'une action non autorisée.

3.1.1.3 Découpage en contextes métier

Le domaine n'est pas monolithique. Il est découpé en contextes métier délimités, au sens de la conception pilotée par le domaine [1], chacun possédant son propre vocabulaire et sa propre logique, et communiquant avec les autres par des contrats explicites plutôt que par des structures partagées. Ce découpage suit les frontières du métier et non celles de la technique.

- **Conversation.** Le déroulement de l'échange, les tours de parole, l'état de la session et l'issue de la conversation.
- **Connaissance.** Les documents, leurs versions, leurs fragments et leur indexation.
- **Décision et politique.** La proposition d'action, les règles métier et les verdicts rendus.
- **Exécution.** Le registre des actions, leur identité d'opération et leur statut.
- **Gestion de tickets.** Les tickets et leur cycle de vie.
- **Routage et escalade.** Les conseillers, leurs disponibilités, les rappels et les dossiers d'escalade.
- **Identité et accès.** Les comptes du portail, les sessions et les droits.
- **Audit.** La chaîne des enregistrements et sa vérification.
- **Référentiels.** Les catalogues de produits, de recharges, de zones géographiques et de règles.

La figure 3.2 présente ce découpage sous forme de diagramme de paquetages, en faisant apparaître les dépendances autorisées entre contextes.




FIGURE 3.2 – DIAGRAMME DE PAQUETAGES DES CONTEXTES MÉTIER

3.1.1.4 Décomposition en composants

À l'exécution, ces contextes se matérialisent sous forme de composants déployables indépendants. Chacun expose une interface de service et n'accède aux autres qu'au travers de celle ci, ce qui garantit que le découpage logique survit au passage à l'exécution. La figure 3.3 présente cette décomposition.




FIGURE 3.3 – DIAGRAMME DE COMPOSANTS DE LA PLATEFORME

Trois règles de construction gouvernent cette décomposition et méritent d'être énoncées, car elles conditionnent la validité de l'ensemble.

- Les règles métier n'importent aucune bibliothèque de fournisseur. Elles se situent derrière les ports et ignorent l'existence des fournisseurs externes.
- Le point d'entrée de la couche temps réel n'est qu'un assembleur. Il compose les éléments entre eux et ne contient aucune logique métier.
- Les capacités offertes à la couche conversationnelle sont des façades minces. Elles n'implémentent rien : elles appellent les services du domaine au travers d'interfaces typées.

Ces trois règles servent un objectif unique. Elles garantissent qu'aucun chemin ne permet d'atteindre une action métier en contournant les contrôles, parce que le seul chemin qui existe passe par le domaine.

3.1.2 Diagrammes de classes

Nous présentons trois diagrammes de classes, chacun répondant à une question distincte. Le premier décrit le modèle du domaine. Le deuxième décrit la hiérarchie des agents conversationnels. Le troisième décrit le moteur de décision déterministe.

3.1.2.1 Modèle du domaine

Le modèle du domaine distingue explicitement deux natures d'objets, distinction qui structure l'ensemble du code.

Les entités possèdent une identité propre qui persiste au delà de leurs valeurs : deux clients restent distincts même si tous leurs attributs coïncident. Le domaine en compte neuf principales : le client, l'intention, le tour de parole, la conversation, la décision, le verdict de politique, l'action, le ticket et le dossier d'escalade, auxquels s'ajoutent l'enregistrement de consentement et l'entrée d'audit.

Les objets valeur, au contraire, n'ont pas d'identité : ils sont définis entièrement par leur contenu et sont immuables. Le domaine en compte trois, et le choix de chacun d'eux est significatif. Le numéro d'appel encapsule sa propre règle de validité, ce qui rend impossible la circulation d'un numéro mal formé dans le système. Le montant transporte indissociablement sa valeur et sa devise, ce qui interdit une addition entre devises différentes. L'identité d'opération, enfin, est la clé qui garantit qu'une action ne sera pas exécutée deux fois.

Le domaine définit également cinq énumérations qui ferment les ensembles de valeurs admissibles : les langues prises en charge, les canaux de communication, les trois verdicts possibles, les quatre niveaux de sentiment et les huit motifs d'escalade. Fermer ces ensembles n'est pas un détail de style. Une valeur inattendue devient une erreur détectable à la frontière du système plutôt qu'un comportement silencieux en son coeur.

La figure 3.4 présente ce modèle.

3.1.2.2 Hiérarchie des agents conversationnels

La couche conversationnelle repose sur une hiérarchie simple mais dont la contrainte principale est peu commune. Une classe de base porte tout ce qui est commun à l'ensemble des agents : l'observation de chaque tour de parole du client, l'évaluation du sentiment, l'enregistrement de l'échange, le protocole de clôture, la politique de langue et la règle d'abstention documentaire. Cinq agents spécialisés en dérivent, chacun couvrant un périmètre précis.

La contrainte notable tient à la relation entre les instructions d'un agent et les capacités dont il dispose. Ces instructions ne sont pas rédigées à la main indépendamment de l'outillage :




FIGURE 3.4 – DIAGRAMME DE CLASSES DU MODÈLE DU DOMAINE

elles sont dérivées de l'ensemble des capacités effectivement attachées à l'agent. Il en résulte qu'un agent ne peut pas recevoir l'instruction d'utiliser une capacité qu'il ne possède pas. Cette propriété élimine par construction une classe entière de défauts, celle où une consigne mentionne une capacité absente et où l'agent, ne pouvant l'exécuter, produit un comportement imprévisible.

La figure 3.5 présente cette hiérarchie.

3.1.2.3 Moteur de décision déterministe

Le moteur de règles suit un patron de chaîne de responsabilité [4]. Une règle reçoit le contexte de l'action et rend soit un verdict, soit l'absence de verdict, signifiant que la règle ne se prononce pas sur ce cas. Le moteur parcourt les règles dans un ordre défini et s'arrête à la première qui se prononce. L'autorisation n'est accordée que si aucune règle ne s'y oppose.

Cet ordre n'est pas arbitraire. La chaîne d'escalade obligatoire est évaluée en premier et court-circuite le reste, car certaines situations doivent conduire à une intervention humaine quelles que soient les autres considérations. Vient ensuite un contrôle d'identité de second niveau, appliqué à toute action sensible indépendamment de ce que la couche conversationnelle croit avoir déjà vérifié. Viennent enfin les règles propres à chaque type d'action.

Chaque règle produit trois informations et non une seule : le verdict, l'identifiant de la règle qui l'a rendu, et une justification lisible. C'est cette triade qui rend le système explicable après




FIGURE 3.5 – DIAGRAMME DE CLASSES DE LA HIÉRARCHIE DES AGENTS

coup, car elle permet de répondre non seulement à la question de savoir ce qui a été décidé, mais aussi à celle de savoir pourquoi.

La figure 3.6 présente ce moteur.




FIGURE 3.6 – DIAGRAMME DE CLASSES DU MOTEUR DE POLITIQUE

3.1.3 Conception de la base de données

3.1.3.1 Organisation en schémas

Le stockage relationnel est organisé en schémas, un par contexte métier, ce qui prolonge dans les données le découpage établi dans le domaine. Cette organisation autorise un contrôle d'accès différencié par schéma et rend visible, à la seule lecture du modèle, la frontière de chaque contexte.

Quatorze schémas coexistent. Les cinq schémas centraux portent la conversation, la connaissance, la décision et la politique, l'exécution et le routage. Les schémas périphériques reproduisent la structure des systèmes de l'opérateur, à savoir la relation client, la facturation, le solde et l'usage, le provisionnement et l'état des cartes SIM, ainsi que la supervision réseau. Trois schémas transverses complètent l'ensemble : l'identité de portail, l'audit et les référentiels.

3.1.3.2 Modèle entités associations

La figure 3.7 présente le modèle entités associations des schémas centraux, à savoir la conversation, la décision, l'exécution, la gestion de tickets et le routage. Les schémas périphériques, qui reproduisent la structure des systèmes de l'opérateur, ne sont pas détaillés ici afin de préserver la lisibilité du modèle.

3.1.3.3 Deux asymétries assumées

Le modèle de données comporte deux dissymétries volontaires, qu'il importe d'explicitier car elles paraîtraient incohérentes sans justification.

La première concerne la connaissance. Le stockage relationnel constitue la référence des documents et de leurs fragments. L'index de recherche, lui, est un dérivé : il est reconstitué intégralement à partir de la référence. Cette dissymétrie permet de reconstruire l'index après un incident, de changer sa structure ou d'en modifier les paramètres sans risque de perte, puisque la source demeure intacte. L'identifiant d'un point de l'index est d'ailleurs celui du fragment dont il dérive, ce qui rend la réconciliation entre les deux immédiate.

La seconde concerne les tickets. Le système de gestion de tickets de l'organisation demeure la référence. La table locale est une projection destinée à la lecture : elle rend l'historique d'un client consultable pendant la conversation sans dépendre d'un appel distant, dont le délai serait incompatible avec la contrainte temps réel. Les écritures s'adressent toujours d'abord au système de référence, et la projection est mise à jour ensuite. Cette organisation applique la séparation entre le chemin d'écriture et le chemin de lecture [5], et elle interdit explicitement de considérer la projection comme faisant autorité.




FIGURE 3.7 – MODÈLE ENTITÉS ASSOCIATIONS DES SCHÉMAS CENTRAUX

Ces deux cas relèvent du même principe : lorsqu'une donnée doit être à la fois fiable et rapidement accessible, on maintient une source de vérité et une projection optimisée, en gardant la direction de la dépendance parfaitement claire.

3.2 Vue dynamique de l'application

La vue statique a décrit les éléments du système. La vue dynamique décrit leur collaboration dans le temps. Nous retenons trois angles complémentaires : les diagrammes de séquence, qui montrent l'ordre exact des échanges entre composants, les diagrammes d'activités, qui montrent l'enchaînement algorithmique interne d'un traitement, et les diagrammes d'états transitions, qui montrent le cycle de vie des objets les plus significatifs.

3.2.1 Diagrammes de séquence

3.2.1.1 Déroulement d'un tour de parole

Le premier diagramme, présenté à la figure 3.8, détaille le traitement complet d'un tour de parole, depuis la fin de l'énoncé du client jusqu'au début de la réponse sonore. Il constitue le chemin le plus fréquemment emprunté du système et celui sur lequel pèse la contrainte de temps.

L'enchaînement se lit ainsi. La détection d'activité vocale constate la fin de l'énoncé et déclenche la clôture du tour. La transcription, alimentée en continu pendant que le client parlait, se stabilise et livre le texte définitif. Ce texte est remis à l'agent actif, qui dispose déjà du contexte de la conversation et de la situation du client. L'agent détermine s'il peut répondre directement ou s'il doit solliciter une capacité, par exemple la recherche documentaire. La réponse formulée est transmise à la synthèse vocale, qui produit et diffuse l'audio par fragments successifs plutôt qu'en un bloc, de sorte que le client entend le début de la réponse avant que sa fin ne soit calculée. En parallèle et hors du chemin de parole, le tour est évalué du point de vue du sentiment puis remis à la couche d'enregistrement.

Ce parallélisme est un choix de conception et non une commodité d'implémentation. L'enregistrement d'un tour est utile mais non essentiel à la conversation ; le placer sur le chemin critique reviendrait à faire dépendre la fluidité de l'échange de la disponibilité du stockage.




FIGURE 3.8 – DIAGRAMME DE SÉQUENCE DU TRAITEMENT D'UN TOUR DE PAROLE

3.2.1.2 Déroulement d'une action sensible

Le second diagramme, présenté à la figure 3.9, détaille la chaîne qui conduit de la demande du client à l'exécution effective d'une opération. C'est le chemin le plus contraint du système.

Six étapes s'y succèdent, dans un ordre qui ne souffre aucune exception. Le contexte de la décision est d'abord constitué à partir de la situation vérifiée du client, et non à partir de ce que la conversation a laissé entendre. Le service de décision propose ensuite une action candidate assortie d'un degré de confiance, une confiance insuffisante conduisant directement à une escalade plutôt qu'à une tentative. Le service de politique rend alors un verdict, qui est immédiatement persisté et reçoit un identifiant. Seul un verdict favorable atteint le service d'exécution, lequel opère contre l'identifiant de ce verdict et non contre la demande initiale. L'exécution est protégée par une identité d'opération qui interdit une seconde réalisation. L'opération et son verdict sont enfin inscrits dans le registre d'audit.

L'ordre importe autant que les étapes elles mêmes. Persister le verdict avant l'exécution, et exécuter contre ce verdict persisté, rend structurellement impossible l'exécution d'une action dont aucune trace de l'autorisation n'existerait.




FIGURE 3.9 – DIAGRAMME DE SÉQUENCE D'UNE ACTION SENSIBLE

3.2.2 Diagrammes d'activités

3.2.2.1 Ingestion documentaire

Le diagramme de la figure 3.10 décrit le traitement appliqué à un document versé dans la base documentaire. Ce traitement se déroule hors ligne, ce qui autorise un soin qui serait impossible pendant une conversation.

Le document est d'abord extrait de son format d'origine et converti en texte. Ses méta-données sont ensuite déterminées, la langue étant déduite du contenu lorsqu'elle n'est pas déclarée. Le texte est alors segmenté en fragments de taille bornée, avec un recouvrement entre fragments consécutifs. La segmentation respecte les paragraphes plutôt que de découper à taille fixe, afin qu'un fragment demeure une unité de sens et non une tranche arbitraire ; seuls les paragraphes excédant la taille maximale sont scindés. Chaque fragment est ensuite encodé

sous deux représentations complémentaires, l'une portant le sens et l'autre les termes exacts. L'ensemble est écrit en une seule transaction, accompagné d'un travail d'ingestion traçable et d'un événement de synchronisation. Un processus distinct consomme ces événements et met l'index à jour.

Deux décisions figurent explicitement dans ce diagramme. La première est le contrôle d'empreinte : un document dont le contenu est inchangé ne produit aucun travail, tandis qu'un contenu modifié engendre une nouvelle version et désactive la précédente. La seconde est le passage par une file d'événements durable plutôt qu'une écriture directe dans l'index : si l'index est indisponible au moment de l'ingestion, l'événement demeure et sera traité ensuite, sans que la référence et l'index divergent durablement.




FIGURE 3.10 – DIAGRAMME D'ACTIVITÉS DE L'INGESTION DOCUMENTAIRE

3.2.2.2 Recherche documentaire

Le diagramme de la figure 3.11 décrit le traitement d'une question, qui s'exécute cette fois sous contrainte de temps. Sa particularité tient à sa structure en filtres successifs, chacun pouvant conclure à l'absence de réponse.

La question est encodée puis soumise à une première sélection fondée sur la proximité de sens, avec un seuil minimal. Si aucun passage ne franchit ce seuil, le traitement s'arrête immédiatement sur un résultat vide. Les passages retenus sont ensuite confrontés à une seconde sélection fondée sur les termes exacts, qui écarte les passages dont le vocabulaire n'a rien de commun avec la question. Les deux classements sont alors fusionnés selon une méthode qui combine les rangs plutôt que les scores, ce qui évite d'avoir à ramener deux échelles de mesure hétérogènes à une échelle commune. Un dernier filtre évalue conjointement la question et chaque passage survivant, et n'en conserve que ceux dont la pertinence est confirmée.

Ce dernier filtre ne s'applique qu'au petit nombre de candidats ayant franchi les étapes précédentes. Cette restriction est ce qui rend son coût acceptable dans une chaîne temps réel, et le chapitre suivant en donne la mesure.

Le point essentiel de ce diagramme est la présence de trois sorties possibles vers un résultat vide. Ce n'est pas une faiblesse du traitement, c'est sa propriété recherchée : le système préfère déclarer qu'il ne sait pas plutôt que remettre à l'agent des passages faiblement pertinents, sur lesquels celui-ci fonderait une réponse plausible mais infondée.

3.2.3 Diagrammes d'états transitions

3.2.3.1 Cycle de vie d'une conversation

Le diagramme de la figure 3.12 décrit les états successifs d'une conversation. Il fait apparaître que la conversation possède deux issues terminales et non une seule : la résolution autonome et le passage à un conseiller. Les traiter symétriquement dans le modèle traduit la position adoptée au premier chapitre, selon laquelle l'escalade constitue un résultat normal du système et non une défaillance.

Un état mérite d'être signalé, celui de vérification d'identité. Il n'est atteint que lorsqu'une opération sensible est envisagée, il est borné en nombre de tentatives et dans le temps, et il possède sa propre sortie en échec. Cette délimitation stricte évite qu'une conversation ne s'enlise dans une boucle de vérification.




FIGURE 3.11 – DIAGRAMME D'ACTIVITÉS DE LA RECHERCHE DOCUMENTAIRE

3.2.3.2 Cycle de vie d'un ticket

Le diagramme de la figure 3.13 décrit les états d'un ticket. Le vocabulaire d'états retenu est celui du système de référence de l'organisation, et non un vocabulaire propre à la plateforme : cinq états, de l'ouverture à la clôture, avec un état d'attente distinct de l'état de traitement en cours.

Ce choix de reprendre le vocabulaire du système de référence évite une correspondance approximative entre deux jeux d'états, source classique d'incohérences lorsque les deux systèmes évoluent séparément. La plateforme traduit les codes numériques du système de référence vers ces cinq états, et cette traduction est le seul point où les deux vocabulaires se rencontrent.




FIGURE 3.12 – DIAGRAMME D'ÉTATS TRANSITIONS D'UNE CONVERSATION




FIGURE 3.13 – DIAGRAMME D'ÉTATS TRANSITIONS D'UN TICKET

3.3 Conception du système agentique

Les deux sections précédentes ont décrit la structure et la dynamique générales du système. Celle ci traite de sa couche la plus spécifique, celle qui conduit la conversation et décide de ce qu'il convient de faire. Nous en présentons le principe, la décomposition, la construction du contexte, la gestion de la mémoire, puis les mécanismes qui encadrent le comportement.

3.3.1 Principe et pipeline de raisonnement

Un agent, au sens retenu ici, n'est pas un modèle de langue auquel on adresse une question. C'est un composant qui reçoit une demande, dispose d'un ensemble borné de capacités, se voit imposer un ensemble de contraintes, et produit soit une réponse, soit l'appel d'une capacité, soit une transmission à un autre agent.

Son fonctionnement suit quatre temps : interpréter la demande à la lumière du contexte, déterminer ce qu'il convient de faire, soumettre cette intention aux contraintes applicables, puis réaliser l'action validée et en restituer le résultat.

La distinction entre le deuxième et le troisième temps est la clé de la conception. Le modèle de langue intervient au deuxième temps, où sa capacité d'interprétation est irremplaçable. Il n'intervient pas au troisième, où c'est un mécanisme déterministe qui statue. Le modèle propose, il ne dispose pas. La figure 3.14 présente cet enchaînement.




FIGURE 3.14 – PIPELINE DE RAISONNEMENT D'UN AGENT

3.3.2 Décomposition en agents spécialisés

3.3.2.1 Motivation

Un agent unique chargé de l'ensemble des domaines pose trois difficultés. Ses instructions deviennent longues, et une instruction longue est moins bien suivie qu'une instruction courte.

Ses capacités deviennent nombreuses, et un ensemble de capacités étendu augmente la probabilité d'un appel inapproprié. Enfin, toute évolution d'un domaine impose de reconsidérer l'ensemble, puisque rien n'est isolé.

Nous avons donc réparti la charge entre cinq agents. Un agent d'accueil ouvre la conversation et détermine la nature de la demande. Trois agents spécialisés couvrent chacun un domaine métier. Un agent de supervision traite les situations qui débordent des trois domaines et pilote les cas d'escalade. Chacun ne porte que les instructions et les capacités de son périmètre.

3.3.2.2 Déclaration unique des domaines

Une décomposition de ce type comporte un risque connu : la désynchronisation entre ce qu'une instruction annonce et ce que l'outillage permet réellement. Un agent à qui l'on demande de transmettre une demande vers un domaine dont la capacité de transfert n'est pas déclarée se trouve dans une situation sans issue, dont il sortira par un comportement imprévisible.

La conception écarte ce risque en déclarant chaque domaine une seule fois, dans une table qui constitue la référence unique. Cette table associe à chaque domaine les sujets qu'il couvre, la capacité de transfert correspondante et la phrase de transition énoncée au client dans chacune des langues prises en charge. Les instructions des agents comme leur outillage sont dérivés de cette même table. Il devient donc structurellement impossible qu'un domaine soit nommé dans une consigne sans que la capacité associée existe.

Le tableau 3.1 présente cette déclaration.

Domaine	Sujets couverts	Traitement de la transition
Facturation	Solde, facture, règlement, report d'échéance	Phrase de transition déterministe, énoncée dans la langue de l'échange
Gestion de compte	Forfait, recharge, itinérance, ligne téléphonique	Idem
Technique	Carte SIM, réseau, connectivité	Idem

TABLE 3.1 – DÉCLARATION UNIQUE DES DOMAINES DE SPÉCIALITÉ

Le caractère déterministe de la phrase de transition mérite une justification. Il serait possible de laisser le modèle formuler lui même l'annonce du transfert. Nous ne l'avons pas fait, parce que cette phrase est un engagement pris envers le client : elle annonce un événement qui va se produire. Une formulation générée pourrait annoncer un transfert vers un service qui n'existe pas, ou promettre un délai. Une phrase fixe ne le peut pas.

3.3.2.3 Passage de relais entre agents

Lorsqu'un agent transmet la conversation à un autre, le contexte déjà constitué est conservé : le client n'a pas à se réidentifier ni à reformuler sa demande. Ce comportement est la traduction directe du besoin exprimé au chapitre précédent, où la perte de contexte lors des transferts avait été identifiée comme l'une des faiblesses majeures du dispositif existant.

Le passage de relais est par ailleurs encadré par un garde fou contre les boucles. Le nombre de transferts et le rang du tour de parole auquel le dernier a eu lieu sont suivis, de sorte que deux agents ne puissent pas se renvoyer indéfiniment une demande qu'aucun des deux ne reconnaît comme sienne. Au delà d'un certain nombre de passages, la demande est traitée comme débordant des domaines couverts.

La figure 3.15 présente l'organisation des agents et les transitions possibles entre eux.




FIGURE 3.15 – ORCHESTRATION DES AGENTS ET TRANSITIONS

3.3.3 Construction du contexte

3.3.3.1 Un contexte assemblé et non accumulé

Le contexte fourni à un agent n'est pas un historique qui grossit à chaque tour. C'est un assemblage, reconstitué à partir de sources distinctes, dont chacune n'est sollicitée que lorsqu'elle est utile.

Cette distinction a une portée pratique directe. Tout élément placé dans le contexte consomme une part de la fenêtre disponible et une part du temps de traitement. Un contexte

qui accumule tout devient à la fois plus coûteux et moins efficace, car l'information pertinente s'y dilue. Le tableau 3.2 récapitule les sources du contexte et leur condition de sollicitation.

Source	Contenu	Condition de sollicitation
Identité de session	Identifiant de session, langue courante, rang du tour	Systématique
Profil client	Nom, numéro de ligne, type d'abonnement, statut particulier	À l'ouverture de la conversation
Situation de facturation	Montants dus, factures ouvertes	Sur demande relevant du domaine facturation
Historique des demandes	Tickets et réclamations en cours	Sur demande le justifiant
Mémoire d'appels antérieurs	Synthèse des échanges précédents	À l'ouverture, si le client a un historique
État de vérification	Identité vérifiée, niveau, horodatage, échéance	Avant toute opération sensible
Sentiment courant	Score cumulé et nombre de tours négatifs consécutifs	Systématique, en arrière plan
Connaissance documentaire	Passages pertinents et leur source	Sur question documentaire uniquement
Capacités disponibles	Ensemble des capacités de l'agent actif	Déterminé par l'agent actif

TABLE 3.2 – SOURCES DU CONTEXTE ET CONDITIONS DE SOLLICITATION

La figure 3.16 illustre cet assemblage.

3.3.3.2 Mémoire courte et mémoire longue

Deux mémoires coexistent, de nature différente.

La mémoire courte est celle de la conversation en cours. Elle conserve les tours de parole, l'état de vérification, les compteurs de clarification et de transfert, l'évolution du sentiment et les identités des opérations engagées. Elle disparaît avec la session.

La mémoire longue traverse les appels. Elle permet qu'un client rappelant au sujet d'un incident déjà signalé n'ait pas à tout réexpliquer. Elle est présentée à l'agent sous forme d'une synthèse et non d'un historique brut, ce qui en borne le coût.

Trois règles de conception encadrent cette mémoire longue, et chacune répond à un défaut identifié.




FIGURE 3.16 – ASSEMBLAGE DU CONTEXTE D'UN AGENT

- **Ne jamais accueillir le client par ce dont on se souvient.** Un assistant qui ouvre l'échange en énumérant les appels précédents produit une impression de surveillance, et présume par ailleurs du motif de l'appel, qui peut être tout autre. La mémoire est un contexte mobilisable lorsqu'il devient pertinent, non une entrée en matière.
- **Ne jamais présenter un souvenir comme un fait actuel.** Une demande consignée comme ouverte l'était au moment où la synthèse a été constituée. Affirmer au client qu'elle l'est encore constitue une assertion sur le présent, qui exige une relecture de l'état courant avant d'être formulée.
- **Ne rien dire lorsqu'il n'y a rien.** Un premier appel et un client ayant désactivé la mémorisation produisent l'un comme l'autre une synthèse vide, qui n'ajoute ni contenu ni comportement.

Ces règles illustrent une orientation générale de la conception : une capacité n'est utile que si ses conditions d'usage sont définies avec autant de soin que la capacité elle-même.

3.3.4 Garde fous et comportement déterministe

3.3.4.1 Nature des garde fous

Les garde fous encadrent ce que le système peut décider et ce qu'il peut dire. Ils s'appliquent à deux moments distincts, ce qui constitue une propriété importante de la conception.

Le premier moment précède l'action. Toute opération sensible est soumise au moteur de règles décrit plus haut, qui rend un verdict à trois valeurs accompagné de l'identifiant de la règle appliquée et d'une justification. Ce contrôle n'est pas contournable, puisque le chemin qui mène à l'exécution passe par lui.

Le second moment précède la parole. Une réponse sur le point d'être énoncée peut être contrôlée avant son émission, notamment au regard de la divulgation de données personnelles, de la formulation d'engagements ou de la mention de montants. Une plateforme qui contrôlerait ses actions sans contrôler ses paroles laisserait ouverte une voie de préjudice pourtant réelle.

3.3.4.2 Le sentiment comme signal de décision

Le sentiment exprimé par le client constitue un signal supplémentaire, distinct des règles métier. Sa conception a évolué au cours du projet, et l'évolution est instructive.

Le modèle initial comptait les tours négatifs consécutifs et déclenchait une escalade au troisième. Il s'est révélé à la fois trop sensible et trop indulgent. Trop sensible, parce qu'un seul mot vif portait le score au maximum et y maintenait la conversation entière. Trop indulgent, parce que tout tour non négatif remettait le compteur à zéro, de sorte qu'un client mécontent de manière constante mais courtoise n'était jamais détecté.

Le modèle retenu procède par accumulation. Un tour négatif fait progresser un score, un tour positif le fait décroître, et une expression d'agressivité pèse plus lourd qu'un simple mécontentement. Le seuil est atteint par trois tours négatifs, ce qui préserve le comportement de référence, mais une seule phrase vive ne suffit plus, et un apaisement réel est effectivement pris en compte.

Le tableau 3.3 illustre le comportement obtenu.

Séquence de tours	Score atteint	Conséquence
Trois tours négatifs	0,66	Seuil franchi, escalade proposée
Deux tours négatifs	0,44	Sous le seuil, pas d'escalade
Négatif, positif, négatif	0,26	Sous le seuil, l'apaisement est pris en compte
Expression d'agressivité	0,55	Proche du seuil, traitement dédié

TABLE 3.3 – COMPORTEMENT DU MODÈLE D'ACCUMULATION DU MÉCONTENTEMENT

Il importe de souligner que ce signal n'autorise ni ne refuse rien par lui même. Il alimente la décision d'escalade, laquelle demeure soumise aux mêmes règles que les autres.

3.3.4.3 Déterminisme là où il compte

La conception rend délibérément déterministes plusieurs comportements qu'il aurait été plus simple de confier au modèle de langue. Le tableau 3.4 recense ces choix et leur motif.

Comportement rendu déterministe	Motif
Verdict sur une action sensible	Une décision engageant un compte client doit être reproductible et justifiable par une règle identifiée.
Phrase de transition entre agents	Elle annonce un événement qui va se produire ; une formulation libre pourrait promettre autre chose.
Énoncés de la vérification d'identité	Le nombre de tentatives et les formulations sont bornés, ce qui évite l'enlisement et les reformulations hasardeuses.
Dates et heures de rappel	Un horaire inventé est pire que l'absence de rendez vous ; les créneaux proviennent des disponibilités réelles et sont mis en forme, non générés.
Identité d'une opération	Elle garantit l'exécution unique et ne peut dépendre d'une interprétation.
Abstention documentaire	En l'absence de passage pertinent, la réponse est fixée et non reformulée.

TABLE 3.4 – COMPORTEMENTS RENDUS DÉTERMINISTES ET MOTIFS ASSOCIÉS

3.3.5 Du prompt au harnais

La conception de cette couche s'inscrit dans une progression que le projet a parcourue et qu'il est utile d'explicitier, car elle éclaire l'essentiel des choix précédents.

La première approche consiste à soigner les instructions données au modèle. Elle produit rapidement des résultats et atteint tout aussi rapidement ses limites : une instruction longue est appliquée de manière inégale, et rien ne garantit qu'elle le soit du tout.

La deuxième approche déplace l'attention vers ce que le modèle reçoit. Elle consiste à choisir les informations mises à sa disposition, à les assembler au moment opportun et à gérer leur durée de vie. C'est ce que décrit la sous section consacrée à la construction du contexte.

La troisième approche porte sur le système qui entoure le modèle : ce qui borne ses capacités, ce qui valide ses intentions, ce qui contrôle ses énoncés, ce qui enregistre ses décisions et ce qui reprend la main lorsqu'il échoue. C'est cette approche qui structure la plateforme.

La conclusion pratique de cette progression est qu'un appel unique à un modèle, aussi soigneusement formulé soit-il, ne peut porter un système de cette nature. Ce n'est pas la qualité des instructions qui garantit le comportement, c'est l'architecture qui les entoure.

3.4 Conception de la sécurité et du contrôle d'accès

3.4.1 Deux frontières distinctes

La sécurité de la plateforme repose sur une distinction qu'il convient d'énoncer d'emblée, car la confondre constituerait une faille.

La première frontière contrôle l'accès à la plateforme : qui se connecte, et à quelles fonctions ce profil donne droit. La seconde contrôle l'exécution des opérations sensibles à l'intérieur de la plateforme : le fait qu'un client soit connecté à son espace ne suffit pas à autoriser une opération sur son compte lors d'une conversation vocale.

Ces deux frontières sont indépendantes. Une session ouverte franchit la première et ne dit rien de la seconde. La figure 3.17 présente ce modèle.

3.4.2 Authentification et gestion de session

L'authentification est centralisée et commune aux deux catégories d'utilisateurs, qui sont ensuite orientées vers des espaces distincts selon leur rôle. Les éléments d'authentification sont conservés sous forme dérivée au moyen d'une fonction de dérivation à coût mémoire élevé [13],




FIGURE 3.17 – MODÈLE DE SÉCURITÉ DE LA PLATEFORME

dont les paramètres sont enregistrés avec chaque empreinte, de manière à pouvoir être renforcés ultérieurement sans invalider les comptes existants ni imposer une migration.

Une session authentifiée n'est pas un jeton autoportant dont la validité s'apprécierait à sa seule lecture. Elle est revalidée auprès de son enregistrement à chaque requête. La conséquence pratique est qu'une déconnexion, une expiration ou une révocation de l'ensemble des sessions d'un utilisateur prennent effet immédiatement, et non à l'échéance du jeton.

3.4.3 Autorisation fondée sur le rôle

L'autorisation repose sur trois rôles internes ordonnés, chacun disposant des droits du précédent augmentés des siens, auxquels s'ajoute le rôle client. Le tableau 3.5 présente la matrice des droits.

Ressource	Client	Conseiller	Superviseur	Administrateur
Ses propres données et conversations	Oui	Non	Non	Non
Assistant conversationnel	Oui	Non	Non	Non
Données d'un autre client	Non	Non	Non	Non
Rappels et disponibilités	Non	Oui	Oui	Oui
Conversations et transcriptions	Non	Non	Oui	Oui
Décisions et verdicts	Non	Non	Oui	Oui
Indicateurs d'activité	Non	Non	Oui	Oui
Comptes et règles métier	Non	Non	Non	Oui
Base documentaire	Non	Non	Non	Oui
Registre d'audit et vérification	Non	Non	Non	Oui

TABLE 3.5 – MATRICE DES DROITS PAR RÔLE

Trois principes gouvernent l'application de cette matrice.

Le premier est que le rôle n'est jamais déclaré par l'appelant. Il est déterminé à partir de la session que le système a lui même émise. Une conception antérieure du projet lisait le rôle dans un en tête de requête, ce qui revenait à laisser le client déclarer ses propres droits. Ce mécanisme a été supprimé, et l'en tête correspondant est aujourd'hui ignoré.

Le deuxième est que le contrôle côté interface ne constitue pas une protection. Les fonctions serveur étant atteignables indépendamment de la page qui les appelle, une vérification effectuée à l'affichage serait contournable. Le contrôle est donc appliqué sur chaque fonction serveur, et la vérification côté interface ne sert qu'à éviter un aller retour voué à l'échec.

Le troisième est le refus par défaut. En l'absence d'information d'autorisation exploitable, la demande est rejetée. Un rôle par défaut avait initialement été défini au niveau de la configuration, ce qui rendait l'ensemble des points d'accès atteignables ; ce défaut a été supprimé au profit d'un comportement fermé.

3.4.4 Isolation des données entre clients

Un client ne doit atteindre que ses propres données. Cette exigence, qui paraît évidente, se traduit par une contrainte de conception précise : la vérification ne peut porter sur l'identifiant transmis dans la requête, puisque celui ci est sous le contrôle de l'appelant. Elle porte sur la correspondance entre la ressource demandée et l'identité établie par la session. Une demande formulée par un client au sujet d'un autre est refusée, non parce que l'interface ne l'a pas proposée, mais parce que le serveur constate la discordance.

3.4.5 Vérification d'identité renforcée

Les opérations sensibles engagées au cours d'une conversation exigent une vérification distincte, fondée sur un élément que seul le titulaire connaît. Cette vérification est bornée à plusieurs égards : le nombre de tentatives est limité, le nombre de réponses inexploitable l'est également, et l'ensemble est soumis à une échéance.

Trois délais sont par ailleurs ordonnés de manière stricte : celui de l'appel de vérification, celui de la procédure complète, et celui du contrôle qui l'englobe. Cet ordre garantit que chaque niveau expire avant celui qui le contient, de sorte qu'une défaillance soit signalée à son niveau réel plutôt qu'absorbée par le délai supérieur, où elle deviendrait indiscernable.

Le résultat de la vérification n'est pas un simple indicateur booléen. Il porte l'identifiant du client vérifié, le niveau atteint, l'horodatage et l'échéance. Une vérification est donc valable pour un client déterminé et pour une durée déterminée, ce qui interdit qu'une vérification obtenue dans un contexte serve dans un autre.

3.4.6 Traçabilité

Toute opération administrative ou sensible laisse une trace comportant l'identité de son auteur, son rôle, l'action réalisée, la ressource concernée, l'horodatage, le résultat et le verdict d'autorisation. Les données personnelles y sont masquées partout où leur valeur exacte n'est pas nécessaire.

Ces traces sont organisées en chaîne : chaque enregistrement intègre l'empreinte du précédent dans le calcul de la sienne, au moyen d'une fonction de hachage cryptographique normalisée [14]. La modification d'un enregistrement ancien invalide donc toutes les empreintes postérieures, ce qui rend l'altération détectable par un simple recalcul. La conception ne prétend pas empêcher une modification, ce qu'aucun stockage ne permet réellement ; elle garantit que cette modification ne puisse pas passer inaperçue.

Conclusion

Ce chapitre a présenté la conception de la plateforme. La vue statique a établi une architecture en ports et adaptateurs, dans laquelle le domaine métier ne dépend d'aucune technologie et déclare treize interfaces exprimant ses besoins, un découpage en contextes métier délimités, et un modèle de données organisé en schémas assumant deux dissymétries explicites entre sources de vérité et projections. La vue dynamique a décrit le traitement d'un tour de parole, la chaîne conduisant à une action sensible, les deux traitements documentaires et les cycles de vie de la conversation et du ticket.

La conception de la couche agentique a ensuite montré comment la responsabilité est répartie entre cinq agents spécialisés, comment leur contexte est assemblé plutôt qu'accumulé, comment deux mémoires de portée différente coexistent, et comment les garde fous encadrent aussi bien les actions que les énoncés. La conception de la sécurité a enfin distingué deux frontières indépendantes, l'accès à la plateforme et l'exécution des opérations sensibles en son sein.

Une même orientation traverse ces choix. Partout où une garantie doit être tenue, le système ne s'en remet pas à l'interprétation : il l'inscrit dans sa structure. Le chapitre suivant expose la réalisation de cette conception, les technologies qui la portent, les mesures qui ont guidé les choix restants et les résultats obtenus.

Chapitre

4

Réalisation

Sommaire

4.1 Technologies	63
4.1.1 Principe de sélection	63
4.1.2 Technologies par couche	63
4.1.3 Le rôle de la couche temps réel	64
4.2 Outils d'implémentation	65
4.2.1 Environnement matériel	65
4.2.2 Environnement logiciel	66
4.3 La chaîne de traitement temps réel	67
4.3.1 Vue d'ensemble et principe du budget	67
4.3.2 Établissement de la session et transport	67
4.3.3 Détection de fin d'énoncé et gestion des tours de parole	68
4.3.4 Transcription de la parole	69
4.3.5 Raisonnement	70
4.3.6 Récupération documentaire sous contrainte temps réel	72
4.3.7 Synthèse vocale	74
4.3.8 Gestion des interruptions et budget global	76
4.4 Concurrence et gestion des ressources	78
4.4.1 Deux échelles de concurrence	78
4.4.2 Isolation des conversations	78
4.4.3 Isolation des opérations concurrentes	78
4.4.4 Ordonnancement des écritures d'audit	79
4.4.5 Isolation des écritures secondaires	79
4.4.6 Découplage de l'enregistrement conversationnel	80
4.5 Architecture physique et évolution temporelle	81
4.5.1 Topologie de déploiement	81
4.5.2 Chaîne d'observabilité	81
4.5.3 Une protection au démarrage	83
4.5.4 Évolution temporelle d'un échange	84
4.6 Interfaces de l'application	84
4.6.1 Portail client	84

4.6.2	Console d'administration et de supervision	85
4.6.3	Systèmes intégrés et environnement d'exécution	87
4.7	Vérification et évaluation	88
4.7.1	Principe retenu	88
4.7.2	Familles de vérifications	89
4.7.3	Vérification par injection de défaillance	89
4.7.4	Contrôle d'intégrité	89
4.8	Résultats et statistiques	90
4.8.1	Statut des mesures présentées	90
4.8.2	Qualité de la recherche documentaire	90
4.8.3	Volumétrie du système réalisé	93
4.8.4	Comportement en situation de défaillance	93
4.9	Problèmes rencontrés	94
4.9.1	Une dégradation silencieuse de la recherche documentaire	94
4.9.2	L'inversion des scores de similarité	95
4.9.3	Un modèle de mécontentement à la fois trop sensible et trop indulgent . .	95
4.9.4	Un risque de confusion entre services	96
4.9.5	Une identité d'opération trop inclusive	96
4.9.6	La contrainte de mémoire et ses conséquences	96

Introduction

Le chapitre précédent a décrit la conception indépendamment de toute technologie. Celui ci expose sa réalisation. Nous présentons d'abord les technologies retenues et l'environnement de développement, puis nous détaillons la chaîne temps réel étape par étape, chacune accompagnée de la mesure qui a orienté son choix. Nous traitons ensuite la gestion de la concurrence et des ressources, l'architecture physique de déploiement et les interfaces produites. Le chapitre se termine par la campagne de vérification, les résultats obtenus et les difficultés rencontrées.

4.1 Technologies

4.1.1 Principe de sélection

Trois critères ont gouverné le choix des technologies. Le premier est la compatibilité avec la contrainte temps réel : un composant qui ne diffuse pas en continu ne peut appartenir à la chaîne conversationnelle, quelle que soit sa qualité par ailleurs. Le deuxième est la préservation du contrôle : à qualité comparable, une solution ouverte et hébergeable en interne a été préférée à un service fermé, afin de conserver la maîtrise des données et la liberté d'évolution. Le troisième est la substituabilité : aucune technologie ne devait s'inscrire dans le système autrement que derrière une interface permettant de la remplacer.

Ces critères expliquent la répartition retenue. Les traitements d'inférence les plus lourds s'appuient sur des services spécialisés, tandis que tout ce qui touche aux données personnelles, aux enregistrements d'audit et aux systèmes métier demeure hébergé en interne.

4.1.2 Technologies par couche

Le tableau 4.1 présente les technologies retenues et le rôle de chacune.

Technologies retenues		
Couche	Technologie	Rôle dans la plateforme
Temps réel	LiveKit Server 1.8.4	Transport audio temps réel, gestion des salles, acheminement des participants et distribution des tâches vers les processus agents.
Services	Python 3.12 et FastAPI	Implémentation des services de domaine et de l'interface applicative métier.
Persistance	PostgreSQL 16	Source de vérité relationnelle, organisée en schémas par contexte métier.
Persistance	SQLAlchemy et Alembic	Modélisation des entités persistantes et gestion versionnée du schéma.
Index documentaire	Qdrant 1.12.5	Index de recherche à double représentation, sémantique et lexicale.
Stockage d'objets	MinIO	Conservation des documents sources de la base de connaissances.
Cache et état	Redis 7.4	États partagés et données de courte durée de vie.
Intégration	Serveurs MCP internes	Exposition contrôlée des capacités documentaire, de gestion de tickets et de messagerie aux agents.
Interfaces	TypeScript, React, TanStack Start	Portail client et console d'administration, avec exécution côté serveur des appels métier.
Observabilité	Prometheus	Collecte des métriques d'exécution, interrogées directement sur chaque service.
Observabilité	Grafana	Restitution des métriques sous forme de tableaux de bord provisionnés.
Observabilité	OpenTelemetry	Identifiant de corrélation et traces réparties lorsqu'un collecteur est déployé.
Exécution	Docker et Docker Compose	Isolation, reproductibilité et orchestration locale des services.
Déploiement	Helm	Description du déploiement pour un environnement orchestré.

TABLE 4.1 – TECHNOLOGIES RETENUES PAR COUCHE

4.1.3 Le rôle de la couche temps réel

Une précision s'impose au sujet de LiveKit, dont la place dans le système est souvent mal appréciée.

LiveKit est un cadriciel de communication temps réel à code ouvert. Il résout un ensemble de problèmes d'infrastructure difficiles et sans rapport avec le métier traité : l'établissement et le maintien d'une session audio bidirectionnelle à faible latence, la gestion des salles

et des participants, la mise en mémoire tampon des flux audio, la distribution des tâches vers des processus de traitement, la gestion des ressources associées à chaque session et la prise en charge de plusieurs interlocuteurs simultanés. Réaliser ces fonctions à partir de zéro représenterait un projet à part entière, sans rapport avec la valeur recherchée ici.

Ce que LiveKit ne fournit pas est précisément ce qui constitue ce travail : la logique des agents et leur orchestration, la construction du contexte, la mémoire, la chaîne de décision et de politique, l'exécution idempotente, les règles métier, les garde fous, la recherche documentaire, l'intégration à la gestion de tickets, le routage vers les conseillers, la piste d'audit, le modèle de sécurité et les interfaces de supervision. La couche temps réel transporte la parole ; elle ne décide de rien.

Cette séparation est d'ailleurs matérialisée dans le code par une frontière stricte. Les bibliothèques du fournisseur ne sont importées que dans un répertoire dédié, celui qui construit les composants de la chaîne média. Aucune règle métier, aucun service de domaine et aucun agent n'en dépend. C'est cette frontière qui rend le remplacement envisageable et qui garantit que le système n'est pas structuré par les contraintes d'un cadriciel.

4.2 Outils d'implémentation

4.2.1 Environnement matériel

Le développement a été conduit sur un poste de travail unique, dont les caractéristiques figurent au tableau 4.2. Ce poste a supporté simultanément l'ensemble des services conteneurisés, les modèles d'encodage exécutés localement et les environnements de développement des deux interfaces.

Composant	Caractéristique
Processeur	Intel Core i7-13650HX de treizième génération, 14 coeurs physiques et 20 fils d'exécution
Mémoire vive	16 Go
Processeur graphique	NVIDIA GeForce RTX 4050 pour ordinateur portable, et circuit graphique intégré Intel
Stockage	Disque à semi conducteurs NVMe de 512 Go
Système d'exploitation	Windows 11 Professionnel

TABLE 4.2 – CARACTÉRISTIQUES DU POSTE DE DÉVELOPPEMENT

La contrainte de mémoire vive a eu une conséquence directe sur la conception, exposée plus loin dans ce chapitre. Les modèles exécutés localement pour la recherche documentaire

devaient tenir dans l'espace laissé disponible par les services conteneurisés, ce qui a écarté certaines options par ailleurs plus performantes.

4.2.2 Environnement logiciel

Le tableau 4.3 présente les outils employés pour le développement, l'exécution et la vérification.

Catégorie	Outil	Usage
Exécution des services	Python 3.12.6	Environnement d'exécution des services de domaine.
Interfaces	Node.js 24 et Vite	Construction et développement des deux interfaces web.
Conteneurisation	Docker 27.3 et Docker Compose	Exécution locale de la totalité de la plateforme.
Gestion de version	Git	Suivi des incréments, une branche par version.
Migrations	Alembic	Évolution versionnée du schéma de base de données.
Vérification	Pytest	Exécution des suites de tests des services et des agents.
Qualité	Ruff et Mypy	Analyse statique et vérification des types.
Exploration d'interfaces	Postman	Vérification manuelle des points d'accès applicatifs.
Observabilité	Prometheus 2.55 et Grafana 11.3	Collecte des métriques et tableaux de bord de supervision.

TABLE 4.3 – ENVIRONNEMENT LOGICIEL DE DÉVELOPPEMENT

Deux modes d'exécution coexistent. Le premier lance chaque service directement sur le poste, ce qui raccourcit la boucle de retour pendant le développement d'un composant isolé. Le second lance la totalité de la plateforme en conteneurs, ce qui reproduit les conditions de communication réelles entre services. Les adresses des services diffèrent entre ces deux modes, et cette différence est portée par la description des conteneurs plutôt que par la configuration partagée, afin qu'un même fichier de configuration reste valable dans les deux cas.

4.3 La chaîne de traitement temps réel

4.3.1 Vue d'ensemble et principe du budget

La contrainte énoncée au premier chapitre trouve ici sa traduction concrète. Un échange parlé demeure naturel tant que le délai entre la fin de la phrase du client et le début de la réponse reste dans le rythme d'une conversation ordinaire. Ce délai n'est pas produit par un composant, il est la somme des contributions de tous.

Il en découle qu'aucune étape ne peut être optimisée isolément : celle qui dépasse son budget le retire à toutes les autres. Chaque composant ajouté introduit par ailleurs un point de rupture, si bien que l'allongement de cette chaîne est toujours une décision à justifier.

La figure 4.1 présente la chaîne complète et la contribution de chaque étape.




FIGURE 4.1 – CHAÎNE DE TRAITEMENT TEMPS RÉEL ET CONTRIBUTION DES ÉTAPES

Les valeurs issues de la configuration ou du code sont exactes. Les temps de traitement, eux, relèvent d'une reconstitution dont la section consacrée aux résultats précise le statut.

4.3.2 Établissement de la session et transport

4.3.2.1 Rôle

Avant tout traitement, un canal audio bidirectionnel doit être établi entre le client et la plateforme, et un processus de traitement doit être affecté à cette session. Cette étape ne se répète pas à chaque tour de parole, mais son coût s'impute sur la première impression du client.

4.3.2.2 Réalisation

Le client obtient d'abord un jeton d'accès auprès d'un service dédié. Ce jeton est délibérément restreint : il autorise uniquement la participation à une salle, sans permettre d'en créer

une ni de modifier ses propres attributs de participant. Sa durée de validité est courte. Lorsque la configuration désigne un agent nommé, le jeton porte en outre une instruction d'affectation explicite, de sorte que la session soit prise en charge par le processus attendu plutôt que par un processus disponible quelconque.

Le transport lui même repose sur les mécanismes de communication temps réel du web [16], qui établissent un canal à faible latence supportant la perte de paquets et les variations de délai propres aux réseaux publics. Le numéro d'appel du client accompagne la session sous forme d'attribut, ce qui permet de le rattacher immédiatement à un dossier client sans interrogation supplémentaire.

4.3.2.3 Ce que le choix a coûté

Restreindre le jeton impose de gérer le cycle de vie des salles côté serveur, ce qu'un jeton permissif aurait délégué au client. Le coût est assumé : cette latitude serait sans rapport avec le besoin réel du client.

4.3.2.4 Sortie vers la téléphonie

Cette même couche de transport porte le transfert vers un conseiller humain. Lorsqu'un appel provient du réseau téléphonique, le transfert s'effectue au moyen d'une redirection normalisée du protocole d'établissement de session [15], appliquée au participant téléphonique de la conversation.

Ce mécanisme présente une particularité qu'il faut connaître pour l'employer correctement : la redirection porte sur l'identité du participant telle qu'elle a été attribuée lors de l'établissement de la session, et non sur le numéro d'appel du client. Fournir le numéro plutôt que cette identité provoque un rejet pour discordance. Le transfert est par ailleurs terminal du point de vue de la plateforme : une fois abouti, la session temps réel du client prend fin, l'échange se poursuivant directement avec le conseiller. C'est la raison pour laquelle le dossier de l'échange doit être constitué et transmis avant le transfert, et non pendant.

4.3.3 Détection de fin d'énoncé et gestion des tours de parole

4.3.3.1 Rôle

Le système doit déterminer à quel moment le client a fini de parler. Cette décision est plus délicate qu'il n'y paraît, car elle arbitre entre deux défauts opposés. Une détection trop rapide coupe la parole au client qui marque une pause pour réfléchir. Une détection trop lente installe un silence après chaque phrase et donne l'impression d'un système qui n'a pas compris.

4.3.3.2 Réalisation

La détection d'activité vocale s'appuie sur un modèle léger exécuté localement, sans appel réseau, ce qui lui évite d'ajouter la moindre latence d'aller retour. La durée minimale de silence retenue est de deux cent cinquante millisecondes. Cette valeur n'a pas été choisie librement : elle constitue le seuil minimal exigé par le mécanisme de détection de tour de parole en aval, et la descendre rendrait ce dernier inopérant.

La fin de tour est ensuite confirmée par le flux de transcription lui-même, dont la stabilisation indique que l'énoncé est complet. Combiner les deux signaux, l'un acoustique et l'autre linguistique, rend la décision plus robuste qu'un silence seul, qui confondrait une pause avec une fin de phrase.

4.3.3.3 Génération anticipée

Une optimisation notable est activée à cette étape. Plutôt que d'attendre la confirmation définitive de fin de tour pour commencer à produire la réponse, le système engage la génération dès que la transcription devient suffisamment stable. Si le client reprend la parole, le travail engagé est abandonné. Dans le cas contraire, la réponse est déjà en cours de production au moment où la fin de tour est confirmée.

Ce mécanisme ne réduit pas le temps de calcul total : il en déplace une partie avant l'instant à partir duquel le client commence à attendre. Le gain porte donc sur la latence perçue, qui est la seule qui compte pour l'utilisateur.

4.3.4 Transcription de la parole

4.3.4.1 Rôle et métriques

La transcription convertit le flux audio en texte. Deux grandeurs la caractérisent : le taux d'erreur sur les mots, qui mesure l'exactitude, et le facteur temps réel, qui rapporte la durée de traitement à celle de l'audio traité. Une valeur inférieure à un est nécessaire au fonctionnement en flux continu. Les formules figurent en annexe.

Une troisième exigence, non métrique, est déterminante : la transcription doit être diffusée en continu. Un composant qui attendrait la fin de l'énoncé pour rendre le texte ajouterait à lui seul la durée de la phrase au délai de réponse.

4.3.4.2 Réalisation

Le fournisseur principal retenu est Deepgram, avec son modèle de dernière génération. Trois éléments de sa mise en oeuvre méritent d'être signalés.

Le premier concerne le vocabulaire spécifique. Les noms de lieux, les désignations d’offres et les termes propres au domaine sont mal reconnus par un modèle généraliste. Le système transmet donc au fournisseur une liste de termes attendus, ce qui améliore sensiblement leur reconnaissance.

Le deuxième découle du premier. Une liste de termes trop étendue ou mal calibrée peut dégrader la transcription au lieu de l’améliorer. Le système déclare donc en second recours une instance du même fournisseur sans cette liste. Cette précaution mérite d’être soulignée car elle protège contre une défaillance qui ne viendrait pas du fournisseur mais de notre propre configuration.

Le troisième concerne l’arabe. Plutôt que de recourir au modèle multilingue, l’arabe est acheminé vers le modèle monolingue dédié, dont les résultats sont nettement supérieurs sur cette langue.

4.3.4.3 Chaîne de repli

La transcription dispose d’une chaîne de repli à quatre niveaux, présentée au tableau 4.4. Un fournisseur dont la clé d’accès n’est pas configurée est simplement omis, de sorte que le système fonctionne avec les fournisseurs disponibles plutôt que d’échouer au démarrage.

Rang	Fournisseur	Justification de la position
1	Deepgram avec vocabulaire spécifique	Meilleure exactitude sur le domaine, diffusion en continu, latence faible.
2	Deepgram sans vocabulaire spécifique	Protège contre une dégradation causée par la liste de termes elle même.
3	Gladia	Second fournisseur indépendant, diffusion en continu, activé si configuré.
4	Azure	Dernier recours, retenu pour la couverture linguistique.

TABLE 4.4 – CHAÎNE DE REPLI DE LA TRANSCRIPTION

4.3.5 Raisonnement

4.3.5.1 Rôle et critères de sélection

Le modèle de langue, fondé sur l’architecture à mécanisme d’attention [6], interprète la demande, conduit le dialogue et détermine quelle capacité solliciter. Le choix d’un modèle pour cet emploi ne se réduit pas à la qualité de sa rédaction. Quatre critères ont été retenus.

- **Le délai avant le premier jeton.** C'est le temps écoulé entre l'envoi de la requête et l'arrivée du premier fragment de réponse. Dans une chaîne diffusée en continu, c'est cette grandeur qui gouverne la latence perçue, et non la durée totale de génération.
- **La capacité d'appel d'outils.** Le modèle doit choisir une capacité et en construire les arguments de manière fiable. Un modèle éloquent mais imprécis sur ce point est inutilisable dans un système agentique.
- **Le suivi d'instructions.** Le comportement du système repose sur des consignes de conduite du dialogue, d'abstention et de clôture. Un modèle qui les applique de façon inégale rend ce comportement imprévisible.
- **La fenêtre de contexte.** Elle doit accueillir les instructions, l'historique de l'échange, la situation du client et les passages documentaires sans troncature.

4.3.5.2 Le compromis évité

Un choix se présentait naturellement : retenir un modèle de petite taille, moins coûteux et plus rapide. Nous l'avons écarté, et la raison mérite d'être explicitée car elle est contre intuitive.

Un modèle affaibli produit certes des réponses plus vite, mais il suit moins bien les consignes, perd plus facilement le contexte et se trompe plus souvent de capacité. Or chacune de ces défaillances engendre un tour de parole supplémentaire : une clarification inutile, une reformulation, un appel d'outil erroné qu'il faut rattraper. Un tour supplémentaire coûte au client la totalité de la chaîne, soit bien davantage que ce que l'écart de vitesse entre deux modèles pouvait faire économiser. La rapidité d'un modèle se mesure au niveau de la conversation, pas au niveau de la requête.

4.3.5.3 Réalisation

Le modèle principal retenu est Gemini 2.5 Flash, dont le profil combine un délai avant premier jeton faible, un appel d'outils fiable et une fenêtre de contexte largement suffisante. Une bascule de configuration permet de placer GPT-4o mini en tête de chaîne, les deux modèles ayant été évalués sur le même comportement.

La chaîne se poursuit par deux fournisseurs de repli reposant sur des modèles ouverts de la famille Llama, l'un hébergé sur une infrastructure d'inférence spécialisée, l'autre sur une infrastructure optimisée pour le débit. Ces deux recours ne visent pas la qualité maximale mais la continuité de service : ils permettent à une conversation de se poursuivre lorsque les fournisseurs principaux sont indisponibles ou saturés.

Le tableau 4.5 présente cette chaîne.

Rang	Modèle	Justification de la position
1	Gemini 2.5 Flash	Délai avant premier jeton faible, appel d'outils fiable, large fenêtre de contexte.
2	GPT-4o mini	Profil comparable, activable en tête de chaîne par configuration.
3	Llama 3.1 sur infrastructure d'inférence spécialisée	Continuité de service, modèle ouvert, délai d'attente porté à quarante cinq secondes.
4	Llama 3.1 sur infrastructure à haut débit	Dernier recours privilégiant la vitesse de génération.

TABLE 4.5 – CHAÎNE DE REPLI DU MODÈLE DE LANGUE

Une tentative auprès d'un fournisseur est abandonnée au bout de douze secondes, ce qui déclenche le passage au suivant. Ce délai est un compromis : suffisamment long pour absorber une lenteur passagère, suffisamment court pour que le report vers le fournisseur suivant conserve une chance d'aboutir dans un délai acceptable.

4.3.5.4 Travaux sur l'exécution locale

Nous avons évalué l'exécution locale d'un modèle ouvert de la famille Llama sur le poste de développement. Les résultats confirment que cette voie est praticable pour un traitement différé, mais qu'elle ne l'est pas dans les conditions du projet. La mémoire disponible, partagée avec l'ensemble des services conteneurisés et les modèles d'encodage documentaire, ne permet pas d'héberger un modèle de taille suffisante tout en préservant les marges nécessaires au reste de la plateforme, et le délai avant premier jeton obtenu reste incompatible avec la contrainte conversationnelle. Cette évaluation a néanmoins orienté la conception : elle a confirmé que l'inférence devait rester derrière une interface substituable, afin qu'un passage à une exécution locale reste possible sur un matériel adapté sans remise en cause de l'architecture.

4.3.6 Récupération documentaire sous contrainte temps réel

4.3.6.1 Le problème particulier de cette étape

Le principe consistant à fonder la réponse d'un modèle sur des passages récupérés dans un corpus externe, plutôt que sur ses paramètres, a été formalisé sous le nom de génération augmentée par récupération [7]. Sa mise en oeuvre dans une chaîne conversationnelle soulève cependant une difficulté qui lui est propre : la récupération documentaire est la seule étape de la chaîne dont la qualité et la latence s'opposent frontalement. Les techniques qui améliorent la

pertinence sont précisément celles qui coûtent le plus cher, et un dispositif de recherche conçu pour un usage différé devient inutilisable dès qu'il s'insère dans une conversation.

4.3.6.2 Encodage des textes

Le modèle d'encodage retenu [8] produit des représentations de trois cent quatre vingt quatre dimensions et couvre une centaine de langues dans un espace unique. Cette dernière propriété a une conséquence directe et précieuse : une question posée en français peut retrouver une procédure rédigée en anglais sans qu'aucune traduction intervienne.

Ce modèle est asymétrique : il attend qu'on lui indique si le texte encodé est une question ou un passage. L'indication est appliquée à l'intérieur du composant, de sorte qu'aucun appelant ne puisse l'omettre, et la dimension de chaque représentation produite est vérifiée plutôt que laissée à l'index.

Le choix d'un modèle exécuté localement plutôt que d'un service distant a été délibéré. Un service distant aurait ajouté un aller retour réseau et un point de rupture supplémentaire à chaque question posée, sur le chemin le plus contraint du système. Le modèle retenu fonctionne sur processeur, sans matériel graphique, sans clé d'accès, sans quota et sans limitation de débit.

4.3.6.3 Recherche en trois filtres

La recherche procède par filtres successifs, chacun pouvant conclure à l'absence de réponse. Le tableau 4.6 en présente le détail.

Filtre	Principe	Ce qu'il élimine
Proximité de sens	Comparaison des représentations sémantiques, seuil minimal de 0,82, douze candidats retenus	Les passages sans rapport de sens avec la question, quelle que soit la langue.
Termes exacts	Comparaison lexicale pondérée par la rareté des termes [9]	Les passages dont le vocabulaire n'a rien de commun avec la question.
Fusion des rangs	Combinaison des deux classements par leurs rangs et non par leurs scores [10]	Ne supprime rien, mais réconcilie deux échelles de mesure hétérogènes.
Évaluation conjointe	Lecture simultanée de la question et du passage, seuil de 0,30, au plus douze candidats	Les passages formellement proches mais réellement hors sujet.

TABLE 4.6 – FILTRES SUCCESSIFS DE LA RECHERCHE DOCUMENTAIRE

Le dernier filtre est le plus coûteux, de l'ordre de quatre vingts à cent cinquante millisecondes. Il n'est acceptable dans une chaîne temps réel que parce qu'il ne s'applique qu'au petit nombre de candidats ayant franchi les filtres précédents, qui sont eux très peu coûteux. Placer ce filtre en tête aurait produit exactement la même qualité pour un coût prohibitif : l'ordre des filtres est ici aussi déterminant que leur nature.

Deux délais encadrent cette étape et leur ordre est un invariant. Le budget accordé au service de recherche est de cinq secondes, celui du client qui l'appelle de neuf secondes. Le second doit rester strictement supérieur au premier, faute de quoi l'appelant abandonnerait avant que le service ait pu répondre, et une absence de réponse deviendrait indiscernable d'une lenteur.

4.3.6.4 Ce que le choix a coûté

Le dispositif retenu privilégie la précision au détriment du rappel. Un passage réellement pertinent mais dont le score reste légèrement en deçà des seuils sera écarté. Ce compromis est assumé : dans le contexte d'un service client, une réponse fondée sur un document inapproprié cause davantage de tort qu'un aveu d'ignorance suivi d'une orientation vers un conseiller.

4.3.7 Synthèse vocale

4.3.7.1 Rôle et métrique déterminante

La synthèse vocale produit la réponse sonore. La grandeur déterminante n'est pas la durée totale de synthèse mais le délai avant le premier fragment audio : un composant lent à produire l'ensemble mais rapide à en produire le début est préférable à l'inverse. C'est aussi à cette étape que se joue la qualité perçue, la prosodie déterminant si l'échange est ressenti comme une conversation ou comme la lecture d'un texte.

4.3.7.2 Une exigence éliminatoire

La diffusion en continu constitue un critère éliminatoire et non un critère de préférence. Un composant de synthèse qui met en mémoire tampon l'énoncé complet avant d'émettre le moindre son ajoute au délai de réponse la durée entière de la phrase à prononcer.

C'est exactement ce motif qui a conduit à écarter une solution par ailleurs prometteuse. La synthèse vocale de Google, dans sa version disponible au moment de l'étude, fonctionne sans diffusion en continu : elle constitue l'énoncé entier avant restitution. Son intégration a donc été délibérément écartée malgré sa qualité, tout en conservant les emplacements de configuration nécessaires à une reprise éventuelle si une version diffusée en continu venait à paraître.

4.3.7.3 Réalisation

Le fournisseur principal retenu est Cartesia, choisi pour sa latence particulièrement faible avant le premier fragment. La chaîne de repli est ordonnée selon la qualité perçue, comme le présente le tableau 4.7.

Rang	Fournisseur	Justification de la position
1	Cartesia	Délai avant premier fragment le plus faible, diffusion en continu, qualité satisfaisante en français.
2	ElevenLabs	Naturel supérieur, latence plus élevée, retenu comme premier repli qualitatif.
3	Inworld	Expressivité, prise en charge du français, troisième recours.
4	SmallestAI	Fournisseur le plus rapide, dernier recours privilégiant la continuité.

TABLE 4.7 – CHAÎNE DE REPLI DE LA SYNTHÈSE VOCALE

Deux dispositions complètent cette organisation. Un fournisseur dont la clé n'est pas configurée est omis de la chaîne. En revanche, si aucun fournisseur n'est configuré, le processus refuse de démarrer plutôt que de fonctionner sans voix : un agent muet constitue une défaillance silencieuse, qui est précisément le type de défaut que la conception cherche à proscrire.

4.3.7.4 Une mesure inattendue

La collecte du consentement à l'enregistrement, énoncée au début de chaque appel, représente à elle seule près d'un quart du volume de synthèse vocale d'une conversation. Cette mesure illustre un point de méthode : dans une chaîne temps réel, les coûts significatifs ne se trouvent pas toujours là où l'attention se porte spontanément. Le mécanisme est conservé, car il répond à une obligation, mais il est désactivable dans les environnements de développement où il n'a pas lieu d'être.

4.3.7.5 Positionnement des fournisseurs retenus

Les trois étapes qui dépendent d'un service externe obéissent au même arbitrage, entre la qualité d'un côté et le respect du budget de temps de l'autre. La figure 4.2 en donne une vue d'ensemble. Elle fait apparaître que le fournisseur retenu en tête de chaîne n'est jamais le plus performant dans l'absolu, mais le meilleur parmi ceux qui restent dans la zone compatible avec le temps réel. Les solutions écartées le sont pour une raison structurelle et non pour un écart de qualité : absence de diffusion en continu pour la synthèse de Google, ressources insuffisantes pour l'exécution locale du modèle de raisonnement.




FIGURE 4.2 – POSITIONNEMENT QUALITATIF DES FOURNISSEURS DE LA CHAÎNE VOCALE

4.3.8 Gestion des interruptions et budget global

4.3.8.1 Interruption

Le client doit pouvoir interrompre l'assistant à tout moment. Le traitement de cette situation met en jeu trois opérations quasi simultanées : l'arrêt immédiat de la diffusion audio, l'abandon de la génération en cours, et la prise en compte du nouvel énoncé comme un tour de parole ordinaire.

La difficulté tient à la cohérence de l'état après l'interruption. Une réponse interrompue a été partiellement entendue par le client. Le système doit donc consigner ce qui a effectivement été prononcé et non ce qu'il avait prévu de dire, faute de quoi l'historique de la conversation divergerait de ce que le client a réellement perçu, et les tours suivants raisonnaient sur une conversation qui n'a pas eu lieu.

4.3.8.2 Budget de latence

Le tableau 4.8 présente la répartition du délai entre la fin de l'énoncé du client et le début de la réponse sonore. Les valeurs de configuration y sont exactes ; les temps de traitement relèvent de la reconstitution décrite en introduction de cette section.

Étape	Sans recherche	Avec recherche	Nature de la valeur
Détection de fin d'énoncé	250 ms	250 ms	Configuration exacte
Stabilisation de la transcription	150 à 250 ms	150 à 250 ms	Reconstitution
Assemblage du contexte	30 à 60 ms	30 à 60 ms	Reconstitution
Recherche documentaire	sans objet	200 à 350 ms	Reconstitution, dont 80 à 150 ms mesurés pour le filtre conjoint
Délai avant premier jeton	400 à 700 ms	400 à 700 ms	Reconstitution
Délai avant premier fragment audio	150 à 250 ms	150 à 250 ms	Reconstitution
Transport et gigue réseau	50 à 100 ms	50 à 100 ms	Reconstitution
Total perçu	1,0 à 1,6 s	1,2 à 2,0 s	Somme

TABLE 4.8 – RÉPARTITION DU DÉLAI ENTRE LA FIN DE L'ÉNONCÉ ET LE DÉBUT DE LA RÉPONSE

Deux enseignements se dégagent de cette répartition. Le premier est que le raisonnement constitue le poste dominant, ce qui justifie l'attention portée au délai avant premier jeton dans le choix du modèle plutôt qu'à sa vitesse de génération globale. Le second est que la génération anticipée décrite plus haut retire une part de ce poste du délai perçu, ce qui explique qu'elle ait été retenue malgré le travail parfois abandonné qu'elle implique.

La figure 4.3 présente cette répartition sous forme graphique.




FIGURE 4.3 – RÉPARTITION DU BUDGET DE LATENCE PAR ÉTAPE

4.4 Concurrency et gestion des ressources

4.4.1 Deux échelles de concurrence

La plateforme doit gérer la concurrence à deux échelles distinctes, qui appellent des réponses différentes.

La première est celle des conversations simultanées. Plusieurs clients échangent en même temps avec la plateforme, et chacun doit disposer de son propre état sans interférence. La seconde est celle des opérations concurrentes à l'intérieur d'une même conversation. Ce cas est moins évident mais tout aussi réel : un client peut engager deux règlements au cours d'un même appel, et rien ne garantit que le second attendra la conclusion du premier.

4.4.2 Isolation des conversations

Chaque session est prise en charge par un processus de traitement distinct, doté de son propre état. Cet état contient l'identifiant de session, la langue courante, la situation du client, l'état de vérification d'identité avec son échéance, l'historique du sentiment, les compteurs de clarification et de transfert, et les identités des opérations engagées.

Ce cloisonnement par processus présente un avantage qui va au delà de l'isolation logique : une défaillance affectant une conversation ne se propage pas aux autres. Les processus sont par ailleurs créés et libérés selon l'activité réelle, de sorte que les ressources ne sont mobilisées que par les conversations effectivement en cours.

4.4.3 Isolation des opérations concurrentes

4.4.3.1 L'identité d'opération

Chaque opération sensible reçoit une identité propre, calculée à partir des éléments qui la définissent. Deux tentatives portant la même identité désignent la même opération : la seconde restitue le résultat de la première sans exécuter à nouveau. Deux opérations distinctes reçoivent des identités distinctes et s'exécutent indépendamment, y compris au sein de la même conversation.

4.4.3.2 Ce que l'identité ne doit pas contenir

La composition de cette identité a fait l'objet d'une correction significative, qui illustre la subtilité du problème.

Certains éléments du contexte transmis au moteur de règles servent au jugement sans définir l'opération. Le montant restant dû, le nombre de reports déjà accordés dans l'année, le nombre de réclamations ouvertes et l'état de la ligne appartiennent à cette catégorie. Or chacune de ces valeurs change entre une première tentative et sa reprise, et elle change précisément parce que la première tentative a abouti : le nombre de réclamations ouvertes passe de zéro à un dès qu'une réclamation est déposée, l'état de la ligne passe d'en attente à active dès qu'une activation est réalisée.

Les inclure aurait produit l'effet inverse de celui recherché : une reprise aurait présenté une identité différente, aurait été traitée comme une opération nouvelle, et aurait déposé une seconde réclamation. Ils sont donc exclus du calcul de l'identité tout en restant transmis au moteur de règles.

4.4.3.3 Garantie sous concurrence réelle

Un contrôle applicatif de l'identité ne suffit pas lorsque deux tentatives se présentent simultanément : les deux peuvent constater l'absence d'exécution antérieure avant que l'une d'elles n'ait écrit quoi que ce soit. La garantie est donc portée par la base de données, au moyen d'une contrainte d'unicité sur l'identité d'opération. La seconde écriture échoue, l'échec est intercepté, et la tentative est traitée comme une reprise. La propriété d'exécution au plus une fois tient ainsi même en situation de compétition, et non seulement dans le cas nominal.

4.4.4 Ordonnancement des écritures d'audit

Les enregistrements d'audit forment une chaîne dans laquelle chaque entrée intègre l'empreinte de la précédente. Cette structure impose que les ajouts soient sérialisés : deux écritures simultanées liraient la même empreinte précédente et produiraient une chaîne incohérente. Un verrou consultatif porté par la base de données garantit cette sérialisation pour la durée de la transaction.

Une seconde disposition mérite d'être signalée. L'écriture d'audit ne valide pas sa propre transaction : elle se contente de placer ses données en attente de validation dans la transaction en cours. L'enregistrement métier et son entrée d'audit sont donc validés ensemble ou abandonnés ensemble. Il devient impossible qu'une opération soit enregistrée sans sa trace, ou qu'une trace subsiste sans l'opération correspondante.

4.4.5 Isolation des écritures secondaires

La mise à jour des projections métier consécutive à une exécution est effectuée dans une transaction imbriquée. Cette disposition répond à une hiérarchie d'importance explicite : le

registre des actions et la chaîne d'audit constituent la vérité, les projections ne sont qu'une commodité de lecture. Un échec de projection est donc consigné comme tel sans annuler ni l'action ni sa trace, alors qu'une transaction unique aurait fait perdre l'ensemble pour une raison secondaire.

4.4.6 Découplage de l'enregistrement conversationnel

L'enregistrement des tours de parole obéit au même principe appliqué à la contrainte temps réel. La couche conversationnelle dépose ses éléments dans une file d'attente, opération dont le coût est constant et négligeable. Un traitement d'arrière plan vide cette file et effectue les écritures dans un fil d'exécution séparé.

La conséquence est déterminante : si la base de données devient indisponible, l'écriture est signalée puis abandonnée, et la conversation se poursuit sans que le client perçoive quoi que ce soit. Le choix est explicite et assumé. Perdre l'enregistrement d'un tour de parole est regrettable ; interrompre l'appel d'un client parce qu'un journal ne peut pas être écrit serait bien pire. Les données personnelles sont par ailleurs masquées à l'intérieur du processus conversationnel, avant même de rejoindre la file d'attente.

La figure 4.4 présente cette organisation.




FIGURE 4.4 – GESTION DE LA CONCURRENCE ET DES RESSOURCES

4.5 Architecture physique et évolution temporelle

4.5.1 Topologie de déploiement

La plateforme est déployée sous forme de vingt quatre conteneurs répartis en trois ensembles : six services d'infrastructure, seize services applicatifs développés dans le cadre du projet, et deux services d'observabilité. La figure 4.5 présente cette répartition, chaque conteneur y figurant avec le port qu'il expose.




FIGURE 4.5 – DIAGRAMME DE DÉPLOIEMENT DE LA PLATEFORME

Le processus agent est le seul composant à n'exposer aucun port d'écoute pour les requêtes métier. Il ne reçoit pas de requêtes : il se déclare auprès du serveur temps réel, qui lui affecte des sessions. Cette particularité est cohérente avec son rôle, celui d'un exécutant de sessions et non d'un fournisseur de service.

4.5.2 Chaîne d'observabilité

4.5.2.1 Une instrumentation qui ne dépend de rien

Un système temps réel dont on ne mesure pas le comportement en fonctionnement ne peut être ni diagnostiqué ni amélioré. Encore faut-il que la mesure existe réellement, et non seulement en principe.

La première version de l'instrumentation reposait entièrement sur un collecteur externe. Les temps de première réponse, les compteurs de bascule entre fournisseurs et l'identifiant de corrélation étaient tous conditionnés à la présence de ce collecteur et à la configuration d'un

point de collecte sur chaque service. Dans un déploiement ordinaire, aucun collecteur n'était démarré : les instruments écrivaient donc dans le vide, aucune requête ne portait d'identifiant de corrélation, et rien n'était collecté. L'observabilité existait dans le code sans exister à l'exécution, ce qui est une variante du défaut silencieux que nous avons rencontré ailleurs dans ce projet.

Les deux mécanismes ont été rendus inconditionnels. L'identifiant de corrélation est désormais toujours produit, par la bibliothèque standard seule. Les métriques sont toujours exposées par chaque service et récupérées directement sur celui ci, sans intermédiaire à configurer. Le chemin par collecteur subsiste et n'a pas été affaibli : l'activer ajoute les traces réparties, sans déplacer les métriques, car les fonctions d'enregistrement alimentent les deux destinations.

4.5.2.2 Collecte et restitution

Un service de collecte interroge toutes les quinze secondes le point de mesure des douze services instrumentés, en les désignant par leur nom de conteneur. Les mesures sont conservées quinze jours, durée suffisante pour observer un cycle hebdomadaire et une régression par rapport à ce cycle, sans que le volume stocké demande une surveillance particulière.

Un service de restitution en tire deux tableaux de bord. Le premier suit la santé de la plateforme : services actifs, débit, part de réponses en erreur, latence au quatre vingt quinzième centile et routes les plus lentes. Le second, plus spécifique, suit le comportement de la couche agentique : répartition des verdicts et son évolution, règles qui refusent et qui escaladent le plus, registre des actions par issue, déclencheurs d'escalade, notifications non délivrées, bascules de fournisseur, et délais de première réponse audible et de premier jeton par langue.

C'est le second qui présente le plus d'intérêt. Le premier décrirait n'importe quel service web, tandis que le second décrit cette plateforme en particulier, et la part de verdicts autorisés y constitue l'indicateur le plus révélateur : il se déplace avant tout le reste lorsqu'un seuil, un catalogue ou un système amont change.

4.5.2.3 Trois décisions de conception

Trois choix méritent d'être signalés, car ils conditionnent l'utilité de l'ensemble.

- **La cardinalité est bornée.** Une combinaison d'étiquettes engendre une série temporelle. Les mesures portent donc le gabarit de la route et non le chemin résolu, sans quoi chaque client engendrerait sa propre série, définitivement. Les autres étiquettes proviennent de vocabulaires fermés, et toute valeur venue de l'extérieur est tronquée. Une conséquence appréciable en découle : aucune donnée personnelle ne peut atteindre une étiquette, ce qui permet d'exposer les mesures sans les protéger par un secret, tout en gardant les accès restreints à la machine hôte.

- **Les tableaux de bord sont des fichiers.** Ils sont décrits dans le dépôt et non modifiés dans le navigateur, car un tableau de bord édité dans un conteneur et jamais exporté disparaît avec lui. Un générateur produit leur description, ce qui garantit que deux panneaux ajoutés à des moments différents partagent la même géométrie et la même façon d'exprimer un ratio.
- **Un panneau vide dit pourquoi il est vide.** Un panneau qui affiche la mention par défaut du produit ne se distingue pas d'un panneau en panne. Chacun déclare donc son propre message : l'absence d'erreur est présentée comme un résultat, l'absence d'appel comme une absence de données. Un ratio ne s'affiche jamais à zéro lorsque rien ne s'est produit, son dénominateur étant protégé, faute de quoi le tableau de bord annoncerait un fonctionnement sain à propos d'un trafic inexistant.

4.5.2.4 L'identifiant de corrélation

Chaque requête reçoit un identifiant unique, repris de l'appelant s'il en fournit un, extrait du contexte de trace lorsqu'il en existe un, et engendré sinon. Cet identifiant suit le traitement, les appels qu'il déclenche et les tâches d'arrière plan qu'il programme, et il figure dans chaque ligne de journal produite par l'un d'eux. Il est également renvoyé au client dans la réponse.

Il n'est volontairement pas conservé au delà du traitement. Une connexion persistante sert plusieurs requêtes successives, et un identifiant laissé en place attribuerait à la requête suivante celui de la précédente. Une piste fausse au cours d'un incident coûte davantage qu'une piste manquante.

4.5.3 Une protection au démarrage

La configuration de chaque service provient exclusivement de variables d'environnement, ce qui permet à un même artefact de fonctionner dans les deux modes d'exécution sans modification.

Cette souplesse comporte un risque, contre lequel une protection explicite a été mise en place. Si deux services se voient attribuer la même adresse par erreur de configuration, le processus agent refuse de démarrer. Sans cette vérification, la défaillance serait particulièrement pernicieuse : le système interrogerait un service pour un autre et recevrait une réponse valide mais sans rapport avec la question posée. Aucun test ne détecterait cette situation, et rien dans le comportement observable ne la signalerait. Un refus de démarrage bruyant vaut mieux qu'un fonctionnement silencieusement erroné.

4.5.4 Évolution temporelle d'un échange

La figure 4.6 présente le chronogramme d'un échange complet, depuis l'établissement de la session jusqu'à la restitution de la réponse. Il fait apparaître ce que le budget de latence présenté plus haut ne montre pas : le recouvrement partiel des étapes.

Trois recouvrements y sont visibles. La transcription s'effectue pendant que le client parle et non après. La génération de la réponse débute avant la confirmation de fin de tour, grâce à la génération anticipée. La synthèse vocale émet ses premiers fragments avant que la réponse complète ne soit produite. C'est ce recouvrement qui explique que le délai perçu soit sensiblement inférieur à la somme des durées.




FIGURE 4.6 – CHRONOGRAMME D'UN ÉCHANGE CONVERSATIONNEL COMPLET

4.6 Interfaces de l'application

Deux interfaces web complètent la plateforme : un portail destiné au client et une console destinée aux profils internes. Nous ne présentons ici que les écrans qui rendent visible un mécanisme décrit dans ce rapport.

4.6.1 Portail client

Le portail s'organise autour de l'assistant conversationnel, les autres écrans donnant accès aux informations que la conversation peut mobiliser. La planche 4.7 présente l'assistant en session et la situation de facturation, la planche 4.8 les demandes du client et l'historique de ses échanges.




FIGURE 4.7 – PORTAIL CLIENT : ASSISTANT CONVERSATIONNEL ET FACTURATION




FIGURE 4.8 – PORTAIL CLIENT : DEMANDES EN COURS ET HISTORIQUE DES ÉCHANGES

Un rappel négocié pendant une conversation apparaît sur cette dernière planche avec le créneau réellement réservé, ce qui rend visible la continuité entre l'échange parlé et l'espace personnel.

4.6.2 Console d'administration et de supervision

La console expose les surfaces de supervision et de gouvernance. Deux écrans méritent une présentation isolée car ils rendent observables les garanties centrales de la plateforme.

La figure 4.9 présente l'inspection des décisions. Pour une action donnée y figurent la proposition formulée, le verdict rendu, l'identifiant de la règle appliquée et sa justification. Cet écran permet de répondre non seulement à la question de savoir ce qui a été décidé, mais à celle de savoir en vertu de quoi.




FIGURE 4.9 – CONSOLE D’ADMINISTRATION : INSPECTION DES DÉCISIONS ET DES VERDICTS

La figure 4.10 présente le registre d’audit. Elle ne se contente pas d’afficher les enregistrements : elle rend compte du recalcul de la chaîne d’empreintes et signale toute discordance, ce qui matérialise la propriété de traçabilité vérifiable.




FIGURE 4.10 – CONSOLE D’ADMINISTRATION : REGISTRE D’AUDIT ET VÉRIFICATION D’INTÉGRITÉ

Les planches 4.11 et 4.12 rassemblent les autres surfaces de supervision : la vue d’ensemble opérationnelle et l’historique des appels, puis la gouvernance des règles et de la base documentaire.




FIGURE 4.11 – CONSOLE D’ADMINISTRATION : SUPERVISION DE L’ACTIVITÉ




FIGURE 4.12 – CONSOLE D'ADMINISTRATION : GOUVERNANCE DU COMPORTEMENT

La planche 4.13 présente enfin les surfaces d'escalade : les cas transmis à un conseiller avec leur motif, et le registre des conseillers dont les créneaux alimentent la négociation d'un rappel.




FIGURE 4.13 – CONSOLE D'ADMINISTRATION : ESCALADE ET DISPONIBILITÉS

4.6.3 Systèmes intégrés et environnement d'exécution

La planche 4.14 établit que les intégrations décrites opèrent sur des systèmes réels : un ticket créé par la plateforme y figure dans le système de gestion de tickets de l'organisation, avec le vocabulaire de ce système, et le corpus documentaire y apparaît indexé.




FIGURE 4.14 – INTÉGRATIONS EFFECTIVES

Les deux tableaux de bord décrits à la section précédente constituent la surface d'exploitation de la plateforme. La planche 4.15 les présente : la santé des services d'un côté, le comportement de la couche agentique de l'autre.




FIGURE 4.15 – TABLEAUX DE BORD DE SUPERVISION

La planche 4.16 présente enfin la collecte elle même et la topologie en fonctionnement, cette dernière confrontant le diagramme de déploiement de la figure 4.5 à son exécution réelle.




FIGURE 4.16 – COLLECTE DES MESURES ET TOPOLOGIE EN EXÉCUTION

4.7 Vérification et évaluation

4.7.1 Principe retenu

La vérification d'un système conversationnel se heurte à une difficulté propre : une partie de son comportement n'est pas déterministe. Il serait vain d'exiger d'un modèle de langue qu'il produise deux fois la même phrase.

Nous avons donc retenu un principe simple. Ce qui doit être garanti quelles que soient les circonstances est rendu déterministe par conception, et vérifié comme tel. Ce qui relève de l'interprétation est évalué sur son comportement observable et non sur sa formulation. Ainsi, la vérification ne porte pas sur les mots employés pour refuser une opération, mais sur le fait qu'elle soit effectivement refusée, avec le bon motif.

4.7.2 Familles de vérifications

La figure 4.17 présente les familles de vérifications constituées au cours du projet et la propriété que chacune protège.

Comportement déterministe	Règles et verdicts Un contexte donné produit toujours le même verdict, la même règle et la même justification.	Identité d'opération Une reprise ne produit jamais une seconde exécution, même si le contexte a changé.	Vérification d'identité Tentatives bornées, hiérarchie des délais respectée, entrée inexploitable sans coût.	Abstention documentaire Sans passage franchissant les filtres, la réponse est un aveu d'ignorance.
	Cohérence des personas Les instructions d'un agent ne mentionnent aucune capacité qu'il ne possède pas.	Transfert et escalade Un transfert est terminal ; un rappel ne coexiste jamais avec un transfert abouti.	Mécontentement L'accumulation suit le comportement attendu et déclenche l'escalade au seuil prévu.	Interruption L'interruption arrête la restitution et consigne ce qui a réellement été prononcé.
	Résilience des fournisseurs La défaillance provoquée du principal déclenche le repli sans couper la session.	Enregistrement Les tours sont consignés hors du chemin critique ; une panne de stockage n'affecte rien.	Multilinguisme L'échange suit la langue du client et un changement en cours est pris en compte.	Journalisation Délais de première réponse et jetons consommés sont collectés et bien attribués.

*Ce qui doit être garanti en toutes circonstances est rendu déterministe par conception, puis vérifié comme tel.
Ce qui relève de l'interprétation est évalué sur son comportement observable, jamais sur sa formulation.*

FIGURE 4.17 – FAMILLES DE VÉRIFICATIONS ET PROPRIÉTÉS PROTÉGÉES

4.7.3 Vérification par injection de défaillance

La chaîne de repli présente une difficulté de vérification bien connue : elle ne s'exerce jamais en fonctionnement nominal, et un mécanisme de secours jamais éprouvé est un mécanisme dont on ignore s'il fonctionne.

Le système comporte donc un dispositif d'injection de défaillance, activable par configuration pour chacune des trois étapes dépendant de fournisseurs externes. Ce dispositif substitue au fournisseur principal une configuration invalide, ce qui provoque son échec réel et non simulé. Le chemin de repli est ainsi exercé dans les conditions exactes de son déclenchement en production, et la vérification porte sur la continuité effective de la session.

4.7.4 Contrôle d'intégrité

La vérification de la chaîne d'audit constitue une catégorie à part, puisqu'elle porte sur les données et non sur le code. Un traitement dédié recalcule l'ensemble de la chaîne d'empreintes et signale toute discordance entre l'empreinte enregistrée et l'empreinte recalculée. Ce contrôle est accessible depuis la console d'administration et peut être exécuté périodiquement.

4.8 Résultats et statistiques

4.8.1 Statut des mesures présentées

Cette section appelle une précision méthodologique préalable, énoncée sans détour.

Les mesures relatives à la qualité de la recherche documentaire sont réelles. Elles ont été obtenues au moyen d'un instrument de sondage développé pour ce projet et exécuté sur le corpus réel. Elles sont reproduites telles qu'obtenues.

Les mesures de latence de bout en bout, en revanche, procèdent d'une reconstitution. La chaîne d'observabilité décrite plus haut relève bien ces grandeurs en continu, et les tableaux de bord les affichent par langue ; mais une campagne conduite sur une période représentative, avec exécutions répétées et analyse statistique, n'a pas pu être menée dans le temps imparti au projet. Les valeurs présentées sont donc établies à partir de l'architecture réelle, de la configuration réelle et du comportement observé de chaque composant, avec une volonté délibérée de rester en deçà plutôt qu'au delà des performances plausibles. Elles décrivent un comportement attendu et cohérent, non un relevé expérimental.

La distinction est doublement utile. Elle évite de présenter comme mesuré ce qui ne l'est pas, et elle circonscrit précisément ce qui reste à faire : l'instrument existe et fonctionne, seule la campagne manque.

4.8.2 Qualité de la recherche documentaire

4.8.2.1 Le problème du seuil unique

L'instrument de sondage a produit un résultat qui a orienté toute la conception de cette étape. Le tableau 4.9 présente les scores de proximité obtenus sur le corpus, pour des questions posées dans les trois langues, accompagnés d'une question de contrôle sans rapport avec le domaine.

Question	Meilleur score	Bruit conservé au seuil relatif 0,93	Verdict
Activation de l'itinérance, en anglais	0,8953	aucun	correct
Activation de l'itinérance, en français	0,8606	aucun	correct
Activation de l'itinérance, en arabe	0,8310	un document sans rapport à 0,965	fuite
Lenteur de la connexion, en anglais	0,8670	trois documents entre 0,944 et 0,964	fuite
Question de contrôle hors domaine	0,7880	tous écartés	correct

TABLE 4.9 – SCORES DE PROXIMITÉ MESURÉS SUR LE CORPUS DOCUMENTAIRE

Deux enseignements se dégagent de ce relevé.

Le premier concerne l'écart disponible. La question de contrôle, sans aucun rapport avec le domaine, atteint tout de même 0,7880. Une bonne réponse en anglais atteint 0,8953. La marge séparant le bruit d'une réponse correcte n'est donc que de 0,107 en anglais, de 0,073 en français et de 0,043 en arabe.

Le second concerne l'asymétrie linguistique, qui est structurelle et non un artefact de réglage. La similarité entre deux langues différentes est systématiquement inférieure à la similarité au sein d'une même langue, indépendamment du sens. Un seuil unique appliqué aux trois langues est donc environ deux fois et demie plus contraignant pour l'arabe que pour l'anglais. C'est la raison pour laquelle les faux négatifs en arabe constituent le premier mode de défaillance à surveiller.

4.8.2.2 L'inversion qui a imposé une évaluation conjointe

Une seconde mesure, plus décisive encore, a été relevée sur un corpus élargi. Une question de contrôle portant sur la réparation d'un appareil ménager, donc totalement étrangère au domaine, a obtenu un score de 0,8411 contre un document traitant de problèmes de connexion. Dans le même relevé, une question légitime posée en arabe au sujet de l'itinérance internationale a obtenu 0,8310 contre le document qui y répond effectivement.

Une question sans aucun rapport avec le domaine a donc mieux scoré qu'une réponse correcte. Les deux distributions ne sont pas seulement resserrées, elles sont inversées. Aucun seuil, si finement réglé soit il, ne peut écarter ce bruit sans écarter du même mouvement toutes les réponses en arabe.

L'explication est structurelle. Une comparaison par représentations indépendantes encode la question d'un côté et le passage de l'autre, puis compare deux résumés. Elle ne peut donc distinguer une proximité de forme d'une proximité de sens, et elle pénalise systématiquement les paires interlingues. Une évaluation lisant conjointement la question et le passage, avec attention complète sur les deux, ne subit pas cette limite [11]. Le modèle retenu pour cette étape a été entraîné sur un jeu de données multilingue dédié au classement de passages [12], ce qui le rend utilisable sur les trois langues du projet.

C'est ce constat, et non une préférence théorique, qui a imposé le filtre conjoint décrit plus haut. La figure 4.18 présente cette comparaison.




FIGURE 4.18 – SÉPARATION ENTRE RÉPONSES PERTINENTES ET BRUIT SELON LA MÉTHODE D'ÉVALUATION

4.8.2.3 Coût de la solution retenue

Un modèle d'évaluation conjointe de grande taille a d'abord été évalué. Sa qualité est supérieure, mais son encombrement d'environ un gigaoctet et son temps de traitement de deux à cinq secondes par question l'excluent d'une chaîne conversationnelle. Il n'a été conservé qu'à des fins d'évaluation différée.

Le modèle finalement retenu occupe environ cent dix huit mégaoctets et traite les candidats en quatre vingts à cent cinquante millisecondes. Cette réduction d'un ordre de grandeur du coût, pour une qualité restant suffisante sur la tâche visée, n'a été possible que parce que ce filtre s'applique en dernier, à un nombre de candidats déjà fortement réduit. Le tableau 4.10 récapitule cette comparaison.

Modèle	Taille	Temps par question	Décision
Évaluation conjointe de grande taille	environ 1,1 Go	2 à 5 s	Écarté de la chaîne temps réel, conservé pour l'évaluation différée
Évaluation conjointe compacte	environ 118 Mo	80 à 150 ms	Retenu, appliqué en dernier filtre
Encodage sémantique	118 millions de paramètres	quelques millisecondes	Retenu, premier filtre
Encodage lexical	négligeable	quelques millisecondes	Retenu, filtre complémentaire

TABLE 4.10 – COMPARAISON DES MODÈLES ÉVALUÉS POUR LA RECHERCHE DOCUMENTAIRE

4.8.3 Volumétrie du système réalisé

La figure 4.19 récapitule les grandeurs qui caractérisent l'étendue du système produit.

Déploiement	24 conteneurs déployés <i>6 infra, 16 applicatifs, 2 observabilité</i>	13 interfaces déclarées par le domaine	10 bibliothèques partagées	16 modules de persistance
Surfaces exposées	73 points d'accès de l'interface métier	35 écrans <i>20 en console, 15 au portail</i>	5 agents spécialisés	3 domaines métier déclarés
Périmètre et travail	9 types d'opérations sensibles reconnues	3 langues prises en charge	112 incréments livrés	260 validations enregistrées

FIGURE 4.19 – VOLUMÉTRIE DU SYSTÈME RÉALISÉ

4.8.4 Comportement en situation de défaillance

Le tableau 4.11 présente le comportement observé lors des exercices d'injection de défaillance.

Défaillance provoquée	Comportement attendu	Comportement observé
Fournisseur de transcription principal	Passage au fournisseur suivant sans interruption	Session poursuivie, transition non perceptible par le client
Modèle de langue principal	Passage au fournisseur suivant après expiration du délai de tentative	Session poursuivie, allongement du délai de réponse sur le tour concerné
Fournisseur de synthèse principal	Passage au fournisseur suivant sans silence	Session poursuivie, changement de voix perceptible
Base de données indisponible	Perte des enregistrements, conversation préservée	Conversation poursuivie normalement, écritures signalées puis abandonnées
Service documentaire indisponible	Aveu d'ignorance plutôt que réponse infondée	Réponse d'abstention énoncée au client
Aucun conseiller disponible	Proposition de rappel sur créneau réel	Créneau proposé, réservé et confirmé

TABLE 4.11 – COMPORTEMENT DU SYSTÈME EN SITUATION DE DÉFAILLANCE PROVOQUÉE

Le changement de voix perceptible lors du repli de synthèse vocale mérite un commentaire. Il constitue une dégradation assumée : maintenir une voix identique aurait exigé de restreindre le choix des fournisseurs à ceux proposant une voix comparable, ce qui aurait réduit la profondeur de la chaîne de repli. Nous avons préféré une conversation qui se poursuit avec une voix différente à une conversation qui s'interrompt avec la bonne voix.

4.9 Problèmes rencontrés

Nous rapportons ici les difficultés qui ont eu un effet réel sur la conception, en écartant les incidents ordinaires de développement. Chacune est présentée selon la même progression : le constat, l'analyse, la décision et le résultat.

4.9.1 Une dégradation silencieuse de la recherche documentaire

Le constat fut d'abord favorable en apparence. L'assistant répondait aux questions documentaires, les réponses paraissaient plausibles, et rien dans son comportement ne signalait d'anomalie.

L'analyse a révélé une situation nettement moins satisfaisante. Le mécanisme de construction du composant de recherche prévoyait un repli vers une méthode lexicale rudimentaire en cas d'échec du chemin vectoriel. Or ce chemin échouait systématiquement, pour une raison de configuration héritée d'une étape antérieure du projet. L'assistant répondait donc en réalité par

simple recouvrement de termes sur un corpus réduit chargé en mémoire, tout en présentant les caractéristiques extérieures d'un système à recherche vectorielle.

La décision fut de supprimer purement et simplement ce repli. La conclusion qui s'est imposée à cette occasion a ensuite guidé plusieurs autres choix du projet : une dégradation silencieuse est pire qu'une panne. Une panne se voit et se corrige. Une dégradation silencieuse produit des réponses plausibles que personne ne remet en question. Le composant signale désormais son incapacité et le service refuse de répondre, ce qui est bruyant, visible et corrigible.

4.9.2 L'inversion des scores de similarité

Le constat a été établi par la mesure rapportée plus haut : une question hors domaine obtenait un meilleur score qu'une réponse correcte en arabe.

L'analyse a montré que le problème ne relevait pas du réglage mais de la méthode. Aucune valeur de seuil ne pouvait séparer deux distributions inversées. Plusieurs journées ont été consacrées à l'ajustement des seuils avant que cette conclusion ne s'impose, et c'est la construction d'un instrument de sondage systématique qui l'a rendue évidente.

La décision fut d'ajouter une étape d'évaluation conjointe, en la plaçant en dernier et en la restreignant aux candidats survivants pour en rendre le coût acceptable. Le résultat est une séparation nette entre le bruit et les réponses pertinentes, obtenue pour un surcoût de l'ordre de la centaine de millisecondes.

L'enseignement dépasse le cas particulier. Le temps consacré à construire l'instrument de mesure a été très inférieur au temps qu'aurait consommé la poursuite des ajustements empiriques, et c'est lui qui a permis de comprendre le problème plutôt que d'en déplacer les symptômes.

4.9.3 Un modèle de mécontentement à la fois trop sensible et trop indulgent

Le constat provenait de deux observations contradictoires. Des conversations parfaitement ordinaires étaient signalées comme conflictuelles, tandis que des clients manifestement mécontents ne l'étaient pas.

L'analyse a établi que le modèle initial cumulait deux défauts opposés. Un unique terme négatif portait le score au maximum, ce qui expliquait les faux positifs. Tout tour non négatif remettait le compteur à zéro, ce qui expliquait les faux négatifs chez un client constamment mécontent mais courtois.

La décision fut de remplacer le comptage par une accumulation pondérée, dans laquelle un tour négatif fait progresser un score, un tour positif le fait décroître, et l'agressivité pèse

davantage. Le seuil a été calibré pour préserver le comportement de référence à trois tours négatifs. Le résultat figure au tableau présenté au chapitre précédent.

4.9.4 Un risque de confusion entre services

Le constat a été fait lors d'une exécution en mode développement, où deux services se sont trouvés configurés avec la même adresse.

L'analyse a montré la gravité particulière de cette situation. Le service interrogé répondait correctement à une question qui ne lui était pas destinée. Aucune erreur n'était levée, aucun journal ne signalait d'anomalie, et le système continuait de fonctionner en produisant des résultats valides dans leur forme mais sans rapport avec la demande. Aucun test existant ne pouvait détecter cela, puisque chaque composant se comportait correctement.

La décision fut d'ajouter au démarrage une vérification refusant l'exécution lorsque deux services partagent une adresse. Le résultat est un échec immédiat et explicite au lancement, préféré à un fonctionnement silencieusement erroné.

4.9.5 Une identité d'opération trop inclusive

Le constat s'est manifesté lors de la vérification de la reprise des opérations : une seconde réclamation était déposée alors que le mécanisme d'exécution unique aurait dû l'empêcher.

L'analyse a identifié la cause. L'identité de l'opération incluait des éléments du contexte transmis au moteur de règles, dont le nombre de réclamations ouvertes. Or cette valeur passait de zéro à un précisément parce que la première tentative avait réussi. La reprise présentait donc une identité différente et était traitée comme une opération nouvelle. Le mécanisme fonctionnait exactement comme il était écrit, mais il avait été écrit sur une définition erronée de l'identité.

La décision fut de distinguer explicitement les éléments qui définissent une opération de ceux qui servent seulement à la juger, et d'exclure les seconds du calcul de l'identité tout en les conservant dans le contexte transmis aux règles. Le résultat est une propriété d'exécution unique effective, y compris lorsque l'état du client évolue entre une tentative et sa reprise.

4.9.6 La contrainte de mémoire et ses conséquences

Le constat s'est imposé progressivement. Le poste de développement devait accueillir simultanément vingt deux conteneurs applicatifs et d'infrastructure, les modèles d'encodage documentaire et les environnements de développement des deux interfaces, dans seize gigaoctets de mémoire.

L'analyse a conduit à hiérarchiser les besoins plutôt qu'à chercher un gain uniforme. Les modèles exécutés localement constituaient le poste dominant, et c'est là que les décisions ont porté.

Les décisions prises ont été au nombre de trois. Un modèle d'évaluation conjointe d'environ un gigaoctet a été écarté au profit d'un modèle de cent dix huit mégaoctets. L'exécution locale d'un modèle de langue a été évaluée puis abandonnée dans les conditions du projet. Les modèles d'encodage retenus ont été choisis dans leur variante quantifiée pour processeur, sans dépendance à un matériel graphique.

Le résultat dépasse la simple tenue dans l'enveloppe disponible. Cette contrainte a produit une architecture dont les composants les plus coûteux sont placés en dernier dans la chaîne et ne traitent qu'un nombre réduit de candidats. Une machine plus dotée aurait probablement conduit à une conception moins soignée sur ce point.

Conclusion

Ce chapitre a exposé la réalisation de la plateforme. Nous avons présenté les technologies retenues et les critères qui ont présidé à leur sélection, en situant précisément le rôle du cadriciel temps réel par rapport au travail d'ingénierie propre au projet. Nous avons ensuite détaillé la chaîne de traitement temps réel étape par étape, chacune accompagnée de sa métrique, de ses solutions écartées et du coût de la solution retenue.

La gestion de la concurrence a montré comment les conversations et les opérations sont isolées les unes des autres, et comment les garanties d'exécution unique et d'intégrité de la trace résistent à des accès simultanés. L'architecture physique a établi la correspondance entre la conception et les vingt quatre conteneurs effectivement déployés, et décrit la chaîne d'observabilité qui rend le comportement du système mesurable en fonctionnement. Les interfaces ont donné à voir les surfaces produites pour le client comme pour les profils internes.

La campagne de vérification a enfin été présentée, ainsi que les résultats obtenus, en distinguant explicitement les mesures réelles des valeurs reconstituées. Les difficultés rencontrées ont été rapportées avec leur analyse et leur résolution, car plusieurs d'entre elles ont infléchi la conception plus profondément que ne l'aurait fait une exécution sans obstacle.



Conclusion Générale

Ce projet de fin d'études a été mené au sein de la société Amsys Consulting, dans le prolongement de son activité en intelligence artificielle et en ingénierie logicielle. La plateforme développée s'adresse aux opérateurs de télécommunications qui cherchent à prendre en charge automatiquement les demandes courantes de leurs abonnés sans renoncer au contrôle de ce que le système fait en leur nom. Elle se situe à l'intersection de trois domaines que le projet a dû articuler plutôt que juxtaposer : les systèmes conversationnels temps réel, la recherche d'information ancrée dans un corpus documentaire, et l'architecture logicielle appliquée à des opérations métier sensibles. Le cadre de sécurité et les pratiques d'observabilité de la société ont directement orienté plusieurs des choix présentés dans ce rapport.

Le travail réalisé a consisté à concevoir puis à construire cette plateforme dans son ensemble. Nous avons établi une architecture en ports et adaptateurs plaçant les règles métier hors d'atteinte des dépendances techniques, et découpé le domaine en contextes délimités communiquant par contrats explicites. Nous avons réalisé une chaîne de traitement vocale temps réel complète, dont chaque étape dispose d'une solution de repli éprouvée par injection de défaillance, et dont le budget de latence a été analysé étape par étape. Nous avons construit une couche agentique organisée autour de cinq agents spécialisés, dont le contexte est assemblé selon les besoins plutôt qu'accumulé, et dont les instructions sont dérivées des capacités réellement détenues, ce qui interdit qu'un agent soit invité à faire ce qu'il ne peut pas faire. Nous avons mis en place une chaîne documentaire dont la sélection procède par filtres successifs et dont la propriété première est de savoir se taire lorsque le corpus ne répond pas, propriété obtenue à la suite de mesures qui ont invalidé une approche initiale par seuil unique. Nous avons enfin réalisé la chaîne de décision, de politique et d'exécution qui protège les opérations sensibles, avec verdict motivé, exécution garantie unique et registre d'intégrité vérifiable, ainsi que les deux interfaces web et le dispositif d'observabilité qui rendent l'ensemble exploitable. Le système compte aujourd'hui vingt quatre services conteneurisés, treize interfaces de domaine, soixante treize points d'accès applicatifs et trente cinq écrans, livrés au fil de cent douze incréments successifs.

Plusieurs perspectives se dégagent de ce travail, toutes réalisables à partir de l'état actuel du système. La première est la conduite d'une campagne de mesure instrumentée complète, avec exécutions répétées et analyse statistique, qui viendrait remplacer par des relevés expérimentaux les valeurs de latence reconstituées présentées dans ce rapport ; l'instrumentation nécessaire est

déjà en place et relève ces grandeurs en continu, de sorte que cette campagne relève désormais de l'exploitation et non du développement. La deuxième porte sur la recherche documentaire : l'asymétrie linguistique mise en évidence par les mesures justifierait des seuils différenciés par langue, ainsi qu'un élargissement du corpus permettant de vérifier que les réglages retenus sur un ensemble restreint se maintiennent à plus grande échelle. La troisième concerne l'exécution locale du modèle de raisonnement, écartée dans les conditions matérielles du projet mais redevenue envisageable sur une machine dotée d'un accélérateur graphique adapté, l'architecture ayant précisément été conçue pour que ce changement ne se propage pas au delà de la couche qui l'intègre. La quatrième consisterait à étendre la couverture métier en ajoutant de nouveaux domaines de spécialité, opération que la déclaration unique des domaines rend peu coûteuse. La cinquième, enfin, viserait l'ouverture de la plateforme à d'autres canaux que la voix et le texte, la couche de domaine étant déjà indépendante du canal d'entrée. Au delà du secteur des télécommunications, l'organisation retenue, qui associe une couche conversationnelle à une chaîne de décision déterministe et vérifiable, s'applique à tout domaine où un système automatisé doit agir sur des données engageant un client et rendre compte de ses décisions.



Bibliographie

- [1] E. Evans, *Domain Driven Design : Tackling Complexity in the Heart of Software*, Addison Wesley, 2003.
- [2] A. Cockburn, *Hexagonal Architecture : Ports and Adapters*, article de référence sur le patron d'architecture en ports et adaptateurs, 2005.
- [3] R. C. Martin, *Clean Architecture : A Craftsman's Guide to Software Structure and Design*, Prentice Hall, 2017.
- [4] E. Gamma, R. Helm, R. Johnson et J. Vlissides, *Design Patterns : Elements of Reusable Object Oriented Software*, Addison Wesley, 1994.
- [5] M. Fowler, *Patterns of Enterprise Application Architecture*, Addison Wesley, 2002.
- [6] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser et I. Polosukhin, *Attention Is All You Need*, Advances in Neural Information Processing Systems 30, 2017.
- [7] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel et D. Kiela, *Retrieval Augmented Generation for Knowledge Intensive NLP Tasks*, Advances in Neural Information Processing Systems 33, 2020. arXiv :2005.11401.
- [8] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder et F. Wei, *Multilingual E5 Text Embeddings : A Technical Report*, arXiv :2402.05672, 2024.
- [9] S. E. Robertson et H. Zaragoza, *The Probabilistic Relevance Framework : BM25 and Beyond*, Foundations and Trends in Information Retrieval, vol. 3, n° 4, p. 333 à 389, 2009.
- [10] G. V. Cormack, C. L. A. Clarke et S. Buettcher, *Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods*, Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval, Boston, p. 758 à 759, 2009.
- [11] R. Nogueira et K. Cho, *Passage Re ranking with BERT*, arXiv :1901.04085, 2019.
- [12] L. Bonifacio, V. Jeronimo, H. Q. Abonizio, I. Campiotti, M. Fadaee, R. Lotufo et R. Nogueira, *mMARCO : A Multilingual Version of the MS MARCO Passage Ranking Dataset*, arXiv :2108.13897, 2021.
- [13] C. Percival et S. Josefsson, *The scrypt Password Based Key Derivation Function*, RFC 7914, Internet Engineering Task Force, 2016.

- [14] National Institute of Standards and Technology, *Secure Hash Standard*, FIPS PUB 180-4, 2015.
- [15] J. Rosenberg, H. Schulzrinne, G. Camarillo, A. Johnston, J. Peterson, R. Sparks, M. Handley et E. Schooler, *SIP : Session Initiation Protocol*, RFC 3261, Internet Engineering Task Force, 2002.
- [16] H. Alvestrand, *Overview : Real Time Protocols for Browser Based Applications*, RFC 8825, Internet Engineering Task Force, 2021.
- [17] PolyAI, *Agent Studio : plateforme d'agents vocaux pour centres de contact*, documentation produit de l'éditeur, 2026.
- [18] Cognigy, *Cognigy.AI : plateforme agentique pour l'expérience client*, documentation produit de l'éditeur, 2026.
- [19] Parloa, *AI Agent Management Platform for Contact Centers*, documentation produit de l'éditeur, 2026.



Nétographie

Les ressources suivantes constituent la documentation technique officielle des composants employés dans le projet. Elles ont été consultées de manière continue pendant la réalisation.

- [N1] Documentation de LiveKit, cadriciel de communication temps réel. <https://docs.livekit.io>
Consulté le 23 août 2026.
- [N2] Documentation de Qdrant, moteur d'index vectoriel. <https://qdrant.tech/documentation>
Consulté le 23 août 2026.
- [N3] Documentation de PostgreSQL, système de gestion de base de données relationnelle. <https://www.postgresql.org/docs>
Consulté le 23 août 2026.
- [N4] Documentation de FastAPI, cadriciel de services web. <https://fastapi.tiangolo.com>
Consulté le 23 août 2026.
- [N5] Documentation de SQLAlchemy et d'Alembic, couche de persistance et gestion des migrations. <https://docs.sqlalchemy.org>
Consulté le 23 août 2026.
- [N6] Documentation de Deepgram, service de transcription de la parole. <https://developers.deepgram.com>
Consulté le 23 août 2026.
- [N7] Documentation de Cartesia, service de synthèse vocale. <https://docs.cartesia.ai>
Consulté le 23 août 2026.
- [N8] Documentation de l'API Gemini, service de modèle de langue. <https://ai.google.dev/gemini-api/docs>
Consulté le 23 août 2026.
- [N9] Spécification du Model Context Protocol, protocole de mise à disposition de capacités. <https://modelcontextprotocol.io>
Consulté le 23 août 2026.

- [N10] Documentation de GLPI, système de gestion de tickets, et de son interface REST. <https://glpi-project.org>
Consulté le 23 août 2026.
- [N11] Documentation d'OpenTelemetry, cadre de collecte de traces et de métriques. <https://opentelemetry.io/docs>
Consulté le 23 août 2026.
- [N12] Documentation de Prometheus, système de collecte de métriques. <https://prometheus.io/docs>
Consulté le 23 août 2026.
- [N12b] Documentation de Grafana, restitution des métriques sous forme de tableaux de bord. <https://grafana.com/docs>
Consulté le 24 août 2026.
- [N13] Documentation de MinIO, stockage d'objets compatible S3. <https://min.io/docs>
Consulté le 23 août 2026.
- [N14] Documentation de Docker et de Docker Compose, environnement de conteneurisation. <https://docs.docker.com>
Consulté le 23 août 2026.
- [N15] Documentation de TanStack Start et de React, cadres des interfaces web. <https://tanstack.com/start>
Consulté le 23 août 2026.
- [N16] Fiche du modèle `intfloat/multilingual-e5-small` sur Hugging Face. <https://huggingface.co/intfloat/multilingual-e5-small>
Consulté le 23 août 2026.
- [N17] Fiche du modèle `cross-encoder/mmarco-mMiniLMv2-L12-H384-v1` sur Hugging Face. <https://huggingface.co/cross-encoder/mmarco-mMiniLMv2-L12-H384-v1>
Consulté le 23 août 2026.
- [N18] Projet Silero VAD, détection d'activité vocale. <https://github.com/snakers4/silero-vad>
Consulté le 23 août 2026.



Annexe A : Fondements de la recherche augmentée par récupération

Cette annexe complète les explications fonctionnelles données au fil des chapitres. Les notions y sont regroupées par thème et présentées par paires, car la plupart des confusions rencontrées sur ce sujet portent moins sur une définition isolée que sur la distinction entre deux notions voisines.

A.1 Représentation des textes

- **Vectorisation et plongement.** La vectorisation désigne toute conversion d'un texte en nombres, y compris par des méthodes non sémantiques fondées sur le comptage de termes. Le plongement désigne spécifiquement une représentation produite par un réseau de neurones, qui capture le sens plutôt que la forme.
- **Représentation dense et représentation creuse.** Une représentation dense comporte majoritairement des valeurs non nulles et porte le sens. Une représentation creuse comporte majoritairement des zéros, chaque dimension correspondant à un terme du vocabulaire, et porte la correspondance lexicale exacte.
- **Modèle symétrique et modèle asymétrique.** Un modèle symétrique encode de la même façon deux textes de même nature. Un modèle asymétrique distingue le rôle de chaque texte, la question d'un côté et le passage de l'autre, et exige que ce rôle lui soit indiqué. Le modèle retenu dans ce projet appartient à la seconde catégorie.
- **Plongement de question et plongement de passage.** Le premier est calculé au moment de la recherche et se trouve donc soumis à la contrainte de temps. Le second est calculé lors de l'ingestion, hors ligne, ce qui autorise un traitement plus coûteux.

A.2 Structure du corpus

- **Document et fragment.** Le document est le fichier source complet. Le fragment est une portion de taille adaptée à la récupération, reliée à son document d'origine, et pouvant recouvrir partiellement le fragment voisin.

- **Stratégie de segmentation et taille de segmentation.** La stratégie désigne la méthode de découpage, par exemple le respect des paragraphes ou l’usage d’une fenêtre glissante. La taille désigne la longueur cible d’un fragment. La première détermine si un fragment demeure une unité de sens, la seconde son coût.
- **Index et base de données.** L’index est la structure de recherche qui rend la comparaison rapide. La base de données conserve les documents, les fragments et leurs métadonnées. Dans ce projet, la base est la source de vérité et l’index en est un dérivé reconstituable.

A.3 Recherche et sélection

- **Similarité et pertinence.** La similarité est une grandeur mathématique, la proximité de deux représentations dans un espace. La pertinence est l’utilité réelle d’un passage pour répondre à la question. Les mesures rapportées au chapitre de réalisation montrent que les deux peuvent diverger.
- **Recherche sémantique et recherche vectorielle.** La recherche sémantique désigne toute recherche par le sens. La recherche vectorielle en est une technique particulière, fondée sur la comparaison de représentations.
- **Sélection des k premiers et sélection par seuil.** La première renvoie toujours exactement k résultats, quelle que soit leur qualité. La seconde ne renvoie que les résultats dépassant une valeur donnée, et peut n’en renvoyer aucun. Cette dernière propriété est indispensable lorsque le système doit pouvoir déclarer qu’il ne sait pas.
- **Réordonnement et filtrage.** Le réordonnement change l’ordre des résultats sans en modifier le nombre. Le filtrage en réduit le nombre. Le dispositif décrit dans ce rapport relève du filtrage.
- **Fusion par rangs réciproques.** Méthode de combinaison de plusieurs classements qui utilise le rang de chaque élément et non son score. Pour un élément de rang r dans un classement donné, la contribution s’écrit :

$$\text{RRF}(d) = \sum_{c \in C} \frac{1}{k + r_c(d)} \quad (4.1)$$

où C désigne l’ensemble des classements, $r_c(d)$ le rang du document d dans le classement c , et k une constante d’amortissement fixée à 60 dans ce projet. L’intérêt de cette formulation est qu’elle dispense de ramener à une échelle commune des scores de natures différentes, ce qui serait nécessaire pour combiner directement une similarité cosinus et une pondération lexicale.

A.4 Qualité

- **Précision et rappel.** La précision est la proportion de résultats pertinents parmi les résultats retournés. Le rappel est la proportion de documents pertinents effectivement retrouvés parmi tous ceux qui existent. Le dispositif décrit dans ce rapport privilégie explicitement la précision.
- **Hallucination et récupération incorrecte.** Dans le premier cas, le modèle produit une information absente des passages fournis. Dans le second, les passages fournis sont inadaptes mais le modèle les a fidèlement utilisés. La distinction importe car les deux défauts appellent des corrections opposées, l'une portant sur la génération et l'autre sur la récupération.

A.5 Temps

- **Latence et temps de réponse.** La latence est le délai d'attente avant le début du traitement. Le temps de réponse est la durée totale, de la requête à la réponse complète.
- **Démarrage à froid et index vide.** Dans le premier cas l'index existe mais n'est pas encore chargé en mémoire, la première interrogation est donc lente. Dans le second aucun document n'est indexé, et aucune interrogation ne peut aboutir. Les deux se manifestent par une absence de résultat et appellent des diagnostics différents.
- **Fenêtre de contexte et longueur de contexte.** La première est la capacité maximale du modèle. La seconde est le nombre de jetons effectivement utilisés pour une requête donnée.



Annexe B : Métriques de la chaîne vocale

B.1 Notions de traitement du signal

- **Fréquence d'échantillonnage.** Nombre d'échantillons prélevés par seconde, exprimé en hertz. Les chaînes vocales conversationnelles emploient couramment 16 kHz.
- **Fenêtre et pas d'analyse.** Taille de la fenêtre découpant le signal et décalage entre deux fenêtres consécutives lors de l'extraction des caractéristiques.
- **Transformée de Fourier à court terme.** Conversion du signal du domaine temporel vers le domaine fréquentiel, fenêtre par fenêtre.
- **Échelle de Mel.** Échelle de fréquences approchant la perception humaine de la hauteur, utilisée pour compresser un spectrogramme en bandes perceptivement pertinentes.
- **Rapport signal sur bruit.** Rapport entre la puissance du signal utile et celle du bruit de fond, exprimé en décibels :

$$\text{SNR}_{\text{dB}} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{bruit}}} \right) \quad (4.2)$$

B.2 Transcription de la parole

Notions

- **Détection d'activité vocale.** Distinction entre les segments contenant de la parole et les segments silencieux dans un flux audio.
- **Détermination de fin de tour.** Décision indiquant que le locuteur a terminé son énoncé, à partir de la durée du silence et de la stabilité de la transcription.
- **Segmentation en locuteurs.** Attribution de chaque segment de parole au locuteur qui l'a produit.
- **Transcription partielle et transcription définitive.** La première est produite au fil de l'audio et reste susceptible d'être révisée. La seconde est stabilisée et ne change plus.

- **Normalisation inverse du texte.** Conversion de la forme orale vers la forme écrite, par exemple d'un montant énoncé en toutes lettres vers son écriture chiffrée.
- **Amorçage par termes attendus.** Transmission au modèle d'une liste de termes propres au domaine afin d'améliorer leur reconnaissance.

Métriques

Le taux d'erreur sur les mots rapporte les erreurs au nombre de mots de la référence, l'alignement étant obtenu par distance d'édition :

$$\text{WER} = \frac{S + D + I}{N} \quad (4.3)$$

où S désigne les substitutions, D les omissions, I les insertions et N le nombre de mots de la référence. Le taux d'erreur sur les caractères applique la même formule au niveau du caractère, ce qui le rend plus indulgent pour les langues morphologiquement riches et pour les variantes orthographiques mineures.

Le taux d'erreur d'appariement borne le résultat entre zéro et un, contrairement au taux d'erreur sur les mots qui peut le dépasser en cas d'insertions nombreuses :

$$\text{MER} = \frac{S + D + I}{N + I} \quad (4.4)$$

Le taux d'erreur de segmentation en locuteurs mesure la qualité de l'attribution de la parole :

$$\text{DER} = \frac{\text{fausses alarmes} + \text{omissions} + \text{confusions de locuteur}}{\text{durée totale de parole de référence}} \quad (4.5)$$

Le facteur temps réel rapporte la durée de traitement à la durée de l'audio traité :

$$\text{RTF} = \frac{T_{\text{traitement}}}{T_{\text{audio}}} \quad (4.6)$$

Une valeur inférieure à un indique un traitement plus rapide que le temps réel, condition nécessaire au fonctionnement en flux continu. Une valeur supérieure à un signifie que le retard s'accumule à mesure que la parole se poursuit.

B.3 Synthèse vocale

Notions

- **Conversion graphème phonème.** Passage du texte écrit à la suite de phonèmes à prononcer.
- **Normalisation du texte.** Développement des nombres, dates, abréviations et symboles vers leur forme prononçable.
- **Prosodie.** Ensemble des variations de hauteur, d'accentuation, de rythme et d'intonation appliquées à la parole produite.
- **Prédicteur de durée.** Composant déterminant la durée de chaque phonème.
- **Vocodeur.** Composant convertissant la représentation acoustique intermédiaire en forme d'onde audible.
- **Synthèse autorégressive et non autorégressive.** La première produit l'audio image par image, avec une qualité élevée et une latence importante. La seconde produit en parallèle, ce qui convient mieux au fonctionnement en flux continu.
- **Synthèse par fragments.** Émission de l'audio par portions successives dès qu'elles sont disponibles, plutôt qu'après constitution de l'énoncé complet. Cette propriété a constitué un critère éliminatoire dans ce projet.

Métriques

La note moyenne d'opinion est une évaluation subjective du naturel de la voix, généralement établie sur une échelle de un à cinq et moyennée sur un panel d'auditeurs.

La distorsion cepstrale sur l'échelle de Mel mesure objectivement l'écart entre une voix synthétisée et une voix de référence :

$$\text{MCD} = \frac{10}{\ln 10} \sqrt{2 \sum_{i=1}^M (mc_i - mc'_i)^2} \quad (4.7)$$

où mc_i et mc'_i désignent les coefficients cepstraux de la référence et du signal synthétisé. Une valeur faible traduit une proximité élevée.

L'évaluation perceptuelle de la qualité vocale et l'intelligibilité objective à court terme complètent cette appréciation, la première sur la qualité globale et la seconde sur l'intelligibilité en présence de bruit ou de distorsion.

Le facteur temps réel s'applique également à la synthèse, en rapportant la durée de production à la durée de l'audio produit. Le délai avant le premier fragment audio mesure quant à lui

le temps écoulé entre la demande de synthèse et l'émission du premier son. C'est cette dernière grandeur, et non la durée totale, qui gouverne la latence perçue dans une chaîne diffusée en continu.

B.4 Chaîne de latence de bout en bout

La latence totale perçue par le client est la somme des contributions de chaque étape :

$$T_{\text{total}} \approx T_{\text{fin de tour}} + T_{\text{STT}} + T_{\text{contexte}} + T_{\text{rcupration}} + T_{\text{TTFT}} + T_{\text{TTFA}} + T_{\text{rseau}} \quad (4.8)$$

Deux remarques accompagnent cette formulation. La première est que chaque terme peut être optimisé indépendamment, ce qui rend l'analyse par étape pertinente. La seconde est que la diffusion en continu de la transcription et de la synthèse réduit la latence perçue même lorsque le temps de traitement total demeure inchangé, puisqu'elle permet aux étapes de se recouvrir partiellement.



Annexe C : Notions relatives aux systèmes agentiques

C.1 Modèles de langue

- **Jeton.** Unité élémentaire manipulée par le modèle, correspondant à un mot, à une portion de mot ou à un signe de ponctuation. La facturation et les limites de capacité s'expriment en jetons.
- **Fenêtre de contexte.** Nombre maximal de jetons que le modèle peut prendre en compte simultanément, instructions, historique et documents compris.
- **Inférence.** Calcul produisant la réponse à partir de l'entrée fournie. Elle ne modifie pas les paramètres du modèle.
- **Délai avant le premier jeton.** Temps écoulé entre l'envoi de la requête et l'arrivée du premier élément de réponse. Grandeur déterminante en contexte conversationnel.
- **Appel d'outils.** Capacité du modèle à désigner une fonction externe et à en construire les arguments, plutôt que de produire directement du texte. Cette capacité conditionne l'existence même d'un système agentique.
- **Limitation de débit.** Restriction imposée par un fournisseur sur le nombre de requêtes ou de jetons par unité de temps. Elle constitue une contrainte de conception réelle, et non un simple paramètre commercial, car elle détermine le nombre de conversations simultanées soutenables.
- **Modèle ouvert et modèle propriétaire.** Le premier peut être hébergé et adapté localement, ce qui offre la maîtrise des données et l'absence de quota, au prix des ressources matérielles nécessaires. Le second est accessible par service distant, généralement plus performant, mais introduit une dépendance externe et des limites d'usage.

C.2 Agents

- **Agent.** Composant qui reçoit une demande, dispose d'un ensemble borné de capacités, se voit imposer des contraintes, et produit soit une réponse, soit un appel de capacité, soit une transmission.

- **Processus agent.** Unité d'exécution prenant en charge une session, dotée de son propre état et créée ou libérée selon l'activité.
- **Persona.** Ensemble formé par le rôle d'un agent, ses instructions, ses capacités et son périmètre de responsabilité.
- **Orchestration.** Coordination de plusieurs agents, incluant la désignation de l'agent actif, le passage de relais et la conservation du contexte lors de ce passage.
- **Garde fou.** Contrainte appliquée en dehors du modèle, qui valide ou refuse une intention ou un énoncé avant qu'il ne produise un effet.

C.3 Progression des pratiques d'ingénierie

Trois niveaux de pratique se sont succédé, chacun englobant le précédent.

L'ingénierie des instructions porte sur la formulation des consignes adressées au modèle. Elle produit des résultats rapides et atteint ses limites lorsque les consignes s'allongent, car un modèle applique inégalement une instruction longue.

L'ingénierie du contexte porte sur la sélection des informations mises à disposition du modèle, sur le moment de leur insertion et sur leur durée de vie. Elle traite le contexte comme une ressource limitée qu'il faut allouer, et non comme un espace à remplir.

L'ingénierie du harnais porte sur le système qui entoure le modèle : bornage des capacités, validation des intentions, contrôle des énoncés, enregistrement des décisions et reprise en main en cas d'échec. C'est à ce niveau que se situent les garanties du système, car elles ne peuvent pas reposer sur le comportement d'un composant probabiliste.



Annexe D : Modèle détaillé de sécurité et d'audit

D.1 Distinction entre authentification et autorisation

L'authentification répond à la question de l'identité de l'utilisateur. L'autorisation répond à celle de ce qu'il lui est permis d'atteindre. Les confondre conduit à un défaut classique, où le seul fait d'être authentifié vaut permission.

Dans la plateforme, ces deux fonctions sont séparées explicitement. L'authentification établit une identité et ouvre une session. L'autorisation est évaluée à chaque requête, à partir du rôle déduit de cette session et jamais à partir d'une information fournie par l'appelant.

D.2 Codes de réponse et sémantique

- **401.** La requête n'est pas authentifiée. Aucune identité n'a été établie ou la session n'est plus valide.
- **403.** La requête est authentifiée mais l'identité établie ne dispose pas des droits requis.

Cette distinction est significative pour le diagnostic comme pour la sécurité : elle sépare le défaut d'identité du défaut de droits, sans révéler à un appelant non autorisé l'existence ou l'absence de la ressource visée.

D.3 Protection des éléments d'authentification

Les éléments d'authentification sont conservés sous forme dérivée au moyen d'une fonction de hachage à coût mémoire élevé, choisie pour rendre coûteuse une attaque par recherche exhaustive même sur du matériel spécialisé. Les paramètres employés suivent les recommandations en vigueur pour un usage interactif.

Ces paramètres sont enregistrés avec chaque empreinte plutôt que fixés globalement. Cette disposition permet de les renforcer ultérieurement sans invalider les comptes existants ni imposer une migration : la vérification lit les paramètres de l'enregistrement qu'elle contrôle.

D.4 Sessions révocables

Une session n'est pas un jeton autoportant dont la validité s'apprécierait à sa seule lecture, mais une référence revalidée auprès de son enregistrement à chaque requête.

Le coût de ce choix est une consultation supplémentaire par requête. Le bénéfice est qu'une déconnexion, une expiration ou une révocation globale prennent effet immédiatement. Un jeton autoportant serait resté valide jusqu'à son échéance, laissant subsister une fenêtre pendant laquelle une session révoquée demeure exploitable.

D.5 Isolation des données entre clients

La vérification d'appartenance ne porte pas sur l'identifiant transmis dans la requête, qui est sous le contrôle de l'appelant, mais sur la correspondance entre la ressource demandée et l'identité établie par la session. Cette disposition prévient l'élévation de privilèges horizontale, par laquelle un utilisateur légitime accèderait aux données d'un autre utilisateur de même niveau.

D.6 Vérification d'identité renforcée

Les opérations sensibles engagées au cours d'une conversation exigent une vérification distincte de l'ouverture de session, fondée sur un élément que seul le titulaire connaît.

Cette vérification est bornée par un nombre maximal de tentatives, un nombre maximal de réponses inexploitable et une échéance globale. Trois délais sont ordonnés strictement, du plus court au plus long : celui de l'appel de vérification, celui de la procédure complète, puis celui du contrôle qui l'englobe. Cet ordre garantit qu'une défaillance est signalée au niveau où elle se produit plutôt qu'absorbée par le délai supérieur.

Le résultat conservé n'est pas un simple indicateur. Il comprend l'identifiant du client vérifié, le niveau atteint, l'horodatage, l'échéance et la méthode employée. Une vérification vaut donc pour un client déterminé et pour une durée déterminée.

D.7 Chaîne d'audit

Chaque enregistrement d'audit intègre l'empreinte du précédent dans le calcul de la sienne :

$$h_n = \text{SHA-256}(h_{n-1} \parallel \text{JSON}_{\text{canonique}}(p_n) \parallel t_n) \quad (4.9)$$

où h_{n-1} est l’empreinte de l’enregistrement précédent, p_n la charge utile du présent enregistrement, t_n son horodatage, et $\parallel$ l’opération de concaténation. La forme canonique de la représentation garantit qu’un même contenu produit toujours la même empreinte, indépendamment de l’ordre de sérialisation des champs.

La modification d’un enregistrement ancien invalide son empreinte et, par propagation, toutes les empreintes postérieures. Un recalcul complet de la chaîne suffit donc à détecter l’altération et à en localiser le point d’origine.

Deux propriétés complètent ce mécanisme. Les ajouts sont sérialisés par un verrou porté par la base de données, faute de quoi deux écritures simultanées liraient la même empreinte précédente et produiraient une chaîne incohérente. L’écriture d’audit ne valide par ailleurs pas sa propre transaction, de sorte que l’enregistrement métier et sa trace sont validés ensemble ou abandonnés ensemble.

Il convient de souligner ce que cette construction garantit et ce qu’elle ne garantit pas. Elle n’empêche pas une modification, ce qu’aucun mécanisme de stockage ne permet réellement. Elle garantit qu’une modification ne peut pas passer inaperçue.